Analytical Model for the Characterization and Prediction of Emergency Demand in the Natural Gas Distribution Network of Montería, Colombia. Case Study: Surtigas

Germán Eduardo De Armas Castaño, Sebastián Henrique Delgado Solano,
Ángel Luis Vega Rodríguez, Victoria Sofía Ripoll Nieves

Advisor: PhD. Jenifer Yoris Vasquez Aguilar

gdearmas@utb.edu.co, delgados@utb.edu.co, anvega@utb.edu.co, vripoll@utb.edu.co, jenvasquez@utb.edu.co

Universidad Tecnológica de Bolívar, Colombia

Abstract. Surtigas handles the emergencies of its natural gas network in Montería reactively: crews are dispatched only after a user reports an incident. Crew capacity is planned with simple references to recent demand. This study asks whether a predictive model trained on 50,195 emergency records (2017-2026) can reduce the daily forecast error and the mis-sized crew hours. The CRISP-ML(Q) process model guided the work, with business process management as a cross-cutting framework. Seven techniques were trained under a leakage-free temporal protocol: XGBoost, LSTM, BiLSTM, a one-dimensional convolutional network and three count models (Poisson, negative binomial and zero-inflated negative binomial). Technique and input window were chosen with a 4×5 factorial experiment with three replicates on the validation block, and the test set was consulted once. The technique explained 59 % of the variation in validation error, while the window had no significant effect. XGBoost achieved the lowest validation error (MAE 5.46) and was the most stable technique across seeds and windows. On the test year its mean absolute error was 4.22 emergencies per day, 34 % lower than the best reference method (6.40). It was significantly better than the count models and the references, and not significantly different from the neural networks. Translated into crew time, the forecast reduces mis-sized crew hours by an estimated 1,468 hours per year. In a simulated scenario, allocating crews across districts by their emergency probability cuts deficit hours by 24 % with the same staffing. When late responses are valued under current regulation, a reserve crew pays off only if the annual probability of a maximum regulatory fine exceeds 3 %. The zero-inflated model provides the probability of high-demand days, and a Bayesian network shows that holidays and weekends account for most of the low-demand days. The results support a planning scheme with daily forecasts and monthly retraining, which was implemented in a role-based dashboard for operations, management and analytics staff.

Keywords. emergency demand forecasting, natural gas distribution, count models, XGBoost, CRISP-ML(Q), Surtigas, Montería.

Modelo analítico para la caracterización y predicción de la demanda de emergencias en la red de distribución de gas natural de Montería, Colombia. Caso de estudio: Surtigas

Germán Eduardo De Armas Castaño, Sebastián Henrique Delgado Solano,
Ángel Luis Vega Rodríguez, Victoria Sofía Ripoll Nieves

Asesora: PhD. Jenifer Yoris Vasquez Aguilar

Universidad Tecnológica de Bolívar, Colombia

Resumen. Surtigas atiende las emergencias de su red de gas natural en Montería de forma reactiva, ya que las cuadrillas se despachan solo después del reporte del usuario. La capacidad se programa con referencias simples de la demanda reciente. El proyecto evalúa si un modelo predictivo entrenado con 50 195 registros de emergencias (2017-2026) reduce el error del pronóstico diario y las horas de cuadrilla mal dimensionadas. El proyecto siguió el modelo de proceso CRISP-ML(Q), con la gestión de procesos de negocio como marco transversal. Con base en él, se compararon siete técnicas bajo un protocolo temporal sin fugas de información. Cuatro de ellas son de aprendizaje automático: XGBoost, una red de memoria a corto y largo plazo (LSTM), su variante bidireccional (BiLSTM) y una red convolucional unidimensional. Las otras tres son modelos de conteo: Poisson, binomial negativa y su versión inflada en ceros. La técnica y la ventana de entrada se eligieron con un diseño factorial 4×5 con tres réplicas sobre el bloque de validación. El conjunto de prueba, en cambio, se reservó para una única evaluación final. La técnica explicó el 59 % de la variación del error de validación, mientras que la ventana no tuvo efecto significativo. XGBoost obtuvo el menor error de validación y fue la técnica más estable entre semillas y ventanas. En el año de prueba alcanzó un error absoluto medio de 4,22 emergencias por día, un 34 % menor que el del mejor método de referencia. Fue significativamente mejor que los modelos de conteo y las referencias, y sin diferencia significativa frente a las redes neuronales. Traducida a tiempo de cuadrilla, esa mejora equivale a unas 1468 horas anuales menos de capacidad mal dimensionada. En un escenario simulado, repartir las cuadrillas entre sectores según la probabilidad de cada uno reduce en 24 % las horas en déficit con la misma capacidad. Las emergencias atendidas fuera de la hora se valoraron con la regulación vigente. Con esa valoración, la cuadrilla de reserva solo conviene si la probabilidad anual de una sanción máxima supera el 3 %. Además, el modelo inflado en ceros estima la probabilidad de los días de alta demanda. Una red bayesiana, por su parte, indica que festivos y fines de semana concentran la mayor parte de los días de demanda baja. Por lo tanto, los resultados respaldan un esquema de planificación con pronóstico diario y reajuste mensual. Ese esquema se integró en un tablero de control con una vista para cada rol: operativo, administrativo y técnico.

Palabras clave. predicción de demanda de emergencias, distribución de gas natural, modelos de conteo, XGBoost, CRISP-ML(Q), Surtigas, Montería.

1. Introducción

La aplicación de la analítica de datos en redes de gas se ha concentrado en la detección física de fugas. Por ejemplo, se han propuesto modelos que detectan fugas en gasoductos a partir de señales de emisión acústica y aprendizaje automático [1]. Sin embargo, pocos estudios han abordado una pregunta distinta: cuántas emergencias llegarán cada día al centro de control del distribuidor. Ese pronóstico sí se ha desarrollado en los servicios médicos de emergencia, donde la demanda diaria de ambulancias se pronostica para planificar el personal y la flota [2], [3]. En cambio, no se encontró un trabajo equivalente para la distribución de gas en una ciudad intermedia de Colombia.

Esta brecha tiene consecuencias prácticas. En Colombia, la Comisión de Regulación de Energía y Gas (CREG) define los indicadores de calidad de la distribución de gas [4]. Uno de ellos es el índice de respuesta a servicio técnico (IRST), que mide el porcentaje de solicitudes atendidas dentro de un tiempo de referencia según el tipo de evento. Cumplirlo exige que haya cuadrillas disponibles cuando llega la demanda y, por lo tanto, conviene anticiparla.

Surtigas, fundada en 1968 en Cartagena, distribuye gas natural desde 1979 y en la década de 1990 extendió su red a 32 municipios de Bolívar, Sucre y Córdoba [5]. En Montería, la empresa conserva un registro de 50 195 emergencias atendidas entre 2017 y 2026. La capacidad se programa con referencias simples de la demanda reciente, y la asignación de cuadrillas comienza cuando el usuario reporta el incidente. Si la demanda cambia de un día a otro, esa programación deja días con déficit de cuadrillas y días con horas ociosas.

Por ello, este proyecto estudia en qué medida un pronóstico construido con ese registro reduce ambos desajustes. Con base en lo anterior, propone un modelo analítico que caracteriza la demanda de emergencias y la pronostica con un día de anticipación. El desarrollo siguió el modelo de proceso CRISP-ML(Q) (*Cross-Industry Standard Process for Machine*

Learning with Quality assurance) [6]. Además, se compararon siete técnicas mediante un diseño de experimentos, bajo un protocolo temporal sin fugas de información, y se estimó el beneficio operativo en horas de cuadrilla. Cada técnica evaluada responde a un rasgo de la demanda que el análisis exploratorio mostró en los datos.

El documento se organiza de la siguiente manera. La sección 2 presenta el marco teórico, revisa la literatura y expone las brechas que el proyecto atiende. La sección 3 plantea el problema y las preguntas de investigación, y las secciones 4 y 5 exponen los objetivos y la metodología. La sección 6 presenta los resultados, incluido el tablero de control del OE4. La sección 7 desarrolla el análisis costo-beneficio en tres partes: los costos del proyecto, los beneficios asociados y la rentabilidad. Entre los beneficios están el escenario simulado de asignación por sector y el costo por incumplimiento del tiempo de atención. Por último, se exponen las conclusiones y las limitaciones del proyecto.

2. Marco teórico y revisión de la literatura

2.1. Marco teórico

2.1.1. Modelos de conteo: La distribución de Poisson describe el número de eventos en un intervalo cuando ocurren de forma independiente y con tasa constante. Una variable X sigue una distribución de Poisson con parámetro $\lambda > 0$ si

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \qquad k = 0, 1, 2, \ldots \tag{1}$$

con $E[X] = \mathrm{Var}(X) = \lambda$. Esta igualdad, llamada equidispersión, rara vez se cumple en datos reales. En regresión, la media se vincula con las covariables mediante $\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$, lo que define un modelo lineal generalizado (GLM) [7].

Cuando la varianza supera a la media, la binomial negativa (BN) añade un parámetro de dispersión r, de modo que $\mathrm{Var}(Y) = \mu + \mu^2/r$ [7]. Si además hay más ceros de los esperados, se usa el modelo binomial negativo inflado en ceros (ZINB). Este modelo mezcla un proceso que genera ceros estructurales, con probabilidad π_i, y un proceso BN [8]:

$$P(Y_i = y) = \begin{cases} \pi_i + (1 - \pi_i)\, f_{\mathrm{BN}}(0 \mid \mu_i, r), & y = 0, \\ (1 - \pi_i)\, f_{\mathrm{BN}}(y \mid \mu_i, r), & y > 0, \end{cases} \tag{2}$$

donde $\log(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$ y $\mathrm{logit}(\pi_i) = \mathbf{z}_i^\top \boldsymbol{\gamma}$. Su media es $(1-\pi_i)\mu_i$. La Fig. 1 compara las tres distribuciones con la misma media: la BN tiene colas más pesadas que la Poisson y la ZINB concentra además masa en el cero.

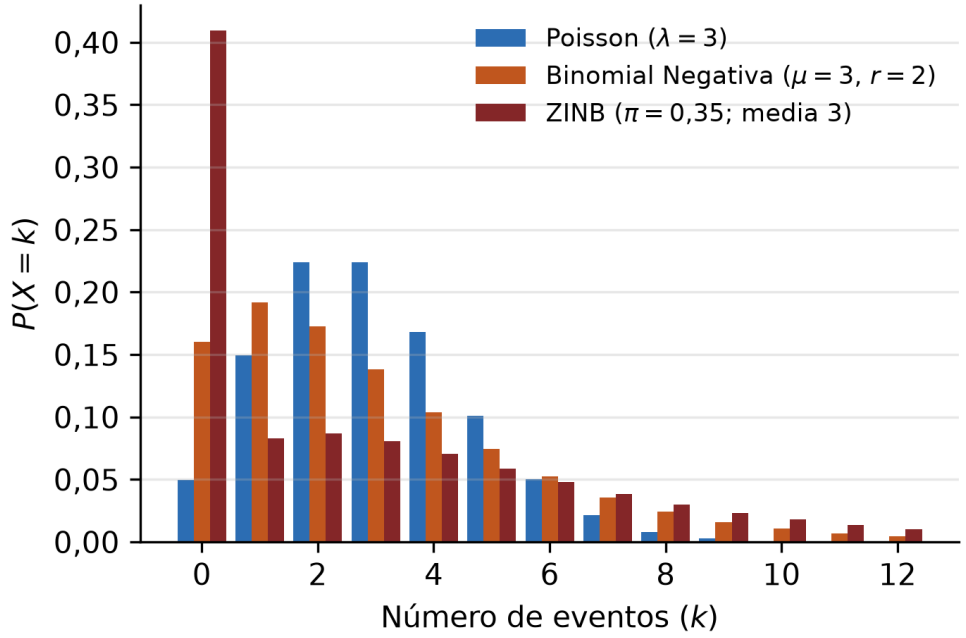


Figura 1. Distribuciones de Poisson, BN y ZINB con media igual a 3. Los parámetros son ilustrativos: la inflación de ceros ($\pi = 0{,}35$) se exageró para que se distinga, mientras que la estimada en los datos es cercana a 0,005.

Además del error puntual, un modelo de conteo se evalúa por la calidad de la distribución que predice. La log-verosimilitud negativa media (NLL) premia asignar alta probabilidad al valor observado. El puntaje de probabilidad continua ordenada (CRPS) compara toda la distribución predicha con la observación [9].

2.1.2. Modelos de aprendizaje automático: Los modelos de conteo suponen que la demanda se relaciona con sus covariables de forma log-lineal, mientras que los métodos de aprendizaje automático no imponen esa forma. XGBoost (*extreme gradient boosting*) construye un pronóstico aditivo $\hat{y}_i = \sum_m f_m(\mathbf{x}_i)$ en el que cada árbol corrige los residuos del anterior [10]. Su función objetivo incluye la regularización $\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_j w_j^2$, que penaliza el número de hojas T y la magnitud de sus pesos w_j. Como no procesa secuencias, la dependencia temporal se incorpora con rezagos de la serie.

Las redes neuronales recurrentes, en cambio, leen la serie como una secuencia, aunque en su versión simple pierden la señal del error en secuencias largas [11]. La red de memoria a corto y largo plazo (LSTM) mitiga ese problema con compuertas de olvido, entrada y salida [11], [12]. La variante bidireccional (BiLSTM) recorre la ventana en ambos sentidos [13]. En este proyecto, la ventana solo contiene días anteriores al día pronosticado, por lo que la lectura bidireccional no introduce información futura. La red convolucional unidimensional (1D-CNN), por su parte, aplica filtros sobre el eje temporal y extrae patrones locales de la serie [14].

Dos modelos más cumplen funciones de apoyo. Una red bayesiana (RB) representa la distribución conjunta de variables discretas mediante un grafo acíclico dirigido y permite consultar la probabilidad de una variable dadas otras [15]. El bosque aleatorio promedia árboles de decisión entrenados sobre submuestras [16]; aquí se usó para imputar tiempos de respuesta y para pronosticarlos.

2.2. Estado del arte

En Scopus, ScienceDirect y la biblioteca virtual de la Universidad Tecnológica de Bolívar, la mayoría de los trabajos con aprendizaje automático en redes de gas vigila la infraestructura. Se priorizaron los publicados en los últimos siete años. Una revisión reciente recopila los métodos de detección de fugas en tuberías y analiza sus ventajas y limitaciones [17]. Según esa revisión, estos métodos no evitan las fugas, pero limitan su impacto al detectarlas a tiempo. En esa línea, un estudio simuló fugas de distinta magnitud en un gasoducto y las clasificó con señales acústicas [1]. Su red neuronal de base radial, optimizada con un algoritmo genético, alcanzó una exactitud del 97 % frente a otras dos redes neuronales. Estos sistemas buscan localizar amenazas físicas, pero no anticipan la carga de trabajo que esas amenazas generan para el operador.

Otros servicios públicos domiciliarios sí pronostican la carga que generan las fallas de su red. En la distribución eléctrica del noreste de Estados Unidos, por ejemplo, se desarrollaron dos modelos que predicen el número de interrupciones causadas por tormentas de nieve y hielo [18]. Al comparar un modelo de aprendizaje automático con un GLM, el GLM predijo mejor los eventos extremos, y el primero, los de menor impacto. Esa misma comparación entre aprendizaje automático y modelos de conteo es la que este proyecto aplica a las emergencias de gas.

El pronóstico de la demanda diaria de emergencias cuenta, además, con antecedentes en el sector salud. En Gran Bretaña, la demanda diaria de ambulancias se pronosticó por región, prioridad y tipo de incidente, con pronósticos puntuales y probabilísticos coherentes entre niveles [2]. Otros trabajos predicen la demanda de llamadas con aprendizaje automático espaciotemporal [3] o con índices biometeorológicos [19]. Para llegar a los estudios más recientes, la búsqueda se amplió con Asta, el asistente de investigación con inteligencia artificial del Allen Institute for AI [20]. Asta busca sobre el índice de Semantic Scholar, y cada fuente que sugirió se verificó en la publicación original. Así se encontró un estudio que comparó nueve algoritmos para pronosticar la demanda de corto plazo de los servicios médicos de emergencia. En él, los métodos de *boosting* obtuvieron el mejor desempeño [21]. También se encontró, en América Latina, un conjunto de datos reproducible para pronosticar la demanda semanal de urgencias respiratorias en 180 hospitales de Chile [22]. Estos antecedentes muestran que la demanda de emergencias tiene regularidades que permiten anticiparla, y orientaron la búsqueda de patrones de calendario en este proyecto.

En cuanto a los métodos de pronóstico, los modelos autorregresivos integrados de media móvil (ARIMA) y su versión estacional (SARIMA) son la referencia clásica para series de tiempo [9], [23]. Sin embargo, su forma lineal limita la captura de interacciones entre el calendario y los rezagos. Para capturar esas interacciones se emplean métodos no lineales, como los ensambles de árboles con gradiente, que dominaron competencias recientes de pronóstico [10], [24], y las redes recurrentes [25].

Por último, muchos estudios aplicados no usan un protocolo de evaluación que evite fugas de información. Una revisión de 17 campos encontró 294 trabajos afectados por fugas, como entrenar con datos posteriores a los de prueba o seleccionar variables con el conjunto de prueba [26]. Elegir el modelo con el error del conjunto de prueba produce, además, estimaciones optimistas de su desempeño [27]. En series de tiempo, la partición de los datos debe respetar el orden cronológico [9], [27].

2.3. Brechas identificadas y aporte de la propuesta

El estado del arte muestra dos brechas. La primera es de aplicación. En las redes de gas, el aprendizaje automático detecta fugas, pero no pronostica la carga de trabajo que generan para el operador. Otros servicios, como la distribución

eléctrica y las ambulancias, sí pronostican esa carga, y en ellos los modelos de conteo y de aprendizaje automático muestran fortalezas distintas. La segunda brecha es de método. Muchos estudios aplicados eligen sus modelos sin un protocolo libre de fugas, o con el conjunto de prueba, lo que sobrestima su desempeño.

En consecuencia, este proyecto contribuye a dos áreas: aplica estos métodos a la demanda de emergencias de un distribuidor de gas y documenta un protocolo de selección sin fugas. Además, lleva el pronóstico a horas de cuadrilla, a pesos y a un tablero de control para la operación diaria. Así, el resultado no se queda en una métrica de error, sino que se traduce en decisiones de capacidad.

3. Planteamiento del problema y preguntas de investigación

3.1. Generalidades del sector y de la empresa

La distribución de gas natural por redes en Colombia está regulada por la CREG y vigilada por la Superintendencia de Servicios Públicos Domiciliarios (SSPD). Este proyecto se ajusta al marco vigente en 2026, que combina dos normas. La primera es el Código de Distribución de Gas Combustible por Redes, adoptado con la Resolución CREG 067 de 1995 [28]. Las Resoluciones CREG 059 de 2012, 127 de 2013, 033 de 2015 y 240A de 2016, entre otras, modificaron este código. Esos cambios tocaron la puesta en servicio, la medición, la facturación y el cálculo de pérdidas. Su numeral 5.7, sin embargo, conserva el texto original y fija en una hora el tiempo máximo entre el reporte de una emergencia y la llegada del equipo. Además, el numeral 5.8 obliga a registrar todas las emergencias con su causa y su correctivo, y un registro de ese tipo es la fuente de datos de este proyecto. La segunda es la Resolución CREG 100 de 2003, modificada por las Resoluciones CREG 009 de 2005 y 005 de 2006 y complementada por la CREG 016 de 2006 [4]. Esta norma define el IRST como el porcentaje de solicitudes atendidas dentro del tiempo de referencia de su tipo de evento. Los tipos de evento son escape de gas, incendio, calidad de la llama e interrupción del servicio.

Sin embargo, la CREG no ha fijado esos tiempos de referencia por tipo de evento. Por ello, la SSPD evalúa el IRST con el límite de una hora del Código de Distribución y solo para los incendios [29]. En 2024, el cumplimiento nacional de ese indicador en gas natural fue del 99 %. En consecuencia, este proyecto toma una hora como tiempo de referencia para la atención de emergencias. Ese tiempo depende, entre otros factores, de que haya cuadrillas disponibles cuando llega la solicitud.

Surtigas atiende la región Caribe colombiana [5], y este proyecto se centra en su sucursal de Montería, capital de Córdoba. Su centro de control recibe las solicitudes, asigna una cuadrilla y registra las marcas de tiempo de asignación, llegada, control y finalización de cada orden. Según su personal, consultado en las visitas a la sucursal, el centro de control sigue en tiempo real la ubicación de las cuadrillas, con cierto retraso. Sin embargo, las cuadrillas no se ubican con anticipación según dónde suelen ocurrir las emergencias, sino que se desplazan a medida que llegan las solicitudes.

3.2. Identificación del problema

La operación es reactiva: la asignación de cuadrillas empieza con el reporte del usuario. Sin embargo, la demanda no es estable. El promedio diario pasó de 12 emergencias en 2017 a 20 en 2024, y varía con fuerza entre los días de la semana. En este proyecto, la capacidad es el número de cuadrillas programadas en un día, que equivale a 8 h por cuadrilla. Como la capacidad se programa con referencias simples de la demanda reciente, los días de alta demanda quedan con déficit y los de baja demanda con capacidad ociosa.

Este ajuste reactivo de la capacidad genera sobrecostos. Cuando la demanda supera a las cuadrillas programadas, el déficit se cubre con horas extra, con un recargo del 25 % [30]. También se cubre con traslados desde otros sectores, que consumen tiempo y combustible. Cuando la demanda es menor, la empresa paga turnos completos que no atienden emergencias. Con la referencia simple que hoy se usa, se estiman unas 3878 h anuales de capacidad mal dimensionada. En la línea base simulada, las horas extra cuestan $51,86 millones al año y los traslados, $11,13 millones (sección 7).

Para una empresa de servicios públicos, el déficit es lo más crítico, porque de él depende la atención de las emergencias no controladas. Estas exigen una llegada en menos de una hora, porque comprometen la seguridad de los usuarios. En Montería, el 99 % de ellas se atiende hoy dentro de ese límite. El problema actual no es, entonces, el incumplimiento, sino lo que cuesta cumplir. Además, ese cumplimiento podría deteriorarse si la demanda sigue creciendo. En la línea base, el déficit que excede el límite legal de horas extra pasa de 337 h en el año de prueba a 509 h en el quinto año. Por ello, la operación debe concentrarse en reducir el déficit y, a la vez, las horas ociosas. El registro contiene la información para anticipar la demanda, pero no se ha usado con ese fin.

3.3. Preguntas de investigación

Pregunta principal: ¿En qué medida un modelo predictivo entrenado con el registro de emergencias de Surtigas reduce el error del pronóstico diario y las horas de cuadrilla mal dimensionadas?

Preguntas específicas:

- ¿Qué patrones de calendario, tendencia y dispersión caracterizan la demanda diaria de emergencias?

- ¿Qué técnica pronostica la demanda diaria con menor error y mayor estabilidad bajo un protocolo sin fugas?
- ¿Cuántas horas de cuadrilla mal dimensionadas evita el pronóstico y cuál es su valor económico?
- ¿Qué indicadores necesita cada rol del centro de control para usar el pronóstico en sus decisiones?

La pregunta principal tiene dos partes: el error del pronóstico frente a las referencias simples y su efecto en horas de cuadrilla y en pesos.

4. Objetivo general y objetivos específicos

Para responder las preguntas de investigación se plantearon un objetivo general y cuatro objetivos específicos. Cada objetivo específico responde una pregunta específica. El OE1 y el OE2 atienden la primera parte de la pregunta principal, el OE3 la segunda, y el OE4 lleva los resultados a la operación.

4.1. Objetivo general

Desarrollar un modelo analítico predictivo para caracterizar y proyectar la demanda operativa de emergencias en la infraestructura de gas natural de Montería.

4.2. Objetivos específicos

OE1. Realizar un análisis exploratorio de datos (EDA) del registro histórico de emergencias operativas, con el fin de identificar sus patrones espacio-temporales y establecer la línea base del proyecto.

OE2. Comparar técnicas estadísticas y de aprendizaje automático mediante un diseño de experimentos con validación temporal, para seleccionar el modelo de pronóstico de menor error.

OE3. Evaluar el beneficio operativo del modelo seleccionado mediante un análisis costo-beneficio a partir de la reducción de horas de cuadrilla mal dimensionadas.

OE4. Integrar los pronósticos y sus indicadores en un tablero interactivo, como herramienta de apoyo a la toma de decisiones del Centro de Control de Surtigas.

5. Metodología

Para cumplir esos objetivos, el proyecto siguió el modelo de proceso CRISP-ML(Q), que organiza el desarrollo de un modelo de aprendizaje automático en seis fases. A cada fase le asocia tareas de aseguramiento de la calidad [6]. La Fig. 2 relaciona esas fases con los objetivos específicos, y las subsecciones siguientes describen cómo se aplicó cada una.

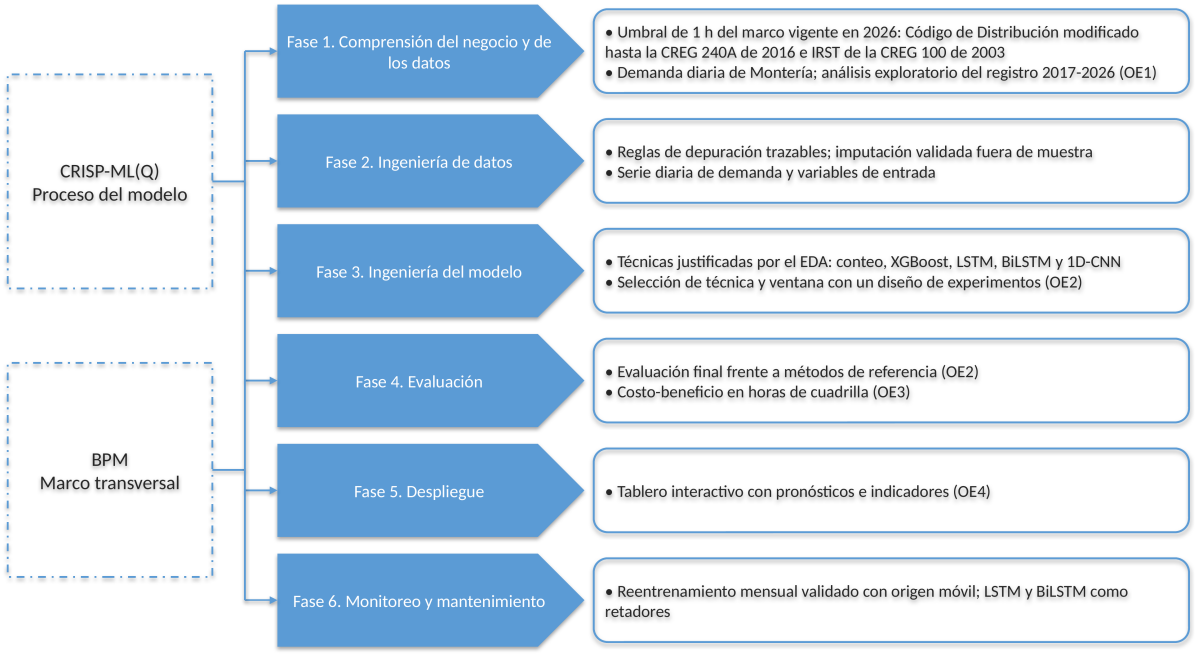


Figura 2. Fases de CRISP-ML(Q) aplicadas al proyecto, con la gestión de procesos de negocio (BPM) como marco conceptual transversal, y su relación con los objetivos específicos.

5.1. Marco conceptual transversal: gestión de procesos de negocio

Mientras CRISP-ML(Q) guía la construcción del modelo, la gestión de procesos de negocio (BPM, por sus siglas en inglés) aporta el marco para integrarlo a la operación. BPM entiende la mejora como un ciclo que identifica, analiza, rediseña, implementa y monitorea los procesos de una organización [31].

En este proyecto, BPM actúa de forma transversal sobre el proceso de atención de emergencias, que va desde la recepción de la solicitud hasta el cierre de la orden. El análisis del proceso actual se apoya en las marcas de tiempo del registro, que reflejan una asignación reactiva de cuadrillas. El rediseño consiste en anteponer una etapa de planificación, en la que la capacidad diaria se ajusta al pronóstico. Por último, el análisis costo-beneficio del OE3 mide el efecto de ese rediseño, y el tablero interactivo del OE4 cumple la función de monitoreo del ciclo. La implementación corresponde al despliegue diario con reajuste mensual. El proceso se caracterizó con los datos del registro y con lo indicado por el personal, sin un diagrama formal en notación BPMN.

5.2. Comprensión del negocio y de los datos

La primera fase definió el problema operativo y su indicador regulatorio, el IRST. A partir de ella se realizó el EDA del OE1, que comenzó con una auditoría de la calidad del registro. Después se examinaron la tendencia de la demanda, su estacionalidad semanal, mensual y horaria, las causales, los barrios, la dependencia temporal, la dispersión del conteo y los tiempos de respuesta. En todas las pruebas se usó un nivel de significancia de 0,05: un valor p menor indica que el resultado difícilmente se explica por azar. La estacionariedad se contrastó con dos pruebas de hipótesis opuestas [23]. La prueba de Dickey-Fuller aumentada (ADF) parte de que la serie tiene raíz unitaria, es decir, de que cada choque cambia su nivel de forma permanente. La de Kwiatkowski, Phillips, Schmidt y Shin (KPSS) parte de lo contrario: que la serie fluctúa alrededor de un nivel fijo. Su combinación indica si un promedio histórico fijo sirve para pronosticar o si hay que usar el nivel reciente. El efecto del calendario se evaluó con la prueba de Kruskal-Wallis, que compara grupos de días sin suponer una distribución normal, pues los conteos no la siguen [32]. La dependencia temporal se evaluó con la autocorrelación y la prueba de Ljung-Box [23]. Esta última indica si, en conjunto, las autocorrelaciones difieren de cero, es decir, si los días previos ayudan a pronosticar.

La relación entre las variables categóricas de la serie diaria se evaluó con la prueba chi-cuadrado de independencia. Esta prueba contrasta si la distribución de una variable cambia según las categorías de otra. La intensidad de la relación se midió con la V de Cramér, con corrección de sesgo, que va de 0 (independencia) a 1 (asociación perfecta). En los pares de variables binarias se usó además el coeficiente Phi, que indica también el sentido de la relación. Cuando las dos variables son ordinales, como el año y el nivel de demanda, se estimó la correlación policórica. Esta medida supone que cada variable ordinal agrupa en categorías una variable continua normal y estima la correlación entre ambas. Cada hallazgo del EDA se vinculó con una técnica candidata, de modo que la selección de técnicas partiera de los datos.

5.3. Ingeniería de datos

La Fig. 3 resume la preparación de los datos.

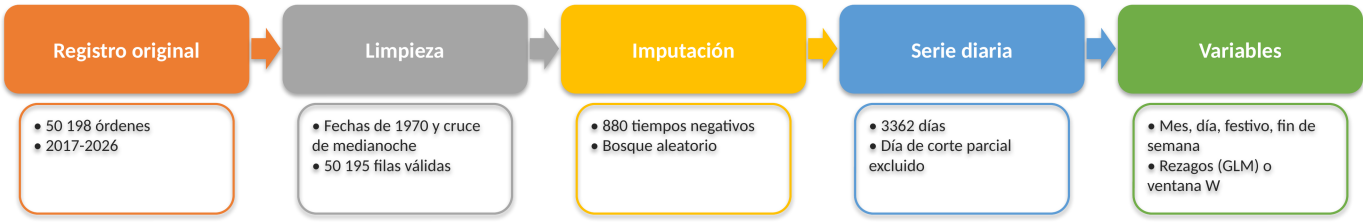


Figura 3. Flujo de preparación de los datos, desde el registro original hasta las variables de los modelos. Los rezagos de 1 y 7 días y la media móvil se usan en los modelos de conteo. XGBoost y las redes reciben la ventana de los W días anteriores.

El registro original contenía 50 198 órdenes y 32 columnas. De ellas se eliminaron 3 con fecha de 1970, producto de errores de carga, y se corrigió una orden que cruzaba la medianoche. Las 880 órdenes con tiempo de respuesta negativo se conservaron y su tiempo se imputó con un bosque aleatorio. Ese modelo se evaluó en las órdenes posteriores al 3 de octubre de 2024, que no se usaron para ajustarlo. En ellas obtuvo un error absoluto medio (MAE) de 1,06 h, frente a 1,14 h de la mediana por año y tipo de emergencia. Esta validación es independiente del pronóstico de tiempos de respuesta de la sección 6, que emplea otra partición y otra referencia. Los valores imputados no entran en el pronóstico de demanda, que cuenta órdenes, ni en el de tiempos, que usa solo órdenes con tiempo real. Tampoco entran en el tiempo tipo de atención, medido en 43 732 órdenes reales.

Con los datos depurados, la serie diaria se construyó contando las emergencias por fecha de registro y asignando cero a los días sin registros. Se usó la fecha de registro porque, para planificar cuadrillas, importa cuándo llega la carga al centro de control. Se excluyó el último día del extracto (18 de marzo de 2026), que termina a las 17:05 con 13 registros cuando un miércoles promedia 22. Así, la serie final abarca 3362 días, del 2 de enero de 2017 al 17 de marzo de 2026, y suma 50 182 emergencias.

El registro no contiene variables externas, como el clima o el número de usuarios conectados. Cada orden indica, en cambio, si la emergencia era controlada o no controlada. Las no controladas exigen atención urgente, dentro del límite de una hora. Las controladas admiten una atención programada: según el personal de Surtigas consultado en las visitas, su tiempo de respuesta máximo es de 15 días. Como variables de entrada se emplearon el mes y el día de la semana, en codificación cíclica, junto con los indicadores de festivo nacional y de fin de semana. Los modelos de conteo incorporan además los rezagos de 1 y 7 días y la media móvil de los 7 días previos, que excluye el día pronosticado. Todas las variables se escalaron con el mínimo y el máximo del bloque de entrenamiento.

5.4. Ingeniería del modelo

A partir del estado del arte se seleccionaron siete técnicas, cuatro de aprendizaje automático y tres modelos de conteo. XGBoost se configuró con un máximo de 500 árboles, una tasa de aprendizaje de 0,03, una profundidad máxima de 5 y un submuestreo de filas y columnas de 0,8. Las redes LSTM y BiLSTM tienen dos capas recurrentes de 64 y 32 unidades con abandono del 20 %. La 1D-CNN, en cambio, tiene dos capas convolucionales de 64 y 32 filtros. XGBoost minimiza el error cuadrático, aunque su parada temprana y la selección usan el MAE. Las tres redes minimizan el error absoluto con el optimizador Adam, lotes de 32 ejemplos y un máximo de 80 épocas. Su tasa de aprendizaje se reduce a la mitad tras cuatro épocas sin mejora. Las cuatro técnicas reciben como entrada una ventana de los W días anteriores, con $W \in \{10, 20, 30, 40, 50\}$. Estos hiperparámetros se fijaron antes del experimento y no se ajustaron, de modo que todas las técnicas recibieron el mismo trato. Ajustarlos con la validación habría consumido el bloque con el que se elige el modelo, y ajustarlos aparte habría requerido una validación anidada. La parada temprana, con paciencia de ocho épocas en las redes y de 30 rondas en XGBoost, definió el número efectivo de épocas y de árboles. Como el MAE de validación sirvió para elegir la técnica y la ventana, ese valor es algo optimista. Por eso, el desempeño se reporta con el conjunto de prueba, que se consultó una sola vez. El diseño factorial varió solo la técnica y la ventana, que son los factores de interés.

Los modelos de conteo son GLM Poisson, BN y ZINB con enlace logarítmico, estimados por máxima verosimilitud. Como punto de comparación se emplearon cuatro métodos de referencia. Dos repiten la demanda pasada: la del día anterior o la del mismo día de la semana anterior. Los otros dos la resumen con la mediana o la media móvil de 7 días. El modelo SARIMA no se incluyó porque su forma lineal limita la captura de interacciones entre el calendario y los rezagos. Ese papel estadístico lo cumplen los GLM, y el mismo día de la semana anterior es la referencia estacional ingenua.

Los supuestos de los GLM se verificaron con el bloque de entrenamiento. La equidispersión de la Poisson se contrastó con la razón entre el estadístico chi-cuadrado de Pearson y sus grados de libertad, que vale 1 si se cumple. También se aplicó la prueba de Cameron y Trivedi, una regresión auxiliar que estima si la varianza crece más rápido que la media. La necesidad del parámetro de dispersión de la BN se evaluó con una prueba de razón de verosimilitud. El exceso de ceros se evaluó con los ceros que espera cada familia y con la prueba de Vuong entre la ZINB y la BN. La independencia de las observaciones se contrastó con la prueba de Ljung-Box sobre los residuos de Pearson. La forma del enlace logarítmico se evaluó con la prueba de enlace de Pregibon, que agrega al modelo el cuadrado del predictor lineal. Por último, la multicolinealidad se midió con el factor de inflación de la varianza (VIF).

5.5. Evaluación

La Fig. 4 resume el protocolo de evaluación.

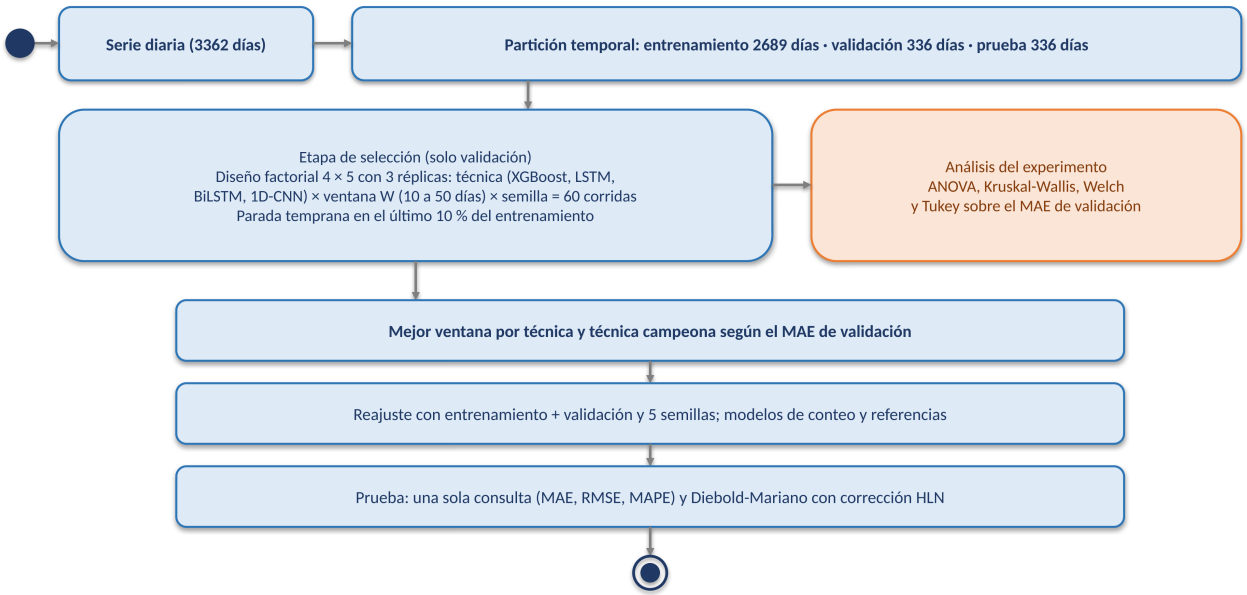


Figura 4. Protocolo experimental: partición temporal, diseño factorial sobre validación, reajuste con cinco semillas y prueba única.

La serie se dividió en orden cronológico. El 80 % se destinó a entrenamiento (2689 días, hasta el 13 de mayo de 2024). La validación recibió el 10 % (336 días, hasta el 14 de abril de 2025). El resto se reservó para prueba: 336 días, del 16 de abril de 2025 al 17 de marzo de 2026. El día intermedio quedó como frontera y no se usó como objetivo.

Cada modelo se ajustó con el bloque de entrenamiento, y la parada temprana (*early stopping*) de las redes y de XGBoost se aplicó sobre su último 10 %. Así, la validación no intervino en el ajuste.

La técnica y la ventana se eligieron con un diseño factorial completo 4×5 con tres réplicas [32]. El factor A es la técnica de aprendizaje automático, con cuatro niveles, y el factor B es la ventana W, con cinco niveles. Las réplicas son tres semillas aleatorias, para un total de 60 corridas, y la variable de respuesta es el MAE de validación. Los efectos se contrastaron con un análisis de varianza (ANOVA) de dos factores. Este análisis indica qué parte de la variación del error se debe a la técnica, a la ventana o a su interacción. Sus supuestos se verificaron con la prueba de Shapiro-Wilk, que contrasta la normalidad de los residuos, y con la de Levene, que contrasta la igualdad de sus varianzas. Como respaldo, el efecto de la técnica se contrastó también con dos pruebas que relajan esos supuestos. La de Kruskal-Wallis no requiere normalidad, y el ANOVA de Welch no requiere igualdad de varianzas [33]. Las técnicas se compararon por pares con la prueba de Tukey, que controla el error de hacer varias comparaciones a la vez. Los modelos de conteo, al ser deterministas, se compararon directamente por su MAE de validación. Como las réplicas son semillas sobre los mismos datos, la inferencia es condicional al bloque de validación. Indica qué técnica rinde mejor en ese periodo, considerando su variación aleatoria. La generalización se comprueba aparte, con la prueba única y el reajuste mensual.

Solo después de esta selección, la combinación ganadora de cada técnica se reajustó con entrenamiento y validación, usando cinco semillas, y el conjunto de prueba se consultó una única vez. Este orden evita el sesgo de selección que se produce al elegir con el conjunto de prueba [27]. Las diferencias de prueba entre XGBoost y los demás modelos se contrastaron con la prueba de Diebold-Mariano sobre la pérdida absoluta [27]. Esta prueba compara, día a día, los errores absolutos de dos modelos y determina si la diferencia media entre ellos puede deberse al azar. Se aplicó la corrección para muestras pequeñas de Harvey, Leybourne y Newbold (HLN), base de las variantes recientes de esta prueba [34]. Para cada técnica de aprendizaje automático se usó el promedio de las predicciones de sus cinco semillas.

El desempeño se midió con tres métricas: el MAE, la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE), definidas como

$$\mathrm{MAE} = \frac{1}{n}\sum_{t}|\hat{y}_t - y_t|, \quad \mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{t}(\hat{y}_t - y_t)^2}, \tag{3}$$

$$\mathrm{MAPE} = \frac{100}{n^{+}}\sum_{t:\, y_t>0}\frac{|\hat{y}_t - y_t|}{y_t}. \tag{4}$$

El MAPE se calcula sobre los n^{+} días con demanda positiva. En los GLM se calcularon además la NLL, el CRPS y

la cobertura del intervalo de predicción de 80 %. Para comprobar la estabilidad del modelo en producción, XGBoost y los GLM se reajustaron cada 30 días con toda la historia previa, en una validación con origen móvil [27]. Esa corrida de XGBoost usa 300 árboles, sin parada temprana y con una semilla, por lo que no replica exactamente la receta del tablero.

El pronóstico también se evaluó como clasificación en tres niveles de demanda, definidos con los terciles del bloque de entrenamiento. Para ello se calculó un costo ordinal $C_{ij} = |i - j|$ y una variante asimétrica que duplica el peso de la subestimación. Como complemento explicativo, se aprendió una RB con búsqueda voraz y puntaje BDeu sobre el mes, el día de la semana, el festivo y el nivel de demanda [15].

Por último, los tiempos de respuesta se pronosticaron por orden, con una partición por fecha (entrenamiento hasta el 30 de abril de 2024) y solo con órdenes de tiempo real. En este caso se compararon la mediana por tipo de emergencia, el bosque aleatorio, el *gradient boosting* de histogramas y XGBoost. Ambos pronósticos se evaluaron también por tipo de emergencia, porque solo las no controladas comprometen la seguridad y el límite de una hora. Para la demanda de no controladas se comparó un XGBoost entrenado con esa serie con el reparto del pronóstico total según la proporción histórica de cada tipo.

Para que los resultados se puedan reproducir, los experimentos usan semillas fijas y el cuaderno se ejecuta de punta a punta. Un verificador automático hace 83 comprobaciones sobre los modelos, y las cifras del artículo se generan desde esos resultados.

5.6. Análisis costo-beneficio

Para el OE3, el beneficio del pronóstico se midió primero en horas de cuadrilla y después en pesos colombianos ($). Esta subsección resume el método, y la sección 7 presenta sus cifras.

5.6.1. Horas en déficit y horas ociosas: Sea $\bar{h}$ el tiempo tipo de atención de una emergencia, desde la asignación hasta la finalización de la orden. Se estimó con la mediana de los tiempos registrados, que no se deja arrastrar por las órdenes atípicas. El análisis es diario porque la decisión que apoya, cuántas cuadrillas programar, también lo es. Si el día t se planifica para $\hat{y}_t$ emergencias y ocurren y_t, en un periodo de n días las horas en déficit y las horas ociosas son

$$\begin{aligned} D &= \bar{h} \textstyle\sum_{t=1}^{n} \max(0,\, y_t - \hat{y}_t), \\ O &= \bar{h} \textstyle\sum_{t=1}^{n} \max(0,\, \hat{y}_t - y_t), \end{aligned} \tag{5}$$

y el total de horas mal dimensionadas es

$$H = D + O = \bar{h} \sum_{t=1}^{n} |\hat{y}_t - y_t|. \tag{6}$$

Una hora en déficit obliga a esperar, a trasladar una cuadrilla o a pagar horas extra, y pone en riesgo el límite de una hora del IRST. Una hora ociosa es capacidad pagada sin emergencias. Como $\bar{h}$ multiplica toda la suma, la reducción porcentual de H entre dos formas de planificar no depende de su valor. La mediana afecta las horas absolutas y los pesos, no esa comparación. La planificación actual se representó con la media móvil de 7 días, porque resume la semana completa más reciente y no depende de un solo día. Esa referencia representa lo indicado por el personal en las visitas, pero no replica exactamente su práctica. Por eso, el error también se compara con las otras tres referencias simples. La propuesta usa el pronóstico del modelo campeón. Ambas se evaluaron en el año de prueba, y sus horas se anualizaron con el factor 365/336. Estas horas incluyen las emergencias controladas, que pueden esperar. Por ello, el déficit calculado es una cota superior de la atención que se debe dar el mismo día, cuya parte crítica son las no controladas. Se calcularon, además, los turnos equivalentes de 8 h y los días críticos, en que la demanda supera al pronóstico en más de 5 emergencias. El déficit que excede dos horas extra diarias por cuadrilla se consideró no cubrible, porque supera el límite legal [30], [35].

5.6.2. Escenario simulado de asignación por sector: El escenario reparte las cuadrillas entre los sectores de la ciudad con datos del registro y supuestos declarados. El barrio de cada orden se tomó del campo de observaciones o de la dirección, y su nombre se normalizó. Con la participación p_b de cada barrio en los 12 meses previos a la prueba, la probabilidad de que tenga al menos una emergencia el día t es

$$P_{b,t} = 1 - e^{-\hat{y}_t\, p_b}. \tag{7}$$

Los 60 barrios más frecuentes se buscaron en el servicio Nominatim de OpenStreetMap, que devuelve un punto aproximado y la comuna [36]. Se ubicaron 47, y cada comuna se tomó como un sector. La participación p_z de un sector es la suma de las de sus barrios ubicados. Las órdenes de prueba sin barrio ubicado se repartieron con esas participaciones, en una simulación de Monte Carlo de 300 repeticiones. Según el personal de Surtigas consultado en

las visitas a la sucursal, el campo «Persona ejecuta» registra al líder de la cuadrilla. Por ello, cada persona distinta de ese campo se contó como una cuadrilla, y la capacidad observada es la mediana de cuadrillas activas por tipo de día.

Esta distribución debe leerse con prudencia. El barrio solo es utilizable en el 51 % de las órdenes, y en el año de prueba únicamente el 28 % quedó asignado de forma directa a su sector. Por eso, los resultados por sector y el mapa de calor no representan toda la demanda. Son una imagen de lo que podría ocurrir si todas las órdenes estuvieran ubicadas y se distribuyeran como las identificadas.

Se evaluaron tres escenarios porque la decisión de la empresa tiene tres opciones. A es la línea base y representa seguir como hoy. Usa la capacidad observada y la reparte por igual entre sectores, porque las cuadrillas no se ubican según dónde ocurren las emergencias (sección 3.1). C es la opción que propone el proyecto y muestra cómo se usaría el modelo en la operación. El centro de control fija con el pronóstico la capacidad del día siguiente, $N_t = \lceil \hat{y}_t \, \bar{h}/8 \rceil$, y reparte las cuadrillas según la participación p_z de cada sector. D responde si conviene pagar un margen frente al error del pronóstico, y agrega a C una cuadrilla de reserva. Para no atribuir al pronóstico lo que aporta el reparto, se calculó además el reparto por probabilidad con la capacidad observada, que no usa el modelo. Ese cálculo solo separa ambos efectos y no es una opción propuesta. También se evaluaron capacidades fijas de 1 a 8 cuadrillas para ubicar el punto de equilibrio, donde el déficit iguala a las horas ociosas.

Las horas ociosas de un sector pueden cubrir el déficit de otro mediante traslados. Cada traslado recorre la distancia esperada entre sectores a 15 km/h, una velocidad de hora pico [37], más 2 min de semáforos [38]. Si M_t son las horas trasladadas el día t y r_t el tiempo de viaje por hora trasladada, el déficit y las horas ociosas del periodo son

$$\begin{aligned} D &= \textstyle\sum_t \big(\sum_z d_{t,z} - M_t \big), \\ O &= \textstyle\sum_t \big(\sum_z o_{t,z} - (1 + r_t)\, M_t \big). \end{aligned} \tag{8}$$

Ninguna norma fija el valor de una hora de retraso en la atención de emergencias. Por ello, ese valor se representó con un peso k, que indica cuántas veces cuenta una hora en déficit frente a una ociosa. Los escenarios se compararon con el costo ponderado $kD + O$ para $k = 1$, 2 y 3. Una cuadrilla adicional que evita ΔD horas en déficit y agrega ΔO ociosas conviene cuando k supera

$$k_{\text{mín}} = \frac{\Delta O}{\Delta D}. \tag{9}$$

5.6.3. Costos y evaluación financiera: El costo de una hora de cuadrilla es

$$c_h = \frac{P\, S}{H_m}, \tag{10}$$

donde $P = 4$ personas por cuadrilla, S es el salario mínimo legal mensual vigente (SMMLV) de 2026, de \$1.750.905, y $H_m = 210$ h, con la jornada de 42 horas semanales [39]. El costo anual de la capacidad de un escenario es

$$C = \frac{365}{336} \left(8\, c_h\, T + 1{,}25\, c_h\, D + c_{km}\, L \right), \tag{11}$$

donde T son los turnos de 8 h del año de prueba y L los kilómetros de traslados. Las horas en déficit, D, se cubren con horas extra, con un recargo del 25 % [30]. Ese es el recargo diurno, y el 86 % de las órdenes se registra entre las 8:00 y las 18:59. Como los recargos nocturno y dominical son mayores, el 25 % tiende a subvalorar la hora en déficit evitada. El costo por kilómetro, $c_{km} = \$975$, suma el combustible de una camioneta diésel en hora pico y su desgaste [40]–[42]. El cálculo excluye las prestaciones sociales, que no cambiarían el orden de los escenarios. Un costo de hora mayor elevaría el VPN de C y empeoraría el de D, de modo que el supuesto no favorece a C.

El flujo neto de cada año es la reducción del gasto de un escenario frente a la línea base, incluidos el mantenimiento mayor y la operación del sistema. La inversión inicial suma la creación del modelo y un mes de marcha blanca (sección 7.1). La proyección a cinco años supone que los salarios crecen 5 % al año, la meta de inflación del 3 % más un ajuste de dos puntos. La demanda crece 5 %, la tasa compuesta de la serie entre 2017 y 2025. En el año 3 se incluye un mantenimiento mayor de equipos y vehículos, equivalente a un mes de nómina. Los flujos se descontaron con una tasa mínima atractiva de rendimiento (TMAR) de $i = 15\,\%$. Parte de la tasa de 11,88 % en pesos constantes que la CREG fijó para el transporte de gas natural, ajustada con la inflación [43]. Con ella se calcularon el valor presente neto (VPN) y el valor anual equivalente (VAE):

$$\begin{aligned} \text{VPN} &= -I_0 + \textstyle\sum_{j=1}^{N} F_j\, (1 + i)^{-j}, \\ \text{VAE} &= \text{VPN}\, \frac{i}{1 - (1 + i)^{-N}}. \end{aligned} \tag{12}$$

Se calcularon, además, la tasa interna de retorno (TIR), la relación beneficio-costo (B/C) y el periodo de recuperación de la inversión (PRI). Un escenario es viable si su VPN es positivo, su TIR supera la TMAR y su B/C es mayor que 1.

5.6.4. Costo por incumplimiento y costo por confiabilidad: El déficit no cubrible corresponde a emergencias atendidas fuera de la hora, que incumplen el IRST. Su número anual se aproximó como

$$N_x^{nc} = \frac{365}{336}\,\frac{D_x^{nc}}{\bar{h}}. \tag{13}$$

La CREG no fija una compensación propia por incumplir el IRST [4]. Por ello, su costo se estimó con dos elementos normativos. El primero es la indemnización mínima al usuario, de un día de consumo por cada día de falla [44]. El segundo es el riesgo de una multa de la SSPD de hasta 2000 SMMLV [44]–[46]. Así, el costo anual por incumplimiento es

$$C_x^{inc} = c_{ind}\,u\,N_x^{nc} + p_x\,M_s, \qquad p_x = p_0\,\frac{D_x^{nc}}{D_A^{nc}}, \tag{14}$$

donde c_{ind} es la indemnización mínima por usuario, u el número de usuarios afectados por emergencia y M_s la multa máxima. p_0 es la probabilidad anual de recibirla en la línea base, que se evaluó entre 0 y 10 %. El costo por confiabilidad valora el gas no suministrado con el costo de racionamiento de la región Caribe [47], [48]:

$$C_x^{conf} = CR\,DP_h\,t_f\,u\,N_x^{nc}, \tag{15}$$

donde CR es el costo de racionamiento, DP_h la demanda horaria de un usuario y t_f el tiempo sin servicio por emergencia. Este costo es social y no entra en los flujos, pero acota el peso k. Con $t_f = 1$ h y $u = 1$, ese peso es

$$k = 1{,}25 + \frac{CR\,DP_h}{\bar{h}\,c_h}. \tag{16}$$

La tarifa y el consumo se tomaron de una factura residencial de Surtigas [49]. Por último, la probabilidad de equilibrio entre dos escenarios X e Y es el valor de p_0 con el que ambos tienen el mismo costo anual esperado:

$$p_0^{*} = \frac{\left(C_X + c_{ind}\,u\,N_X^{nc}\right) - \left(C_Y + c_{ind}\,u\,N_Y^{nc}\right)}{M_s\left(D_Y^{nc} - D_X^{nc}\right)/D_A^{nc}}, \tag{17}$$

Por encima de p_0^{*} conviene el escenario X, que deja menos horas no cubribles.

5.7. Despliegue y tablero de control

La Fig. 5 presenta el sistema propuesto para el OE4. Cada día, la ventana se actualiza con el dato real y el modelo pronostica el día siguiente sin reentrenarse; cada mes, el modelo se reajusta con toda la historia. El tablero de control reúne el pronóstico, la probabilidad de alta demanda y la explicación del nivel.

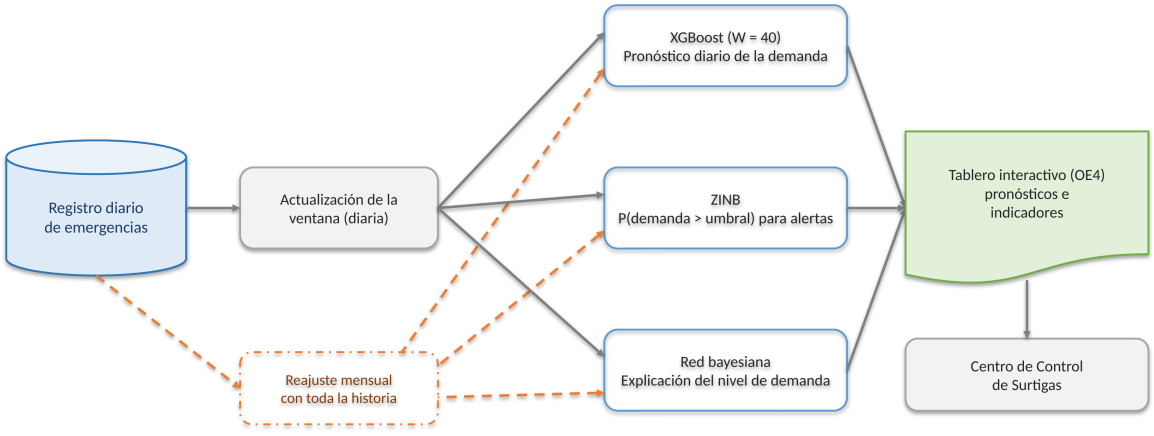


Figura 5. Sistema propuesto: actualización diaria, modelos de pronóstico, alerta y explicación, y tablero de control.

El tablero se diseñó por roles, porque cada usuario toma decisiones distintas. El rol operativo, que agrupa al centro de control y a los líderes de cuadrilla, planea el día siguiente. El rol administrativo, la jefatura, dimensiona la capacidad del mes y su costo. El rol técnico mantiene el modelo y vigila que siga siendo confiable. Cada rol ve solo lo que necesita.

El operativo no ve costos ni la salud del modelo; el administrativo ve además la capacidad y el costo, y el técnico ve todas las vistas.

Los indicadores clave de desempeño (KPI) se eligieron con tres criterios. Primero, cada KPI proviene de un resultado del proyecto, como el pronóstico, el intervalo de la ZINB, el nivel de la RB o las horas en déficit. Así, el tablero no muestra cifras sin respaldo en el análisis. Segundo, cada KPI apoya una decisión concreta del rol que lo ve. Tercero, todos se calculan con el registro de emergencias, sin datos que Surtigas no tenga hoy. Los umbrales de las alarmas y del semáforo se fijaron a partir de las cifras del proyecto, como el MAE de validación de 5,46. Por eso se declaran como una propuesta, pendiente de validar con Surtigas.

El tablero tiene dos capas. La primera es una interfaz de programación de aplicaciones (API) en Python, construida con FastAPI, que reutiliza los modelos del proyecto. Pronostica con el ensamble de cinco semillas de XGBoost, reajustado cada mes. La ZINB da el intervalo de 80 % y la probabilidad de 17 o más emergencias, y la RB explica el nivel esperado. La segunda capa es una aplicación web en React y TypeScript, construida con Vite. Los gráficos usan Recharts, y el mapa de calor por barrio usa Leaflet sobre OpenStreetMap [36]. En modo de reproducción, se elige una fecha del registro y el tablero muestra lo que habría visto el centro de control ese día, con el pronóstico del siguiente.

Hoy, el tablero se ejecuta en un computador local. Un archivo de arranque para Linux y otro para Windows levantan la API y la interfaz y abren el navegador. Para publicarlo en la red, la interfaz puede alojarse como un sitio estático y la API, en un contenedor con disco persistente. La API necesita ese disco porque guarda las respuestas de la evaluación. Además, no cabe en las funciones sin servidor de esos servicios, por el tamaño de TensorFlow, que usa el modelo retador. Antes de publicarlo, Surtigas debe autorizar el uso de su registro en un servidor externo.

El tablero se verificó en dos niveles. Un programa automático comprueba que reproduce las cifras del proyecto, y pruebas unitarias cubren cada vista de la API. La usabilidad se evaluará con la escala de usabilidad del sistema (SUS), un cuestionario de diez preguntas integrado en el propio tablero. Un puntaje de 68 es el valor de referencia habitual de esa escala [50].

6. Resultados y discusión

Esta sección responde la primera parte de la pregunta principal y sigue el orden de la metodología. Primero se describe la demanda con el EDA (OE1). Después se verifican los supuestos, se selecciona el modelo y se evalúa en el año de prueba (OE2). Al final se presenta el tablero de control que lleva estos resultados a la operación (OE4).

6.1. Análisis exploratorio

El EDA parte del registro de emergencias y busca describir la demanda diaria que se quiere pronosticar. Cada orden contiene la fecha y la hora de registro, el tipo de emergencia, la causal, el barrio y las marcas de tiempo de la atención. Al contar las órdenes por fecha se obtiene la variable objetivo: el número de emergencias por día, un conteo no negativo. Las variables predictoras son el día de la semana, el mes, el indicador de festivo y el de fin de semana, junto con los rezagos de la propia serie. El nivel de demanda agrupa la variable objetivo en tres categorías y es la variable que explica la RB. Las demás variables de la orden describen la demanda, pero no entran en los modelos de la serie diaria. El Cuadro 1 resume el tipo, la naturaleza y el papel de cada una.

Cuadro 1
Variables disponibles: tipo, naturaleza y papel en el proyecto

Variable	Tipo	Naturaleza	Papel
Emergencias por día	Cuantitativa discreta	Conteo de 0 a 97	Objetivo
Nivel de demanda	Cualitativa ordinal	Bajo, medio o alto	Objetivo de la RB
Día de la semana	Cualitativa nominal	Siete categorías, cíclica	Predictora
Mes	Cualitativa nominal	Doce categorías, cíclica	Predictora
Festivo	Cualitativa binaria	Sí o no	Predictora
Fin de semana	Cualitativa binaria	Sí o no	Predictora
Rezagos y media móvil	Cuantitativa	Demanda de días anteriores	Predictora derivada
Año	Cualitativa ordinal	2017 a 2026	Descriptiva
Tipo de emergencia	Cualitativa binaria	Controlada o no controlada	Descriptiva
Causal	Cualitativa nominal	Categorías del registro	Descriptiva
Barrio	Cualitativa nominal	Texto libre	Escenario por sector
Tiempo de respuesta	Cuantitativa continua	Horas, de la asignación a la llegada	Objetivo del modelo de tiempos

Fuente: elaboración propia.

En cuanto a la calidad del registro, el Cuadro 2 resume los problemas encontrados en el registro original y el tratamiento de cada uno. El registro no tiene órdenes duplicadas ni fechas futuras, y la fecha de registro, con la que se construye la serie, está completa. Los problemas se concentran en la secuencia de tiempos de atención y en campos administrativos que no se usan para pronosticar.

Cuadro 2
Problemas de calidad del registro original y tratamiento aplicado

Problema	Órdenes	Tratamiento
Fechas de 1970 (campo vacío)	3	Eliminadas
Llegada anterior a la asignación	880	Imputadas; excluidas de la evaluación
Control anterior a la llegada	21	Tiempo de control anulado
Cruce de medianoche	1	Corregida (+1 día)
Campo «Persona legaliza» vacío	44 400	Variable descartada
Contrato vacío	7070	Sin imputación
Barrio no extraíble de la dirección	24 462	Sin imputación

Fuente: elaboración propia.

La Fig. 6 muestra la serie diaria completa, con su tendencia y su nivel.

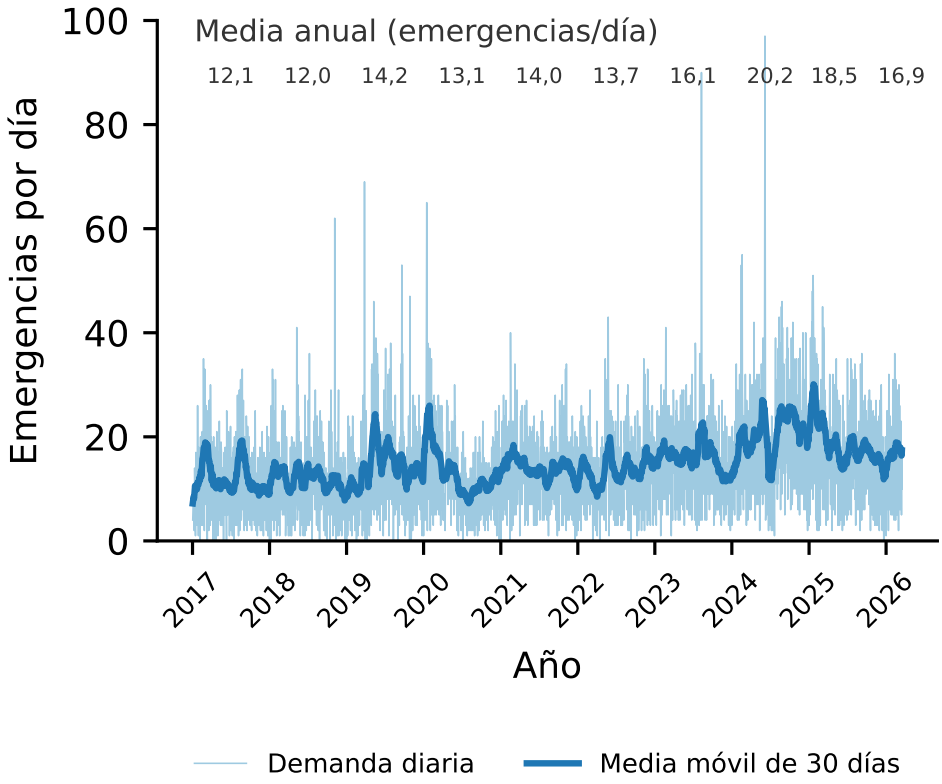


Figura 6. Demanda diaria de emergencias en Montería, enero de 2017 a marzo de 2026. La línea gruesa es la media móvil centrada de 30 días y los números superiores son la media anual (2026 llega hasta el 17 de marzo).

La demanda promedio fue de 15 emergencias por día, con una mediana de 14 y un máximo de 97 el 6 de junio de 2024, dentro del bloque de validación. El promedio anual pasó de 12 en 2017 a 20 en 2024 y bajó a 18 en 2025. La prueba ADF rechaza la raíz unitaria ($p < 0{,}001$): los choques de demanda son transitorios y la serie tiende a volver a su media. La prueba KPSS, en cambio, rechaza que esa media sea constante ($p \leq 0{,}01$). En conjunto, la serie vuelve a su media local, pero ese nivel cambia con el tiempo. Por eso, un promedio histórico fijo queda desactualizado, y todos los candidatos reciben como entrada los días recientes.

Más allá de la tendencia, el calendario es el rasgo más fuerte de la serie (Fig. 7).

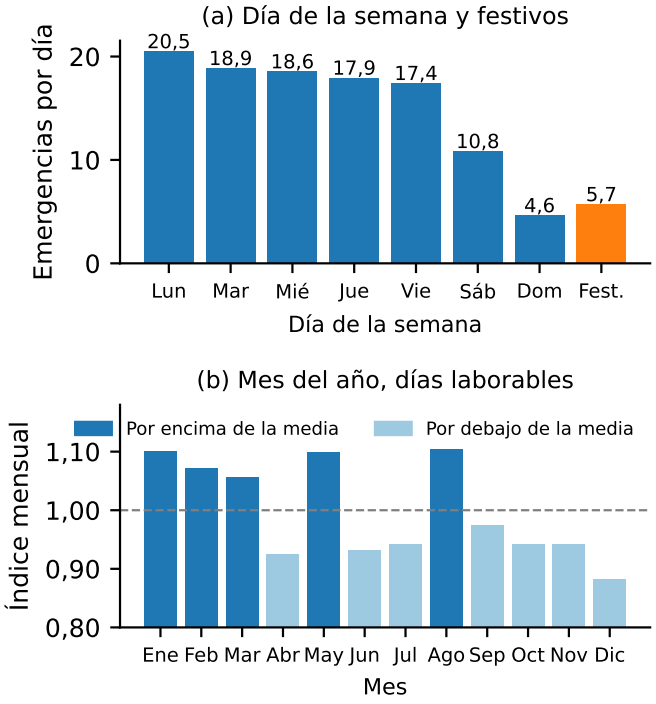


Figura 7. Perfiles de calendario. (a) Media de emergencias por día según el día de la semana (sin festivos) y en festivos. (b) Índice mensual de los días hábiles: demanda del día dividida por la media de los días hábiles de su año. El tono oscuro marca los meses por encima de esa media, y el eje vertical empieza en 0,80 para que se aprecien las diferencias.

De lunes a viernes llegan entre 17,4 y 20,5 emergencias por día, el sábado 10,8, el domingo 4,6 y los festivos 5,7. Un lunes recibe, en promedio, más de 4 veces la demanda de un domingo. La prueba de Kruskal-Wallis confirma que la diferencia entre días de la semana es significativa, es decir, que no se explica por la variación aleatoria ($H = 1395$, $p < 0{,}001$). El efecto del mes es menor, pero también significativo ($H = 72{,}2$, $p < 0{,}001$). Con la tendencia descontada, enero, mayo y agosto quedan cerca de 10 % por encima del promedio anual, y diciembre 12 % por debajo.

Con los terciles del entrenamiento se definieron tres niveles de demanda: bajo (10 o menos emergencias), medio (11 a 16) y alto (17 o más). Esos niveles abarcan el 33,9 %, el 27,5 % y el 38,6 % de los días de la serie. Según la Fig. 8, el 89,4 % de los festivos y el 75,4 % de los fines de semana tienen nivel bajo. En cambio, el 54,7 % de los días laborables tiene nivel alto. Los 35 días sin emergencias son 25 domingos y 10 festivos, por lo que corresponden a ceros de calendario y no a vacíos de captura.

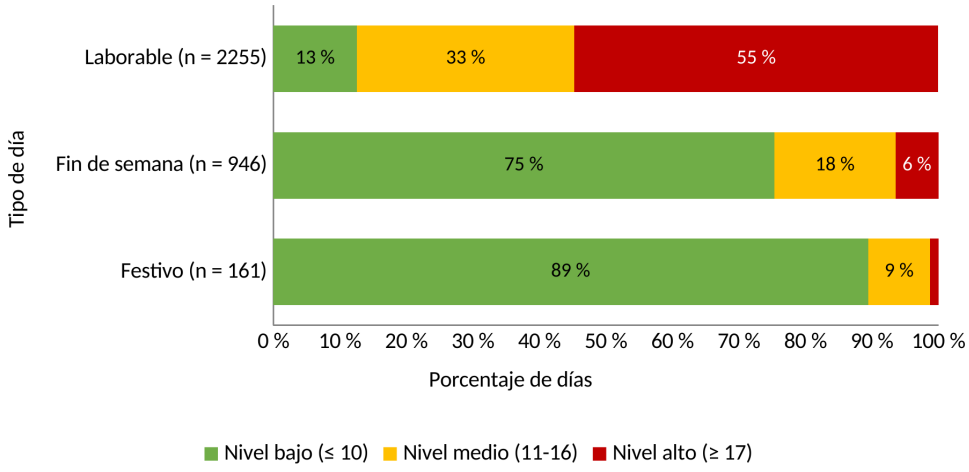


Figura 8. Nivel de demanda diaria según el tipo de día, con colores de semáforo: verde para el nivel bajo, ámbar para el medio y rojo para el alto. Los niveles se definieron con los terciles del bloque de entrenamiento.

Dentro del día, la operación es diurna. El 86 % de las órdenes se registra entre las 8:00 y las 18:59, con el pico a las 9:00. Los sábados, la actividad se corta hacia el mediodía. Este patrón no se modela, porque el pronóstico es de totales diarios, pero indica que la capacidad planeada debe concentrarse en el turno de la mañana. Por eso, el tablero del OE4 lo muestra como indicador (sección 6.8).

La asociación entre las variables de calendario y el nivel de demanda confirma ese patrón. El Cuadro 3 resume la asociación entre las variables categóricas de los 3362 días de la serie. El fin de semana es la variable más asociada con el nivel de demanda ($V = 0{,}57$). Le siguen el día de la semana ($V = 0{,}44$) y el festivo ($V = 0{,}26$), y en los tres casos la prueba chi-cuadrado rechaza la independencia ($p < 0{,}001$). El año tiene una asociación menor ($V = 0{,}18$), con una correlación policórica positiva ($\rho_{pc} = 0{,}26$). Este valor refleja la tendencia creciente de la demanda entre 2017 y 2024. El mes, en cambio, apenas se asocia con el nivel ($V = 0{,}08$). Su relación es significativa por el tamaño de la muestra, pero débil.

Cuadro 3
Asociación entre pares de variables categóricas de la serie diaria (prueba chi-cuadrado de independencia, 3362 días)

Par de variables	χ^2	gl	p	V	Otra
Fin de semana × nivel de demanda	1093,48	2	$< 0{,}001$	0,57	–
Día de la semana × nivel de demanda	1322,17	12	$< 0{,}001$	0,44	–
Festivo × nivel de demanda	234,90	2	$< 0{,}001$	0,26	–
Año × nivel de demanda	240,14	18	$< 0{,}001$	0,18	$\rho_{pc} = 0{,}26$
Mes × nivel de demanda	66,19	22	$< 0{,}001$	0,08	–
Día de la semana × festivo	311,88	6	$< 0{,}001$	0,30	–
Festivo × fin de semana	32,69	1	$< 0{,}001$	0,10	$\phi = -0{,}10$
Mes × festivo	41,34	11	$< 0{,}001$	0,09	–
Mes × año	233,09	99	$< 0{,}001$	0,07	–

V: V de Cramér con corrección de sesgo; ϕ: coeficiente Phi; ρ_{pc}: correlación policórica; –: el coeficiente no aplica al par (Phi exige dos variables binarias y la policórica, dos ordinales). Los pares no listados son independientes ($p > 0{,}05$).
Fuente: elaboración propia.

La Fig. 9 muestra la matriz completa. Entre las predictoras, el día de la semana y el fin de semana tienen una relación estructural, porque la segunda se deriva de la primera. El festivo se asocia con el día de la semana ($V = 0{,}30$), ya que buena parte de los festivos colombianos se trasladan al lunes. Su coeficiente Phi con el fin de semana es negativo ($\phi = -0{,}10$), porque un festivo rara vez cae en sábado o domingo. El mes y el año son independientes del día de la semana, como corresponde a un calendario. En conjunto, la información del calendario se concentra en el tipo de día, y el mes aporta poco por sí solo. Por eso los modelos combinan el tipo de día con los rezagos, que recogen el nivel reciente de la demanda.

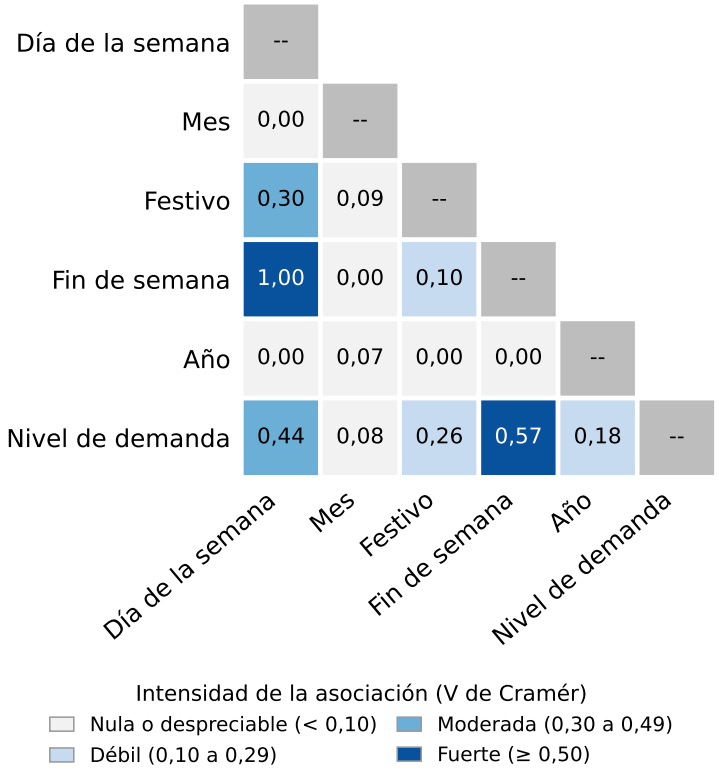


Figura 9. V de Cramér entre las variables categóricas de la serie diaria (3362 días). Un valor de 0 indica independencia y uno de 1, asociación perfecta. La diagonal (–) cruza cada variable consigo misma, y la relación entre el día de la semana y el fin de semana es estructural.

El 58 % de las órdenes corresponde a emergencias controladas y el 42 % a no controladas. Las diez causales más frecuentes concentran el 96 % de los casos. La composición por causal también cambió en el tiempo (Fig. 10). El escape en centro de medición pasó del 27 % de las emergencias en 2017 al 45 % en 2024. El robo de medidor, por su parte, pasó del 2 % en 2017 al 12 % en 2023. Estos cambios sugieren que parte del crecimiento de la demanda responde a causas específicas que podrían atenderse con acciones preventivas. Por eso, el tablero vigila la tendencia de las causas (sección 6.8).

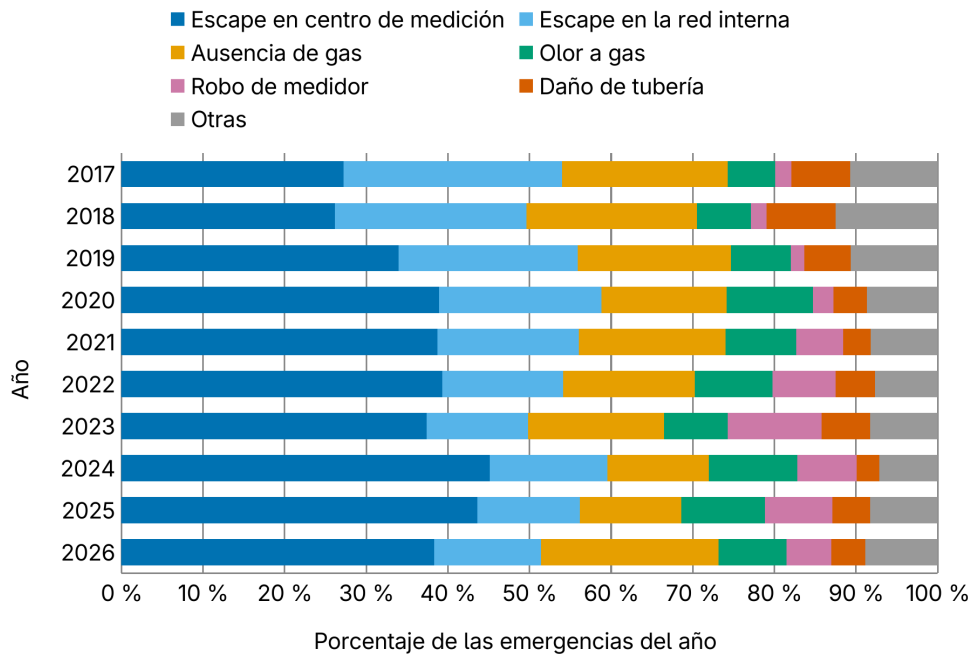


Figura 10. Composición anual de las emergencias según la causal registrada (2026 llega hasta el 17 de marzo).

En la dimensión geoespacial, el campo de barrio es texto libre. Se pudo extraer un nombre de barrio en el 51 % de las órdenes (Cuadro 2), y en el 51 % ese nombre fue utilizable. Entre las órdenes con nombre utilizable, La Granja (546), La Castellana (416) y Cantaclaro (401) concentran el mayor número de emergencias (Fig. 11). Con la mitad de las órdenes sin ubicación, el pronóstico se hizo para la ciudad completa. La sección 7.2.2 explora, como escenario simulado, cómo usar la distribución por barrio para asignar cuadrillas por sector.

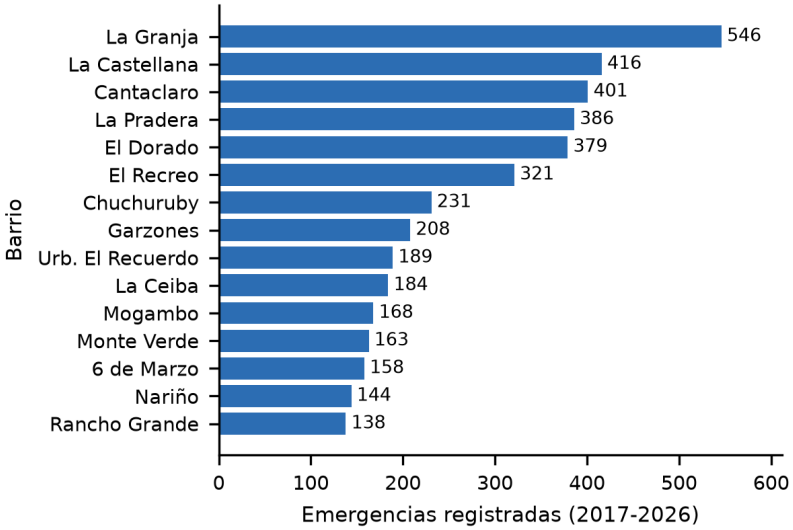


Figura 11. Quince barrios con más emergencias registradas entre 2017 y 2026, entre las órdenes con barrio identificable.

En cuanto a la dependencia temporal, la Fig. 12 muestra la autocorrelación de la serie desde 2018, para excluir el arranque del sistema.

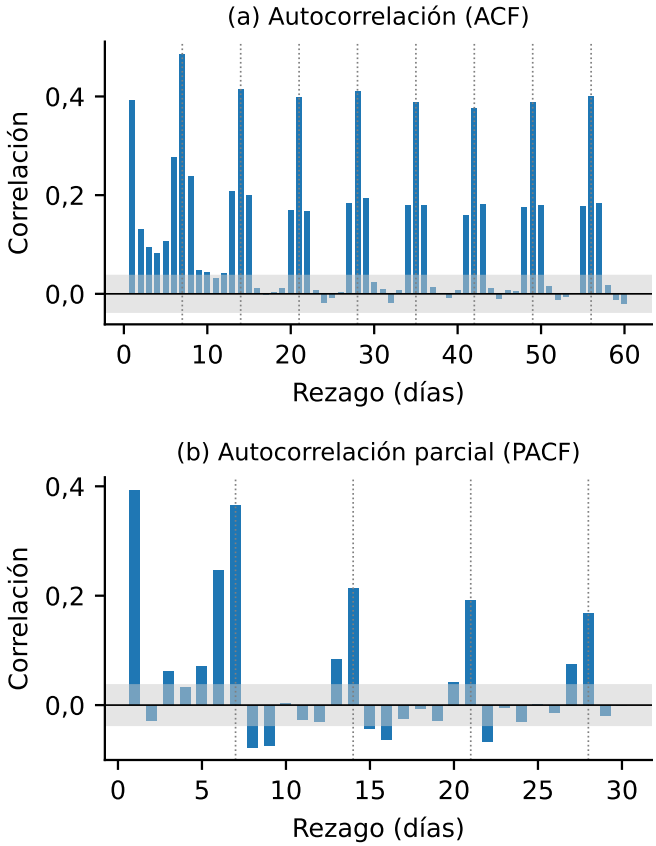


Figura 12. Autocorrelación (a) y autocorrelación parcial (b) de la demanda diaria, 2018–2026. La banda sombreada es el intervalo de 95 % bajo ruido blanco, y las líneas punteadas marcan múltiplos de siete días.

La correlación con el día anterior es de 0,39 y con el mismo día de la semana anterior de 0,49. En los múltiplos de siete días entre 14 y 56 se mantiene entre 0,38 y 0,41, mientras que en los demás rezagos es cercana a cero. La autocorrelación parcial, que aísla el efecto de cada rezago descontando el de los intermedios, tiene picos en los rezagos 1, 7, 14, 21 y 28. Además, la prueba de Ljung-Box rechaza que la serie sea ruido blanco, es decir, una secuencia sin memoria en la que el pasado no ayuda a pronosticar ($Q_{28} = 3758$, $p < 0{,}001$). Lo ocurrido en las cuatro a ocho semanas anteriores informa, por tanto, sobre el día que se pronostica. Este resultado fijó el rango de ventanas del diseño experimental, entre 10 y 50 días.

Desde el punto de vista estadístico, la demanda diaria tiene media de 15 y una razón varianza/media de 5,5, lejos de la equidispersión de la Poisson. Buena parte de esa varianza, sin embargo, viene de mezclar días hábiles con domingos y años de baja demanda con años de alta. Para separar ambos efectos, los días se agruparon por año, mes y día de la semana. Dentro de los grupos, la mediana de la razón varianza/media es 1,33, y en el 63 % de ellos la varianza supera a la media. La relación se ajusta a una BN con $r \approx 10$. Una vez descontado el calendario, queda entonces una sobredispersión moderada pero real.

El Cuadro 4 resume el ajuste de las tres familias sobre la serie completa. La Poisson espera cero días sin emergencias, la BN espera 15,6 y la ZINB reproduce los 35 observados con el menor criterio de información de Akaike (AIC). El AIC premia el buen ajuste y penaliza el número de parámetros, de modo que un valor menor indica un mejor equilibrio entre ambos. Este ajuste es descriptivo. Repetido solo con el bloque de entrenamiento, conserva el mismo orden (AIC de 25 027, 18 654 y 18 630). Por lo tanto, la elección de familia no depende del conjunto de prueba.

Cuadro 4
Ajuste por máxima verosimilitud de las familias de conteo ($n = 3362$ días). ✓: familia con mejor ajuste (menor criterio de información de Akaike, AIC)

Familia	μ	r	ψ	Ceros esperados	LL	AIC
Poisson	14,93	–	–	0	−16 509,17	33 020,35
BN	14,93	3,01	–	15,55	−11 919,30	23 842,61
ZINB ✓	15,03	3,19	0,01	35	−11 908,52	23 823,05

Fuente: elaboración propia.

El parámetro r del Cuadro 4 (≈ 3) es menor que el obtenido al agrupar por calendario (≈ 10). La razón es que el ajuste marginal absorbe como dispersión la variación entre días hábiles, fines de semana y años.

La Fig. 13 complementa el cuadro. El histograma muestra dos modas, una de fines de semana y festivos y otra de días laborables. Una distribución marginal no reproduce esa forma, lo que justifica incluir el calendario en los modelos.

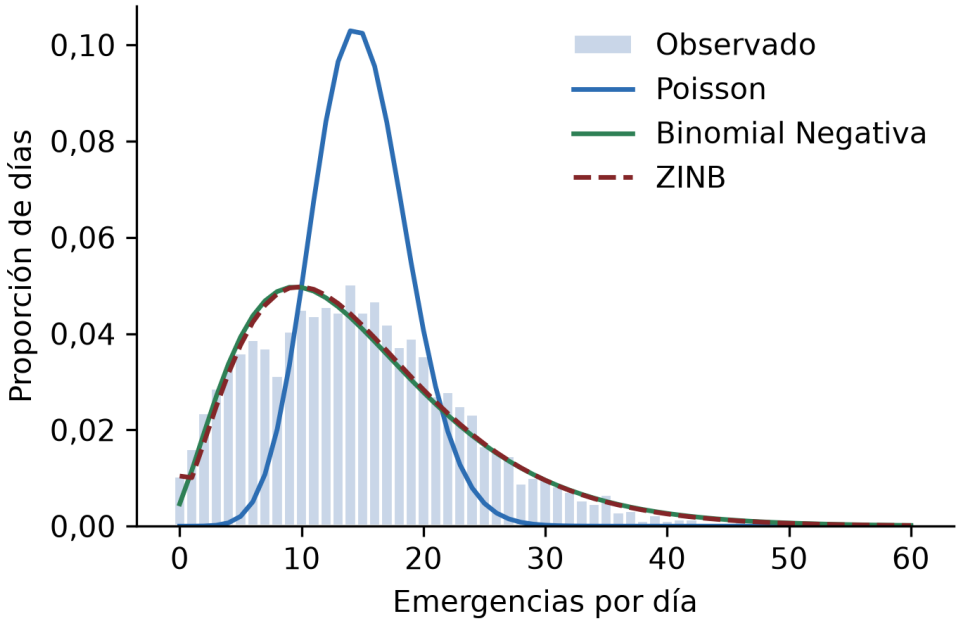


Figura 13. Histograma de la demanda diaria y distribuciones de Poisson, BN y ZINB ajustadas por máxima verosimilitud.

Por su parte, el tiempo de respuesta, desde la asignación de la cuadrilla hasta su llegada, tiene una mediana de 43 min y un percentil 95 de 7 h. La Fig. 14 muestra que esa cola resulta de mezclar dos poblaciones. Las emergencias no controladas se atienden con una mediana de 29 min y las controladas con una de 126 min. Medido desde el registro de la orden, el 99 % de las no controladas tuvo llegada en menos de una hora, frente al 9 % de las controladas. La correlación de Spearman entre la carga del día y la mediana del tiempo de respuesta es débil ($\rho_s = 0{,}06$, en una escala de -1 a 1). Esto sugiere que el tipo de emergencia, más que la congestión, determina la duración.

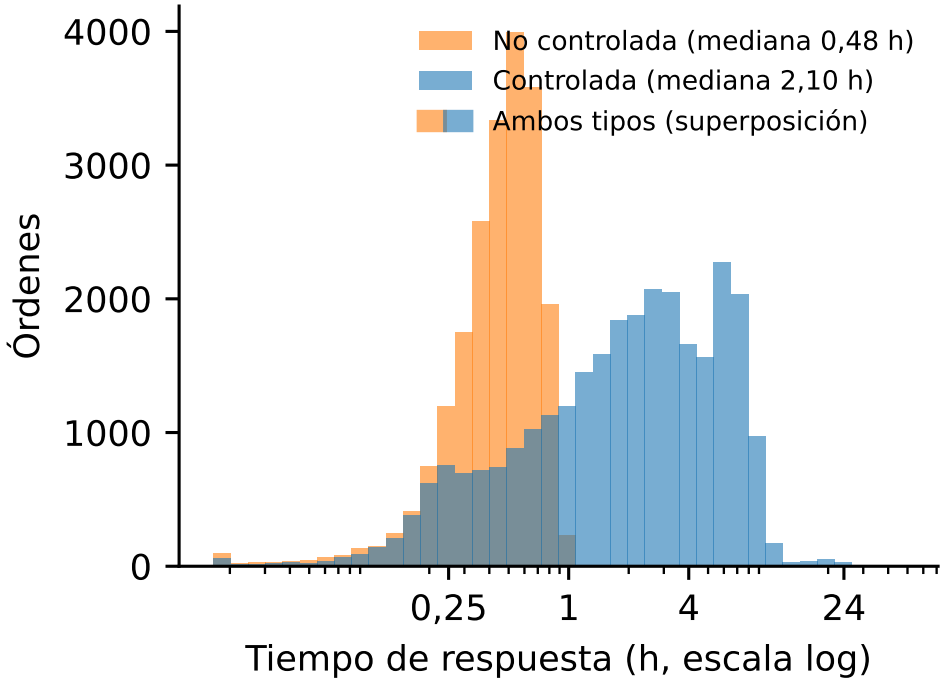


Figura 14. Distribución del tiempo de respuesta (asignación a llegada) según el tipo de emergencia, en escala logarítmica.

Por último, el Cuadro 5 conecta cada hallazgo del EDA con la técnica que se incluyó para aprovecharlo y con su respaldo en la literatura.

Cuadro 5
Relación entre los hallazgos del EDA y las técnicas evaluadas

Hallazgo del EDA	Implicación para el modelo	Técnica	Respaldo
Conteo con sobredispersión moderada ($r \approx 10$) y ceros en domingos y festivos (Cuadro 4)	El modelo debe producir una distribución de conteo además del valor esperado	Poisson, BN y ZINB	[7], [8]
El efecto del día depende del calendario y del nivel reciente (Fig. 7)	Hay que capturar interacciones no lineales entre calendario y rezagos	XGBoost con ventana de rezagos y calendario	[10], [24]
Autocorrelación significativa hasta ocho semanas (Fig. 12)	Conviene que el modelo lea una secuencia larga de días	LSTM y BiLSTM	[11], [13]
Patrón semanal repetido con forma estable (Figs. 7 y 12)	Sirve un detector de patrones locales dentro de la ventana	1D-CNN	[14]
Fuerte persistencia de un día a otro y de una semana a otra	Un modelo útil debe superar la repetición del pasado	Métodos de referencia	[23]

Fuente: elaboración propia.

6.2. Supuestos de los modelos de conteo

Antes de comparar las técnicas se verificaron los supuestos de los GLM (Cuadro 6). Se usaron 2682 días del bloque de entrenamiento: sus 2689 días menos los 7 primeros, que no tienen los rezagos que usan los modelos. La equidispersión de la Poisson no se cumple. El estadístico de Pearson es 3 veces sus grados de libertad, y la prueba de Cameron y Trivedi estima una dispersión positiva ($\alpha = 0{,}10$, $t = 12{,}49$, $p < 0{,}001$). La prueba de razón de verosimilitud confirma que la BN mejora el ajuste de la Poisson ($LR = 1432{,}35$, $p < 0{,}001$). Por lo tanto, la Poisson no describe bien la distribución de la demanda, aunque su pronóstico puntual sea parecido al de las otras familias.

Cuadro 6
Verificación de los supuestos de los modelos de conteo en el bloque de entrenamiento (2682 días)

Supuesto	Prueba	Resultado	Conclusión
Equidispersión	χ^2 de Pearson/gl; Cameron-Trivedi	2,57; $t = 12{,}49$, $p < 0{,}001$	No se cumple: hay sobredispersión
Parámetro de dispersión nulo	Razón de verosimilitud, Poisson frente a BN	$LR = 1432{,}35$, $p < 0{,}001$	La BN es preferible
Ceros explicados por el modelo	Ceros observados frente a esperados; Vuong, ZINB frente a BN	34 frente a 2,81, 8,25 y 33,50; $z = 0{,}86$, $p = 0{,}391$	La ZINB reproduce los ceros, sin diferencia significativa con la BN
Independencia de los residuos	Ljung-Box sobre los residuos de Pearson de la BN	$Q_7 = 99{,}02$, $Q_{28} = 550{,}31$, $p < 0{,}001$	No se cumple: queda dependencia semanal
Enlace logarítmico adecuado	Prueba de enlace de Pregibon	$\hat{\eta}^2$: −0,13, $p < 0{,}001$	No se cumple del todo: hay no linealidad
Ausencia de multicolinealidad	Factor de inflación de la varianza (VIF)	VIF máximo 2,04	Se cumple

Fuente: elaboración propia.

En entrenamiento hubo 34 días sin emergencias. La Poisson espera 2,81 y la BN 8,25, mientras que la ZINB reproduce la cifra observada (33,50). Sin embargo, la prueba de Vuong no distingue la ZINB de la BN ($z = 0{,}86$, $p = 0{,}391$). En este bloque, su probabilidad media de inflación es de 0,01, de modo que la mejora afecta a pocos días del año.

Dos supuestos no se cumplen en la BN. Sus residuos conservan dependencia semanal ($Q_7 = 99{,}02$ y $Q_{28} = 550{,}31$, $p < 0{,}001$), aunque su autocorrelación con el día anterior es casi nula (-0,02). La prueba de enlace indica, además, que el efecto de las covariables no es del todo lineal en la escala logarítmica ($p < 0{,}001$). La multicolinealidad, en cambio, no es un problema, con un VIF máximo de 2. En consecuencia, los GLM describen la dispersión y los ceros, pero no capturan toda la estructura semanal ni las relaciones no lineales. Esa limitación respalda la inclusión de XGBoost y de las redes, que leen la ventana completa de días anteriores.

6.3. Diseño de experimentos y selección del modelo

Verificados los supuestos, el diseño factorial comparó las cuatro técnicas de aprendizaje automático en el bloque de validación. El Cuadro 7 presenta su ANOVA. La técnica explica el 59 % de la variación del MAE de validación ($F = 26{,}53$, $p < 0{,}001$). La ventana no tiene un efecto significativo ($p = 0{,}581$), y tampoco su interacción con la técnica ($p = 0{,}419$). Los residuos no cumplen del todo los supuestos del ANOVA: la prueba de Shapiro-Wilk rechaza la normalidad ($p = 0{,}015$) y la de Levene rechaza la igualdad de varianzas ($p = 0{,}023$). Por ello, el efecto de la técnica se confirmó con dos pruebas que no dependen de esos supuestos: Kruskal-Wallis ($H = 39{,}6$, $p < 0{,}001$) y el ANOVA de Welch ($F = 58{,}7$, $p < 0{,}001$). Ambas confirman que la técnica influye en el error.

Cuadro 7
ANOVA del diseño factorial 4 × 5 con tres réplicas (respuesta: MAE de validación)

Fuente	SC	gl	F	p	η^2
Técnica (A)	19,06	3	26,53	< 0,001	0,59
Ventana W (B)	0,69	4	0,72	0,581	0,02
Interacción A×B	3,04	12	1,06	0,419	0,09
Error	9,58	40			0,30

Fuente: elaboración propia.

La Fig. 15 muestra el resultado de cada combinación. XGBoost obtuvo el menor MAE de validación en todas las ventanas y con la menor variación entre semillas. Entre semillas, la desviación estándar de su MAE de validación no superó 0,11, mientras que en las redes llegó a 0,62 (LSTM), 1,14 (BiLSTM) y 0,72 (1D-CNN). Entre ventanas, su MAE medio varió 0,33, frente a 0,42 a 1,08 en las redes. Según la prueba de Tukey, XGBoost (5,46 con $W = 40$) es significativamente mejor que las otras tres técnicas ($p \leq 0{,}002$). Le sigue BiLSTM (5,89 con $W = 20$), que supera a la 1D-CNN ($p < 0{,}001$) pero no se distingue de la LSTM ($p = 0{,}130$). Los GLM quedaron prácticamente empatados, con un MAE de validación entre 6,21 (Poisson) y 6,28 (BN), lejos del de XGBoost. Por lo tanto, el protocolo selecciona a XGBoost con $W = 40$ como modelo campeón. Como la ventana no tuvo efecto significativo, $W = 40$ es solo la de menor MAE medio de XGBoost, y una ventana menor sería igualmente defendible.

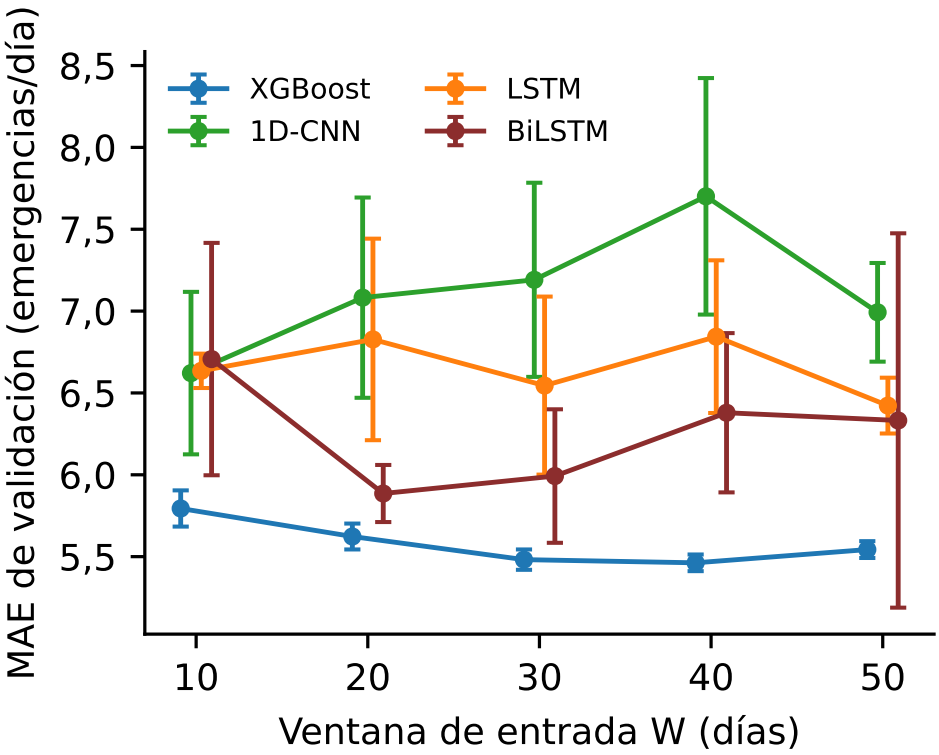


Figura 15. MAE de validación por técnica y ventana de entrada. Cada punto es la media de tres semillas, y las barras indican una desviación estándar.

Después del experimento se hizo un análisis de sensibilidad, solo con la validación, para comprobar si esa selección dependía de los hiperparámetros fijados. Entre 72 configuraciones de XGBoost, la usada quedó segunda, a 0,004 de la mejor. En 27 variaciones de las redes, ninguna bajó de 5,87, frente a 5,46 de XGBoost. Las redes se variaron de a un factor, de modo que esto no descarta una configuración mejor. Ese análisis no cambió ningún modelo ni cifra.

6.4. Desempeño en el conjunto de prueba

Elegido el campeón con la validación, el conjunto de prueba se consultó una sola vez. El Cuadro 8 reúne los errores de entrenamiento, validación y prueba. En prueba, XGBoost tuvo un MAE de 4,22, 34 % menos que el mejor método de referencia, que repite la demanda del mismo día de la semana anterior (6,40). Las cuatro técnicas de aprendizaje automático quedaron entre 4,14 y 4,24, y los GLM entre 4,57 y 4,61. Con reajuste mensual, el MAE de XGBoost fue de 4,31, lo que sugiere que el desempeño se conserva con reajuste periódico.

Cuadro 8

Error de los modelos en entrenamiento, validación y prueba (emergencias por día); NLL y CRPS solo aplican a los GLM. El asterisco marca el modelo campeón; la validación de las técnicas de aprendizaje automático es la media de tres semillas del diseño factorial

		Entrenamiento	Validación	Prueba (336 días)				
Modelo	W	MAE	MAE	MAE	RMSE	MAPE (%)	NLL	CRPS
Aprendizaje automático (media ± d.e. de 5 semillas)								
XGBoost*	40	3,52 ± 0,05	5,46	4,22 ± 0,03	5,59	35,44	–	–
BiLSTM	20	4,19 ± 0,06	5,89	4,17 ± 0,07	5,65	30,85	–	–
LSTM	50	4,34 ± 0,05	6,42	4,14 ± 0,06	5,57	30,83	–	–
1D-CNN	10	4,25 ± 0,27	6,62	4,24 ± 0,07	5,68	32,49	–	–
Modelos de conteo (GLM)								
ZINB	–	4,64	6,22	4,59	6,07	39,68	3,21	3,40
BN	–	4,67	6,28	4,61	6,10	39,74	3,22	3,42
Poisson	–	4,63	6,21	4,57	6,03	39,84	3,43	3,40
Métodos de referencia								
Mismo día, semana anterior	–	6,34	8,25	6,40	8,49	55,42	–	–
Media de 7 días	–	6,40	8,47	6,76	8,21	82,28	–	–
Mediana de 7 días	–	6,61	8,65	7,02	8,58	87,71	–	–
Día anterior	–	7,36	9,82	8,29	10,54	76,61	–	–

Fuente: elaboración propia.

La Fig. 16 compara entrenamiento y prueba por modelo. XGBoost pasa de 3,52 en entrenamiento a 4,22 en prueba, una brecha que indica un ajuste más estrecho a la historia que el de las demás técnicas. En las redes y en los GLM, en cambio, ambos errores son parecidos. La parada temprana limita ese ajuste, y el error de prueba de XGBoost sigue siendo menor que el de los GLM y las referencias.

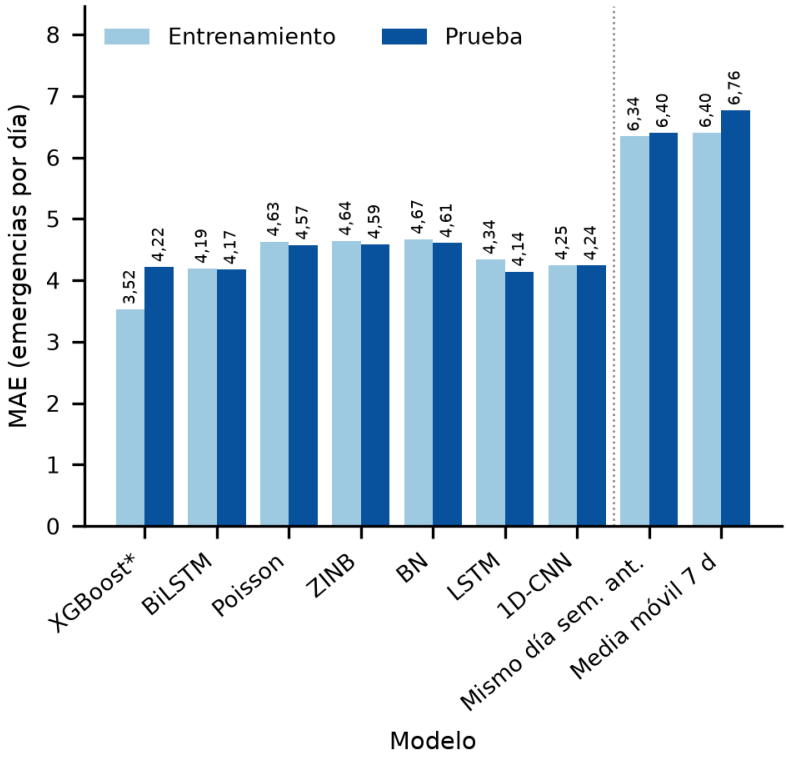


Figura 16. MAE en entrenamiento y en prueba por modelo. Los modelos se ordenan de izquierda a derecha según su MAE de validación, que se reporta en el Cuadro 8. A la derecha de la línea punteada están los dos mejores métodos de referencia (los cuatro aparecen en el Cuadro 8), y el asterisco marca el modelo campeón.

El Cuadro 9 contrasta XGBoost con cada modelo.

Cuadro 9
Prueba de Diebold-Mariano (DM) con corrección HLN entre XGBoost y los demás modelos (pérdida absoluta en prueba). Un ΔMAE positivo indica que XGBoost tiene mayor error

XGBoost frente a	ΔMAE	DM (HLN)	p
BiLSTM	0,07	0,77	0,440
LSTM	0,12	1,37	0,170
1D-CNN	0,07	0,80	0,423
ZINB	−0,38	−3,13	0,002
BN	−0,40	−3,23	0,001
Poisson	−0,37	−3,10	0,002
Mismo día, semana anterior	−2,19	−7,95	$< 0{,}001$
Media de 7 días	−2,56	−10,45	$< 0{,}001$
Mediana de 7 días	−2,81	−10,44	$< 0{,}001$
Día anterior	−4,09	−11,87	$< 0{,}001$

Las diferencias usan el promedio de las predicciones de las cinco semillas (MAE de XGBoost 4,20; BiLSTM 4,14; LSTM 4,09; 1D-CNN 4,13), por lo que no coinciden con la resta de las medias del Cuadro 8.
Fuente: elaboración propia.

XGBoost es significativamente mejor que los tres GLM ($p \leq 0{,}002$) y que todas las referencias ($p < 0{,}001$). Frente a las redes, en cambio, las diferencias no son significativas. Estas diez comparaciones no se corrigieron por multiplicidad. Con Bonferroni, el umbral sería de 0,005, y las diferencias frente a los GLM y las referencias seguirían siendo significativas. La LSTM obtuvo el menor MAE de prueba (4,14). Sin embargo, la prueba de Diebold-Mariano no distingue a XGBoost de la LSTM ($p = 0{,}170$), de la BiLSTM ($p = 0{,}440$) ni de la 1D-CNN ($p = 0{,}423$). Elegir la LSTM por ese resultado reintroduciría además el sesgo que el protocolo evita [27]. Su desviación entre semillas en prueba fue, además, de 0,06, el doble que la de XGBoost (0,03). Así, XGBoost está entre los mejores en prueba y es el más estable, lo que reduce el riesgo de que un reajuste mensual cambie su desempeño. Ese resultado coincide con el buen desempeño del *boosting* en la demanda de emergencias médicas [21].

El modelo pronostica la demanda total, pero la atención urgente depende de las no controladas, que promediaron 7 emergencias diarias en prueba. El pronóstico de XGBoost, multiplicado por la proporción de no controladas en entrenamiento y validación (42 %), obtuvo un MAE de 2,57 (Cuadro 10). Un XGBoost entrenado solo con esa serie obtuvo 2,65, sin diferencia significativa (Diebold-Mariano, $p = 0{,}067$). Ambos superan a la mejor referencia ingenua, la media de los últimos siete días (3,35). En las controladas, los dos enfoques empatan. Basta, entonces, un solo modelo de demanda total, cuyo pronóstico se reparte por tipo sin perder precisión. El tablero calcula esa proporción con el registro disponible. Si el monitoreo mostrara que cambia, el modelo por tipo podría reemplazar el reparto.

Cuadro 10
MAE de prueba de la demanda diaria por tipo de emergencia (336 días)

Método	Controladas	No controladas
Pronóstico total × proporción histórica	**2,74**	**2,57**
XGBoost entrenado por tipo	**2,74**	2,65
Media de los últimos 7 días	4,25	3,35
Mismo día de la semana anterior	4,13	3,77
Media diaria observada	9,42	7,24

Fuente: elaboración propia.

Una explicación probable de que la ventaja de XGBoost en validación no se trasladara a la prueba es la diferencia entre los periodos. El bloque de validación, de mayo de 2024 a abril de 2025, fue el más alto y variable de la serie. Tuvo una media de 22 emergencias por día, una desviación estándar de 11,6 y el pico de 97. El de prueba volvió a una media de 17, con desviación de 8,1. En el periodo agitado XGBoost se distinguió de las redes, y en el estable las cuatro técnicas rindieron igual. La Fig. 17 lo ilustra con el trimestre de enero a marzo de 2026, el más parecido al año de prueba completo. En él, XGBoost tuvo un error de 4,25 y BiLSTM de 4,16, frente a 4,20 y 4,14 en el año completo. La cobertura del intervalo de la ZINB fue del 86 %, frente al 85 % en el año. En ese trimestre, los pronósticos de ambas técnicas casi se superponen y siguen el ciclo semanal observado: caen cada domingo y se recuperan el lunes. Seleccionar en el periodo más difícil puede favorecer a una técnica robusta, aunque varios orígenes temporales darían una selección más sólida.

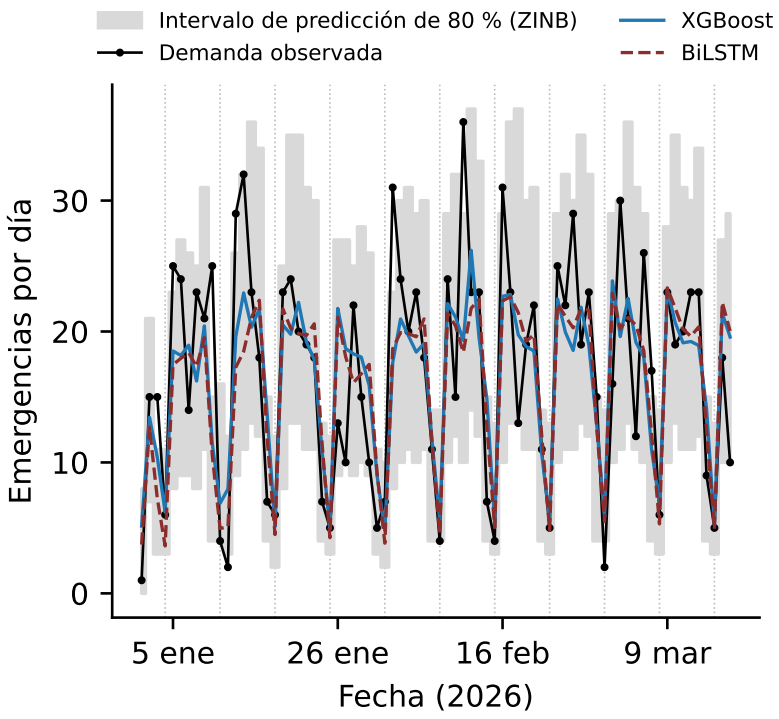


Figura 17. Demanda observada, pronósticos de XGBoost y BiLSTM (promedio de cinco semillas) e intervalo de predicción de 80 % de la ZINB. El periodo, del 1 de enero al 17 de marzo de 2026, es el trimestre más representativo del año de prueba. Las líneas punteadas verticales marcan los domingos.

Entre los GLM, la ZINB obtuvo la menor NLL (3,21), seguida muy de cerca por la BN (3,22). Ambas superan con claridad a la Poisson (3,43) (Cuadro 8). Esto indica que la sobredispersión es la propiedad que más pesa. En el CRPS, en cambio, los tres modelos quedan prácticamente empatados, entre 3,40 y 3,42. Su parámetro de forma ($r = 10{,}2$) es cercano al que el EDA encontró al agrupar los días por calendario ($r \approx 10$). En el año de prueba, su probabilidad media de inflación fue de 0,005: una vez incluido el calendario, casi no quedan ceros sin explicar. El intervalo de 80 % de la ZINB contuvo el 85 % de los días de prueba, una cobertura ligeramente conservadora frente al 80 % nominal. Por su mayor error puntual, los GLM no son la herramienta de pronóstico. Su aporte es la distribución completa, de la que se obtiene la probabilidad de superar un umbral de demanda. Se repite así la complementariedad entre el aprendizaje automático y los GLM que encontró [18].

XGBoost y la ZINB cumplen funciones distintas. XGBoost responde cuántas emergencias se esperan, y con ese número se programa la capacidad. La ZINB responde qué tan probable es cada nivel de demanda, y de ella salen el rango de 80 % y la probabilidad de un día alto. Por eso, el rango no es un margen de error de XGBoost, sino lo que otro modelo espera para ese día. Ambos resultaron coherentes. El pronóstico de XGBoost cayó dentro del rango en 334 de los 336 días de prueba. La correlación fue de 0,91 y la diferencia absoluta media, de 2,08 emergencias. Si el número quedara fuera del rango, los modelos discreparían y ese día convendría revisarlo.

6.5. Clasificación por niveles y red bayesiana

Para el centro de control, saber si mañana será un día de demanda alta puede ser tan útil como el número exacto. Discretizado en los tres niveles, el pronóstico de XGBoost acierta en el 74 % de los días de prueba y la RB en el 73 % (Fig. 18). Predecir siempre la clase más frecuente acierta en el 53 %. La RB nunca predice el nivel medio, porque asigna cada día a la moda de su distribución condicional. El Cuadro 11 muestra que XGBoost tiene menor costo ordinal en ambas variantes. Según las matrices de la Fig. 18, la RB supera a XGBoost en la sensibilidad de los niveles extremos. Obtiene 0,89 frente a 0,70 en el bajo, y 0,95 frente a 0,92 en el alto. Además, lo iguala en el F1 del nivel alto (0,84 frente a 0,83). Lo consigue a costa de no predecir nunca el nivel medio: clasifica 25 de esos días como bajos y 47 como altos.

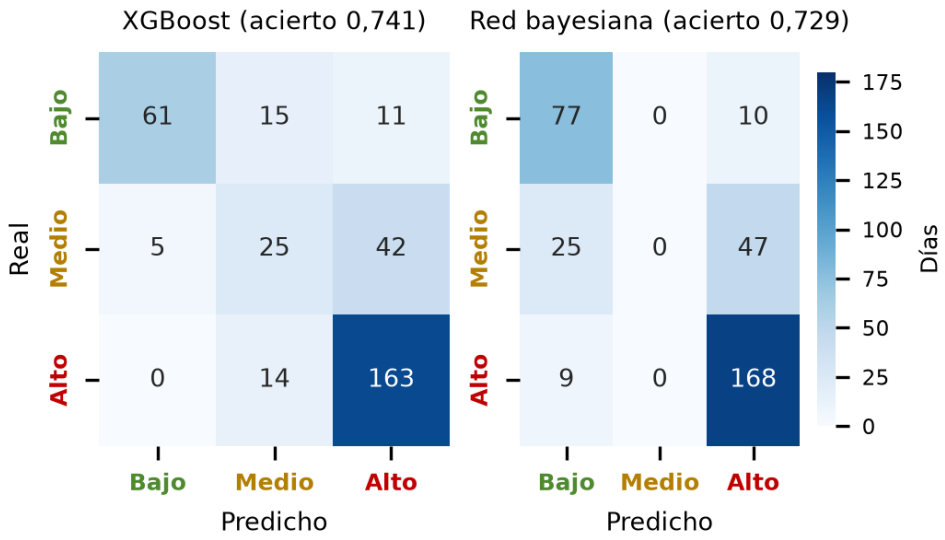


Figura 18. Matrices de confusión de los niveles de demanda en el conjunto de prueba.

Cuadro 11
Desempeño por nivel de demanda y costo ordinal en prueba

Modelo	F1 bajo	F1 medio	F1 alto	Sensibilidad alto	Costo simétrico	Costo asimétrico
RB	0,78	0	0,84	0,95	0,33	0,46
XGBoost	0,80	0,40	0,83	0,92	0,29	0,35

Fuente: elaboración propia.

En la estructura aprendida por la RB, el festivo se vincula con el nivel de demanda, con el mes y con el día de la semana. El nivel, a su vez, se vincula con el día de la semana. Esta estructura coincide con el EDA: los festivos y los fines de semana concentran los días de nivel bajo. Por ello, la RB se propone como capa explicativa para el comité técnico y no como herramienta de pronóstico. Se prefirió a explicar los 40 rezagos de XGBoost porque expresa el resultado en términos de calendario, que el centro de control ya usa.

6.6. Pronóstico del tiempo de respuesta

Además de cuántas emergencias llegarán, la planificación necesita saber cuánto tardará su atención. El Cuadro 12 resume el pronóstico de tiempos de respuesta sobre 13 112 órdenes de prueba. La mediana por tipo de emergencia obtuvo el menor MAE (1,06 h) y la mayor proporción de órdenes con un error de 1 h o menos. El bosque aleatorio, en cambio, tuvo menor RMSE. La alerta de respuestas de más de 4 h se evaluó con ambos métodos. Solo el bosque aleatorio identificó algunas (F1 de 0,25), porque la mediana nunca predice ese intervalo. Con las variables disponibles, el tipo de emergencia explica la mayor parte del tiempo de respuesta.

Cuadro 12
Pronóstico del tiempo de respuesta en prueba (13 112 órdenes)

	Todas las órdenes				MAE por tipo (h)	
Método	MAE (h)	RMSE (h)	Error ≤ 1 h	F1 > 4 h	Contr.	No contr.
Mediana por tipo	1,06	1,87	67,16 %	0	1,81	0,15
Bosque aleatorio	1,11	1,74	60,44 %	0,25	1,90	0,15
Gradient boosting de histogramas	1,13	1,74	59,26 %	–	1,94	0,15
XGBoost	1,19	1,82	58,23 %	–	2,04	0,15

Error ≤ 1 h: porcentaje de órdenes cuyo error absoluto es de 1 h o menos. F1 > 4 h: alerta evaluada solo con la mediana y el bosque aleatorio; –: no evaluado.
Fuente: elaboración propia.

El error global, sin embargo, oculta una diferencia marcada entre tipos (Cuadro 12). En las no controladas, los cuatro métodos tienen un MAE de 0,15 h y aciertan dentro de una hora en todas las órdenes. Esto ocurre porque su tiempo de respuesta es muy estable. En las controladas, el MAE sube a 1,81 h con la mediana por tipo, que sigue siendo el mejor método. La incertidumbre del tiempo proviene, por tanto, de las emergencias sin urgencia normativa. Para planear la atención urgente, la variable crítica es cuántas no controladas habrá, no cuánto tardará cada una.

6.7. Síntesis de resultados

El Cuadro 13 asigna a cada necesidad operativa el modelo que mejor la atiende según los resultados anteriores.

Cuadro 13
Modelo recomendado según la necesidad operativa

Necesidad operativa	Modelo recomendado	Métrica clave
Pronóstico diario de la demanda	XGBoost ($W = 40$)	MAE de prueba 4,22
Probabilidad de alta demanda	ZINB	NLL 3,21; CRPS 3,40
Explicación del nivel de demanda	RB	Acierto 0,73
Tiempo de respuesta esperado	Mediana por tipo	MAE 1,06 h
Alerta de respuesta mayor de 4 h	Bosque aleatorio	F1 0,25

Fuente: elaboración propia.

6.8. Tablero de control por rol

El OE4 lleva los resultados anteriores al centro de control, donde se decide la capacidad de cada día. El Cuadro 14 resume sus tres vistas, el rol que las ve, sus KPI principales y el resultado del proyecto que justifica cada uno.

Cuadro 14
Vistas del tablero de control, KPI principales y razón de su elección

Vista y rol	Pregunta que responde	KPI principales	Razón de su elección
Operación del día (todos los roles)	¿Cuántas emergencias llegan mañana, cuántas cuadrillas programar y dónde ubicarlas?	Pronóstico de mañana y su intervalo de 80 %; probabilidad de demanda alta con semáforo; nivel esperado y su causa; cuadrillas recomendadas; reparto por sector y mapa de calor; no controladas esperadas; avance del día y hora pico	El pronóstico redujo el error un 34 % frente a la referencia, y el intervalo de la ZINB está calibrado (85 %). El calendario explica el nivel, el reparto por sector reduce el déficit y las no controladas son las urgentes
Capacidad y costo (administrativo y técnico)	¿Cómo rindió la capacidad del mes y qué conviene decidir?	Horas en déficit y sin uso; horas no cubribles; días críticos; turnos programados frente a recomendados; cumplimiento de la hora en no controladas; costo aproximado del mes; cuadrilla de reserva; tendencia de la demanda y de las causas	Son los indicadores del análisis costo-beneficio: D, O, horas no cubribles, días críticos, el costo anual de la capacidad y el umbral de sanción de 3 % que justifica la reserva
Salud del modelo (técnico)	¿El modelo y los datos siguen siendo confiables?	Error medio de 30 días; ventaja sobre la referencia; sesgo; cobertura del intervalo; deriva de la demanda; antigüedad del reajuste; error del retador; calidad del registro; cuatro alarmas	Vigilan los supuestos del protocolo: el error de validación (5,46) como umbral, la ventaja de 38 % sobre la media móvil de 7 días (34 % sobre la mejor referencia), la cobertura nominal de 80 % y el cambio de nivel entre validación y prueba

Fuente: elaboración propia.

La Fig. 19 muestra la vista operativa del 17 de marzo de 2026, último día completo del registro. La tarjeta principal anuncia las emergencias previstas para el día siguiente y su rango probable (1). A la derecha, el semáforo muestra la probabilidad de un día de demanda alta (2). Debajo, la vista resume las decisiones del día: cuántas cuadrillas programar (3), en qué sectores ubicarlas (4) y qué nivel de demanda se espera, con su causa (5). También muestra cuántas no controladas se atendieron en menos de una hora (6) y la hora pico (7).



Figura 19. Vista «Operación del día» del tablero para el 17 de marzo de 2026. (1) Emergencias previstas para el día siguiente, según XGBoost, y su rango probable de 80 %, según la ZINB. (2) Probabilidad de un día de demanda alta, con semáforo. (3) Cuadrillas recomendadas y ocupación prevista. (4) Sectores que concentran la demanda prevista con barrio ubicado. (5) Nivel de demanda esperado según la RB y su causa. (6) No controladas atendidas en menos de una hora. (7) Hora pico del día.

La misma vista incluye el mapa de calor de la demanda por barrio en los 12 meses previos, con la ubicación aproximada del escenario de la sección 7.2.2 (Fig. 20). Para cada sector con cuadrilla, el tablero sugiere una base en el centro de sus barrios, ponderado por esas órdenes. El mapa solo incluye las órdenes con barrio ubicado, cerca del 28 % del total, y el tablero lo aclara junto a él. No representa toda la demanda: es una imagen de cómo podría distribuirse si todas estuvieran ubicadas.

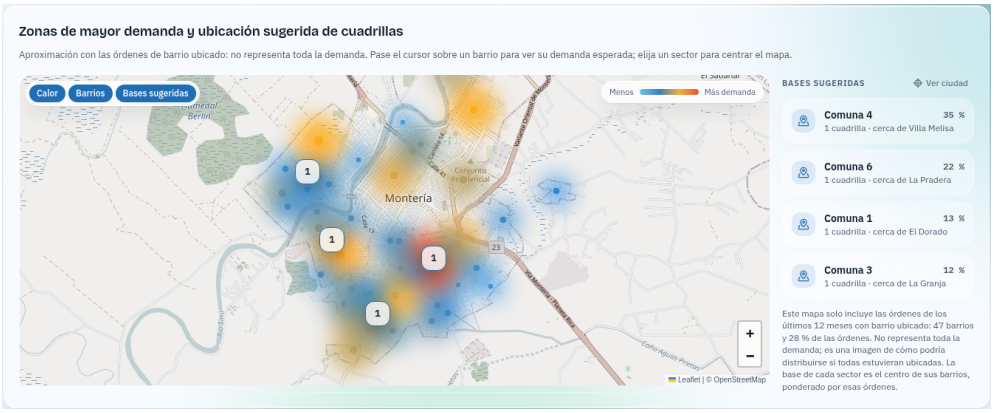
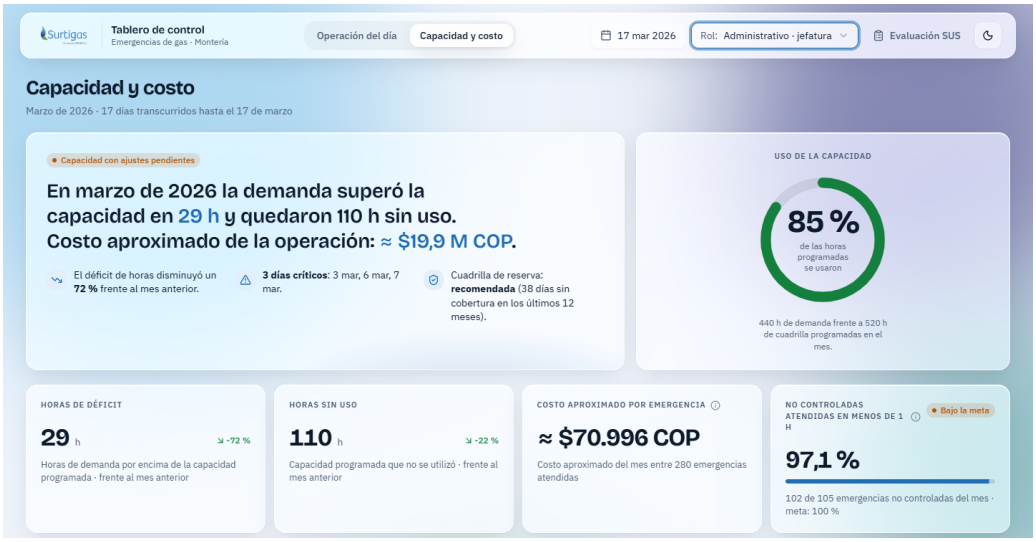
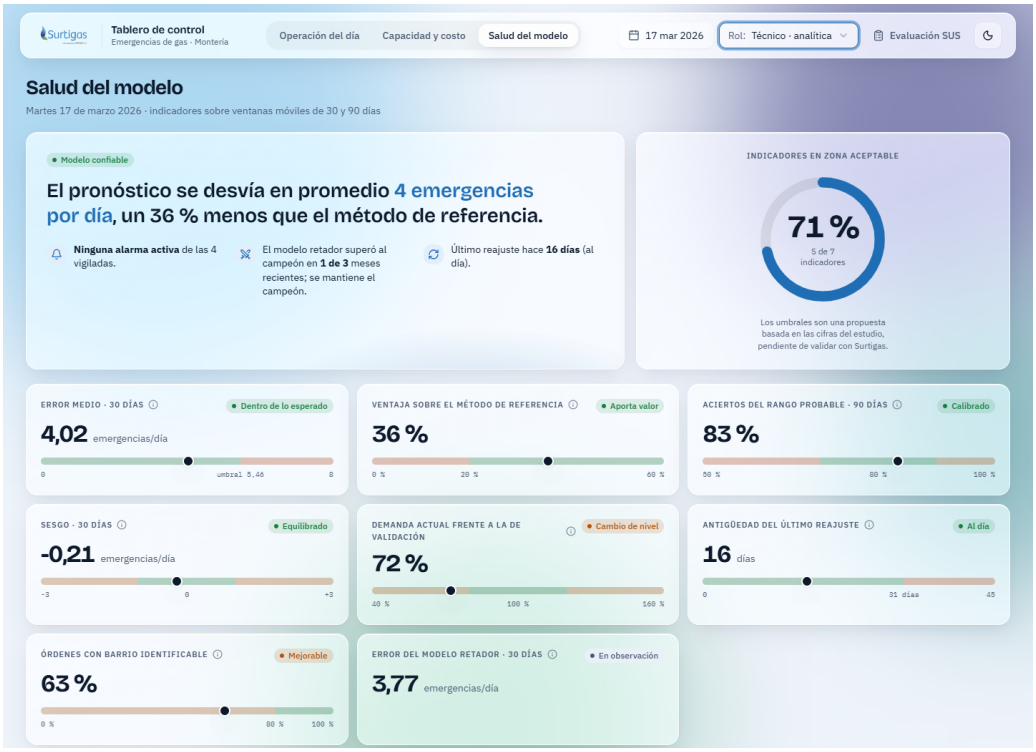


Figura 20. Mapa de calor de las órdenes con barrio ubicado en los 12 meses previos y bases sugeridas por sector. No representa toda la demanda. El tablero identifica cada sector con el nombre de su comuna.

La vista administrativa (Fig. 21a) resume el mes en una frase: cuántas horas superó la demanda a la capacidad, cuántas quedaron sin uso y el costo aproximado de la operación. Los valores monetarios se muestran como aproximados, porque usan los supuestos de la sección 5.6.3, que el tablero lista en una nota. La vista indica, además, si conviene la cuadrilla de reserva, con el criterio de la sección 7.2.4.



(a) Vista «Capacidad y costo» (rol administrativo), marzo de 2026.



(b) Vista «Salud del modelo» (rol técnico), 17 de marzo de 2026.

Figura 21. Vistas administrativa y técnica del tablero. (a) Horas en déficit y sin uso, costo aproximado, uso de la capacidad y KPI del mes. (b) Error medio de 30 días, ventaja sobre la referencia, cobertura del intervalo y demás indicadores del modelo, cada uno con su medidor de umbral.

La vista técnica (Fig. 21b) muestra cada indicador del modelo con un medidor que marca su umbral. En el ejemplo, el error medio de 30 días es de 4,02 emergencias por día, por debajo del umbral de 5,46, y ninguna de las cuatro alarmas está activa. Las alarmas avisan si el error supera el de validación o si la ventaja sobre la referencia baja del 20 %. También avisan si el retador gana tres meses seguidos o si la cobertura del intervalo sale del rango de 70 a 90 %. Así, el tablero vigila en operación lo que un solo año de prueba no alcanza a confirmar.

La verificación automática confirmó que el tablero reproduce las cifras del proyecto. Obtuvo el mismo MAE de prueba, de 4,22 con cinco semillas, una cobertura del intervalo del 85 % y un acierto de la RB de 0,729. Las pruebas unitarias de la API también pasaron sin fallos. El tablero aún no se ha entregado a Surtigas, por lo que el cuestionario SUS quedó integrado para aplicarlo cuando el personal del centro de control lo use.

7. Análisis costo-beneficio

Esta sección responde la segunda parte de la pregunta principal (OE3) y aplica la metodología de la sección 5.6. Primero detalla los costos del proyecto. Después presenta sus beneficios: las horas que el pronóstico deja de dimensionar mal, el escenario simulado por sector, el punto de equilibrio y el costo por incumplimiento. Por último, evalúa la rentabilidad y el retorno de la inversión.

7.1. Costos del proyecto

La inversión inicial es de $37,89 millones y tiene dos componentes (Cuadro 15). La creación del modelo cuesta $7,31 millones: dos personas dedicaron 8 h semanales durante 32 semanas, valoradas con el salario de un analista de datos. Ese salario es de $3.000.000 mensuales, cercano a la mediana del mercado colombiano [51] y al promedio de las vacantes publicadas [52]. La marcha blanca cuesta $30,58 millones, el 81 % de la inversión, porque equivale a un mes de nómina de la línea base. Durante ese mes, el esquema propuesto opera en paralelo con el actual mientras se calibra. Como la empresa pagaría esa nómina de todos modos, incluirla es un supuesto conservador que reduce la rentabilidad estimada.

Cuadro 15
Desglose de la inversión inicial y de los costos anuales de operación del sistema

Concepto	Cálculo	Valor
Valor hora del analista de datos	$3.000.000 / 210 h	$14.285,71
Creación del modelo	2 personas × 8 h/semana × 32 semanas = 512 h	$7.314.285,71
Marcha blanca	Un mes de nómina de A	$30.577.312,60
Inversión inicial		**$37.891.598,32**
Office 365	Costo anual	$599.900,00
Editor de código (VS Code)	Costo anual	$0

Precios de 2026. Los costos anuales se aplican a C y D, indexados con la inflación esperada.
Fuente: elaboración propia.

La operación del sistema cuesta $599.900 al año por la licencia de Office 365, y el editor de código es gratuito. El reajuste mensual tarda segundos en un computador personal. El tablero también se ejecuta en un computador local, por lo que no hay costos de cómputo ni de alojamiento. Si se publicara en la red, el costo del contenedor de la API se sumaría a la operación anual.

El costo anual de la capacidad, por su parte, suma la nómina de las cuadrillas, las horas extra que cubren el déficit y los traslados entre sectores. En la línea base, ese costo es de $429,92 millones en el año base. La sección 7.3 compara ese costo con el de cada escenario.

7.2. Beneficios asociados

Los beneficios del proyecto son de dos clases. Los operativos son las horas de cuadrilla que el pronóstico y el reparto por sectores dejan de dimensionar mal. Los regulatorios son el menor riesgo de incumplir el tiempo de atención de una hora.

7.2.1. Horas mal dimensionadas por el pronóstico: El tiempo tipo de atención es de 1,57 h por emergencia, desde la asignación hasta la finalización. Este valor se midió en 43 732 órdenes reales del periodo de entrenamiento y validación, sin usar el año de prueba. El Cuadro 16 aplica la ecuación (6) a las dos formas de planificar. La planificación propuesta usa el promedio de las predicciones de las cinco semillas de XGBoost.

Cuadro 16
Horas de cuadrilla mal dimensionadas en el año de prueba (336 días)

Indicador	Actual (media 7 días)	Propuesta (XGBoost)
MAE (emergencias por día)	6,76	4,20
Horas ociosas	1803	927
Horas en déficit	1767	1292
Horas en prueba (336 días)	3570	2219
Horas por año	3878	2410
Días con déficit de más de 5 emergencias	94	61

El MAE propuesto (4,20) usa el promedio de las predicciones de las cinco semillas; el 4,22 del Cuadro 8 es la media de los MAE por semilla. Fuente: elaboración propia.

La planificación propuesta reduce en 38 % las horas mal dimensionadas. En el año de prueba ahorra 1351 h: 876 son horas ociosas, que bajan de 1803 a 927, y 475 son horas en déficit, que bajan de 1767 a 1292. Anualizado, el ahorro es de 1468 h, equivalentes a 183 turnos de 8 h, de las cuales 951 son ociosas y 517 en déficit. El 65 % del ahorro proviene, entonces, de la capacidad que la media móvil asigna de más. Además, los días en que la demanda supera al pronóstico en más de 5 emergencias bajan de 94 a 61. Son los días con mayor riesgo para el cumplimiento del IRST. Estas horas incluyen las controladas, pero la mejora se mantiene en la parte urgente: en las no controladas, el MAE es de 2,57 frente a 3,35 de la mejor referencia.

7.2.2. Escenario simulado de asignación de cuadrillas por sector: Esta subsección aplica el procedimiento de la sección 5.6.2 a un escenario simulado. La demanda, el pronóstico y la capacidad provienen del registro, pero la asignación de cuadrillas por sector no se ha aplicado en la operación. Su línea base no es la misma de la sección 7.2.1. Allí se comparan dos pronósticos, y la media móvil representa la planificación sin modelo. Aquí se comparan formas de programar y repartir cuadrillas, por lo que la referencia es la capacidad que la empresa programó en el año de prueba.

Ubicación de los barrios y probabilidad por barrio. En los 12 meses previos al año de prueba, el barrio se identificó en el 48,4 % de las órdenes, con 426 nombres distintos. Esta cifra es menor que el 51 % del EDA porque aquí se descartaron los fragmentos de observación que no son nombres de barrio. De los 60 barrios más frecuentes se ubicaron 47: 35 por su nombre y 12 por un lugar que lo lleva. Esos barrios reúnen el 55,8 % de las órdenes con barrio identificado. Los 13 restantes no aparecen en OpenStreetMap con el nombre del registro o están mal escritos en él. Entre ellos hay variantes abreviadas de barrios ubicados, como «Rep de Panamá», cuyas órdenes se repartieron con la simulación de Monte Carlo.

Los barrios ubicados pertenecen a 9 sectores de la ciudad. Entre las emergencias con barrio ubicado, el Sector 4 concentra el 35 % y el Sector 6 el 22 %. En el año de prueba, el 28 % de las órdenes quedó asignado directamente a su sector, y el resto se repartió con la simulación de Monte Carlo.

La Fig. 22 aplica la ecuación (7) a un lunes con el pronóstico medio de los lunes de prueba (18,8 emergencias). La Pradera y El Recuerdo tienen una probabilidad del 54 % y del 53 % de registrar al menos una emergencia, y ningún otro barrio supera el 40 %. Como la demanda está repartida entre muchos barrios, la unidad útil para asignar cuadrillas es el sector y no el barrio.

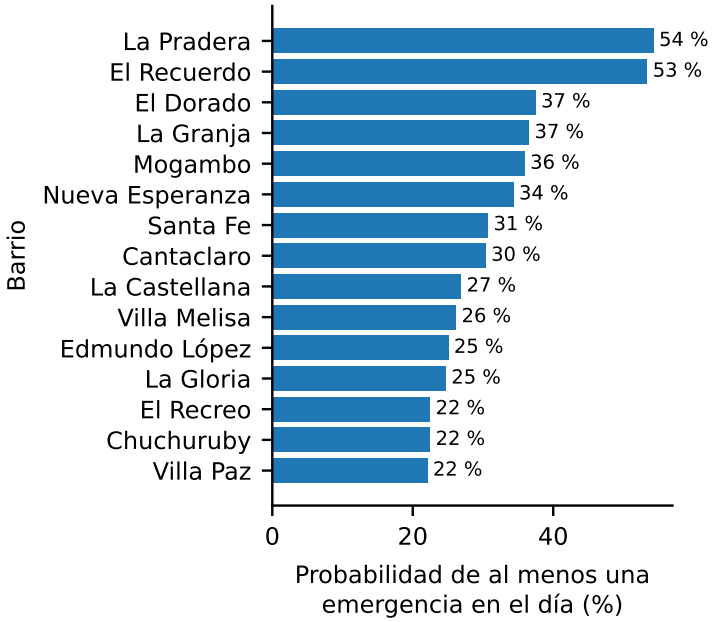


Figura 22. Probabilidad de que cada barrio registre al menos una emergencia en un lunes con el pronóstico medio de los lunes del año de prueba (18,8 emergencias). Quince barrios con mayor probabilidad.

Comparación de escenarios. La capacidad observada en el año de prueba fue de 4 a 5 cuadrillas de lunes a viernes, 4 los sábados y 2 los domingos y festivos. El Cuadro 17 compara los tres escenarios en el total del periodo y en promedio por día. La Fig. 23 muestra, además, el tiempo que cada escenario pierde en traslados entre sectores.

Cuadro 17
Escenarios simulados de asignación de cuadrillas por sector en el año de prueba (336 días)

			Total (336 días, h)		Promedio diario (h)			Costo ponderado, $kD + O$		
Escenario	Cuadrillas por día	Turnos de 8 h	Déficit	Ociosas	Déficit	Ociosas	Días con déficit > 8 h	$k = 1$	$k = 2$	$k = 3$
A. Línea base: capacidad observada, reparto igual entre sectores	4	1266	1145	1724	3,41	5,13	57	2870	4015	5160
C. Capacidad según pronóstico, reparto por probabilidad	4	1228	889	1635	2,65	4,87	44	**2525**	**3414**	**4304**
D. Como C, más una cuadrilla de reserva	5	1564	270	3733	0,80	11,11	12	4003	4272	4542

Costo ponderado: horas en déficit multiplicadas por el peso k, que expresa el valor de una hora en déficit frente a una ociosa, más las horas ociosas; en negrita, el menor de cada columna. Cuadrillas por día redondeadas al entero superior.

Fuente: elaboración propia.

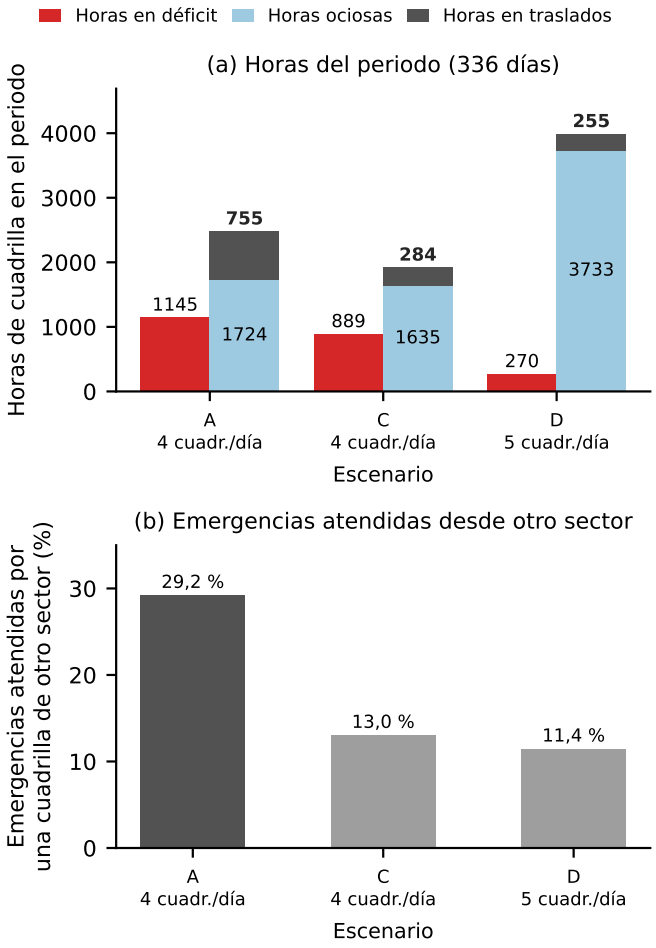


Figura 23. Horas de cuadrilla en déficit y horas ociosas por escenario, sumadas sobre los sectores. (a) Horas en déficit, horas en traslados entre sectores y horas ociosas en el año de prueba, del 16 de abril de 2025 al 17 de marzo de 2026. (b) Porcentaje de emergencias atendidas por una cuadrilla de otro sector. A: línea base, con la capacidad observada y reparto igual; C: capacidad según el pronóstico con reparto por probabilidad; D: escenario C con una cuadrilla de reserva.

Primero conviene separar el efecto del reparto. Con la misma capacidad observada, repartir las cuadrillas según la probabilidad de cada sector reduce en 24 % las horas en déficit frente a la línea base (A). Esas horas bajan de 1145 a 875 h, y los días con déficit de más de 8 h pasan de 57 a 43. La mejora proviene de los traslados: con el reparto igual, A necesita 1633 traslados entre sectores en el año, y con el reparto por probabilidad solo 705. Además, los traslados de A son más largos, de 6 km en promedio frente a 5 km. La razón es que las cuadrillas que le sobran están en sectores alejados de la demanda. Por eso, A pierde 755 h en viajes, frente a 278 h. La Fig. 23b muestra la consecuencia para la atención: en A, una cuadrilla de otro sector atiende el 29 % de las emergencias, frente al 13 % en C. Cada una de esas emergencias recibe la cuadrilla unos 28 min más tarde. Esta es la mejora principal y no requiere más cuadrillas, aunque se apoya solo en la parte de la demanda con barrio ubicado.

La capacidad fijada con el pronóstico (C) usa un 3 % menos de turnos que la observada. Su déficit es similar: 889 h frente a 875 h con la capacidad observada y el mismo reparto. Es decir, el pronóstico reproduce la capacidad que la empresa ya ajusta por tipo de día, pero la fija con un día de anticipación y día por día. Así, la mayor parte de la mejora operativa de C frente a A proviene del reparto por sectores. El aporte propio del pronóstico es programar la capacidad según la demanda esperada, con menos turnos. Agregar una cuadrilla de reserva (D) reduce el déficit en 70 % frente a C, hasta 270 h, y los días con más de 8 h de déficit a 12. A cambio, usa un 27 % más de turnos.

El Cuadro 18 resume lo que cada escenario ahorra frente a la línea base.

Cuadro 18
Horas ahorradas frente a la línea base por escenario en el año de prueba (336 días)

		Ahorro frente a A			
Escenario	Turnos	Déficit (h)	Ociosas (h)	Traslados	Déficit no cubrible (h)
A. Línea base	1266	–	–	–	337
C. Capacidad por pronóstico	1228	256	89	906	257
D. C con reserva	1564	876	−2009	994	48

A es la referencia de la comparación, por lo que no tiene horas ahorradas (–); un valor negativo indica más horas que en A. Déficit no cubrible: horas en déficit que exceden el límite legal de dos horas extra diarias por cuadrilla.
Fuente: elaboración propia.

C y D necesitan entre 900 y 1000 traslados menos que A en el año. En C, el déficit baja 256 h y las horas ociosas 89 h, porque además se programan menos turnos. En D, el déficit baja 876 h, pero la cuadrilla de reserva agrega 2009 h ociosas.

El costo ponderado del Cuadro 17 muestra el papel del valor de una hora en déficit. C tiene el menor costo con $k = 1$, 2 y 3. D solo lo supera cuando $k > 3{,}38$, es decir, cuando una hora en déficit vale más de 3,38 horas ociosas. La elección entre ambos depende, entonces, de cuánto valore Surtigas una hora en déficit. Si esa hora vale más que una ociosa, la capacidad óptima es el cuantil $k/(k+1)$ de la demanda y no su valor esperado. El proyecto incorpora esa asimetría con escenarios: D se aproxima a planificar en un cuantil alto, y la ZINB da la probabilidad de un día de demanda alta.

El resultado depende de la capacidad supuesta. Con el reparto por probabilidad y 3, 4 o 5 cuadrillas de lunes a viernes, el déficit sería de 2286, 1061 y 402 h, respectivamente. La simulación mide el tiempo de los traslados entre sectores, pero no el desplazamiento dentro de cada sector ni su efecto sobre el tiempo de respuesta y el IRST. Por eso, sus horas no cubribles sirven para ordenar los escenarios y no como pronóstico absoluto del indicador.

7.2.3. Punto de equilibrio entre déficit y número de cuadrillas: Los escenarios anteriores no dicen cuántas cuadrillas convendría programar. Para responderlo, la Fig. 24 muestra cómo cambian las horas y el costo anual al variar la capacidad diaria, con el reparto por probabilidad. Al agregar cuadrillas, las horas en déficit bajan y las ociosas suben. Las dos curvas se cortan entre 3 y 4 cuadrillas por día, con unas 1862 h de cada clase en el año de prueba. Como no es posible programar una fracción de cuadrilla, el punto de equilibrio se redondea hacia arriba, a 4 cuadrillas por día. Con 3 todavía predomina el déficit (2320 h), mientras que con 4 baja a 1035 h y ya es menor que las horas ociosas (2735 h). Por encima de él, cada cuadrilla adicional agrega más horas ociosas que las que quita al déficit. Ese valor coincide con la capacidad que Surtigas programa de lunes a viernes, entre 4 y 5 cuadrillas, lo que respalda el modelo.

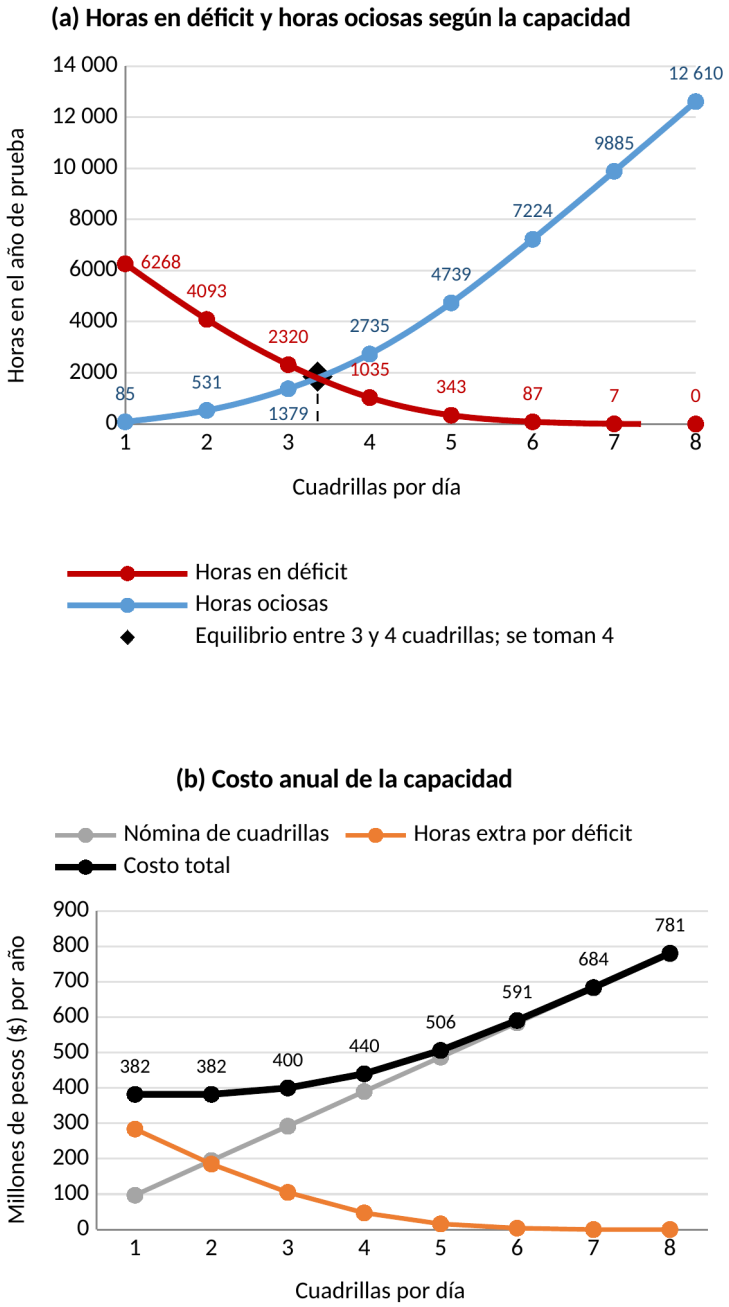


Figura 24. Efecto del número de cuadrillas por día en el año de prueba, con la misma capacidad todos los días y reparto por probabilidad. (a) Horas en déficit y horas ociosas; el rombo marca su intersección, entre 3 y 4 cuadrillas; se toman 4. (b) Costo anual de la capacidad, en millones de pesos ($): nómina, horas extra por déficit y total, que incluye los traslados.

La productividad marginal explica la forma de las curvas (Fig. 25 y Cuadro 19).

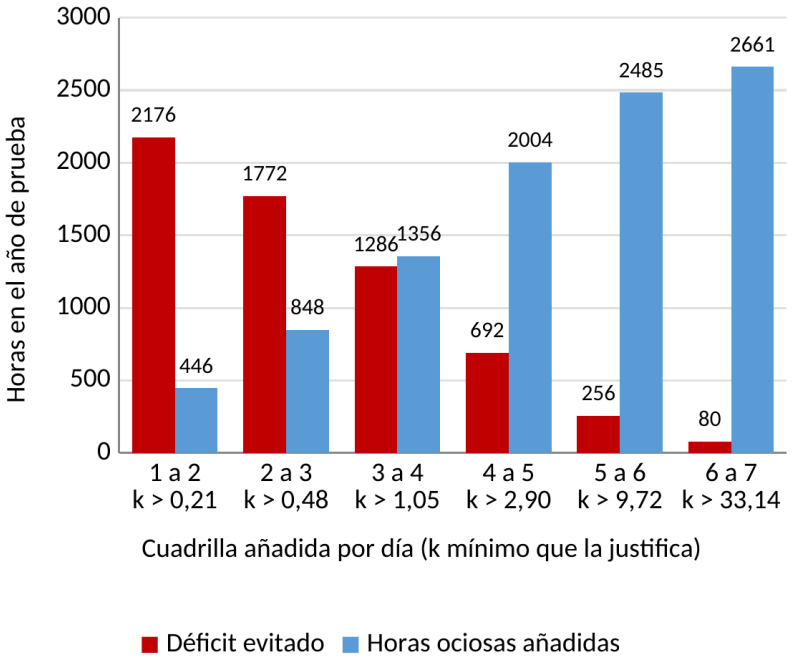


Figura 25. Productividad marginal de la cuadrilla en el año de prueba: horas en déficit que evita y horas ociosas que agrega cada cuadrilla adicional. Debajo de cada par se indica el k mínimo que la justifica, según la ecuación (9).

Cuadro 19
Productividad marginal de cada cuadrilla adicional en el año de prueba, con la misma capacidad todos los días y reparto por probabilidad

Cuadrillas por día	Déficit evitado (h)	Ociosas añadidas (h)	k mínimo	Ahorro extra ($ millones)	No cubribles evitadas (h)
1 a 2	2176	446	0,21	98,53	2556
2 a 3	1772	848	0,48	80,25	1858
3 a 4	1286	1356	1,05	58,22	937
4 a 5	692	2004	2,90	31,34	270
5 a 6	256	2485	9,72	11,57	46
6 a 7	80	2661	33,14	3,64	0
7 a 8	7	2725	386,76	0,32	0

Cada cuadrilla adicional aporta 2688 h de capacidad en el periodo y cuesta $97,38 millones al año en nómina. Parte de esa capacidad se consume en traslados entre sectores. k mínimo: peso de una hora en déficit con el que la cuadrilla adicional reduce el costo ponderado $kD + O$.

Fuente: elaboración propia.

Cada cuadrilla adicional aporta la misma capacidad, 2688 h en el periodo, pero evita cada vez menos déficit. La segunda cuadrilla evita 2176 h, la tercera 1772, la cuarta 1286 y la quinta 692. El resto de su capacidad queda ociosa, porque atiende emergencias que las demás cuadrillas ya cubrían. Estos rendimientos decrecientes aplanan la curva de déficit y empinan la de horas ociosas. La tercera cuadrilla todavía evita más déficit del que deja ocioso, y la cuarta ya no. Por eso las curvas se cortan entre 3 y 4 cuadrillas. Redondear a 4 se justifica si una hora en déficit pesa más que una ociosa. Según el Cuadro 19, la cuarta cuadrilla reduce el costo ponderado $kD + O$ cuando $k > 1{,}05$, y la quinta cuando $k > 2{,}90$. El k mínimo de la ecuación (9) sirve, entonces, como regla de decisión. Si Surtigas fija el peso de una hora en déficit, conviene programar cuadrillas hasta la última cuyo k mínimo quede por debajo de ese peso. Con $k = 2$, la capacidad fija adecuada es de 4 cuadrillas por día, y con $k = 3$ es de 5, porque la quinta se justifica desde $k > 2{,}90$. El resultado es coherente con el Cuadro 17. C ajusta la capacidad cada día, con un promedio de 3,65 cuadrillas, y por eso conserva el menor costo ponderado incluso con $k = 3$. D, que agrega una cuadrilla todos los días, solo gana cuando $k > 3{,}38$.

En pesos, el costo anual sería mínimo con 2 cuadrillas por día ($382,21 millones). La productividad marginal también explica este resultado (Fig. 24b). Cada cuadrilla adicional cuesta $97,38 millones al año en nómina. La segunda ahorra

$98,53 millones en horas extra, algo más de lo que cuesta, y por eso se paga sola. Desde la tercera, el ahorro baja a $80,25 millones o menos, y cada cuadrilla cuesta más de lo que ahorra. Una hora en déficit pagada como extra cuesta solo un 25 % más que una ordinaria. Por eso, una cuadrilla tendría que evitar al menos 2150 h de déficit para pagarse sola. En el déficit no cubrible, en cambio, la cuarta cuadrilla todavía evita 937 h, de modo que su aporte al cumplimiento sigue siendo alto. La capacidad de menor costo, sin embargo, no es operable. Con 2 cuadrillas, el déficit excede el límite legal de horas extra en 3111 h del periodo, frente a 337 h en la línea base. Con las 4 cuadrillas del equilibrio, ese exceso baja a 316 h, menos que en la línea base. Es la menor capacidad fija que mejora el cumplimiento, con un costo de $440,16 millones por año.

El escenario C mejora esa capacidad fija. Programa entre 1 y 6 cuadrillas según el pronóstico del día, con un promedio de 3,65. Así cuesta $400,32 millones por año y deja 257 h no cubribles, menos que la capacidad fija de 4 en ambos indicadores. De igual forma, D cuesta $36,89 millones menos que una capacidad fija de 5 cuadrillas y deja casi el mismo déficit no cubrible (48 frente a 46 h). Ajustar la capacidad al pronóstico rinde más, por tanto, que fijar un número de cuadrillas.

7.2.4. Costo por incumplimiento y costo por confiabilidad: Esta subsección aplica la metodología de la sección 5.6.4 a los escenarios simulados. Según la ecuación (13), cada hora no cubrible equivale a 0,64 emergencias atendidas fuera de la hora. En el año de prueba, la línea base deja 337 h no cubribles, C 257 y D 48. Anualizadas, esas horas corresponden a 233, 178 y 33 emergencias por año, respectivamente (Cuadro 20).

Cuadro 20
Costo por incumplimiento y costo anual esperado de la capacidad según la probabilidad de sanción

Indicador	A	C	D
Horas no cubribles, año de prueba (h)	337	257	48
Emergencias fuera de la hora por año	233	178	33
Indemnización mínima ($ millones)	0,69	0,52	0,10
Costo anual esperado ($ millones) según p_0			
0 %	430,61	**400,85**	469,31
1 %	465,63	**427,51**	474,28
3 %	535,66	**480,82**	484,22
5 %	605,70	534,14	**494,16**
10 %	780,79	667,43	**519,01**

p_0: probabilidad anual de una multa de 2000 SMMLV en la línea base. El costo anual esperado suma al costo del año base del Cuadro 21 la indemnización mínima y la exposición regulatoria $p_x M_s$. En negrita, el menor de cada fila. D supera a C desde $p_0 = 3\,\%$.
Fuente: elaboración propia.

Los componentes tangibles del incumplimiento son pequeños. La indemnización mínima suma $0,69 millones al año en la línea base y $0,52 millones en C. El valor social del gas no suministrado, según la ecuación (15), no supera $0,03 millones en ningún escenario. En consecuencia, la ecuación (16) da $k = 1{,}2525$, prácticamente igual al recargo de la hora extra. Es decir, el gas que deja de recibir el usuario no justifica por sí solo una capacidad mayor. El costo relevante del incumplimiento es, entonces, el riesgo para la seguridad de los usuarios y la exposición a una sanción.

El Cuadro 20 y la Fig. 26 incorporan esa exposición al costo anual. Sin riesgo de sanción, C conserva el menor costo, como en el Cuadro 21. A medida que crece p_0, el costo de A y C aumenta más rápido que el de D, porque D casi no deja horas no cubribles. Según la ecuación (17), D supera a C desde $p_0 = 3\,\%$. Con $p_0 = 1\,\%$, cada hora no cubrible de la línea base cuesta en valor esperado unos $95.556, es decir, 2,87 horas de cuadrilla. Este valor se refiere solo a las horas no cubribles, no a todas las horas en déficit. Aun así, cae dentro del rango de k evaluado en el Cuadro 17.

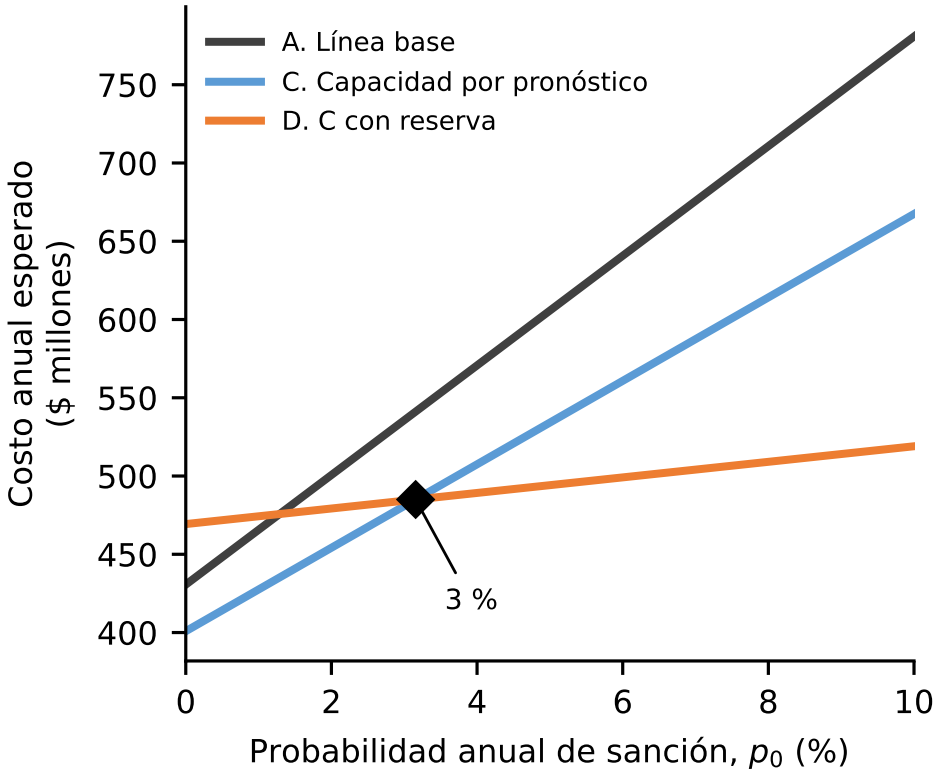


Figura 26. Costo anual esperado de cada escenario según la probabilidad anual p_0 de una multa de 2000 SMMLV en la línea base. El rombo marca el cruce entre C y D, en $p_0 = 3\,\%$. Costos del año base a precios de 2026, con la indemnización mínima incluida.

Cuadro 21
Costo anual de la capacidad y evaluación financiera de los escenarios frente a la línea base

Indicador ($ millones)	A	C	D
Nómina de cuadrillas	366,93	355,91	453,30
Horas extra por déficit	51,86	40,28	12,21
Traslados entre sectores	11,13	4,13	3,71
Costo anual total	429,92	400,32	469,21
VPN	–	99,36	−156,16
VAE	–	29,81	−46,85
TIR (%)	–	83,14	–
Relación B/C	–	3,62	0,00
PRI descontado (meses)	–	21,76	–
Déficit no cubrible, año 5 (h)	509	401	116

Costos del año base a precios de 2026; indicadores frente a A, con TMAR de 15,24 % y horizonte de 5 años. VAE: valor anual equivalente; PRI: periodo de recuperación de la inversión. En D, la TIR y el PRI no existen porque todos sus flujos netos son negativos.
Fuente: elaboración propia.

Por lo tanto, la elección entre C y D no depende del costo de la hora extra, sino del riesgo que Surtigas asigne al incumplimiento del IRST. Si la empresa estima que la probabilidad anual de una sanción máxima es menor de 3 %, el esquema con pronóstico (C) tiene el menor costo esperado. Si la estima mayor, la cuadrilla de reserva se paga con la reducción de ese riesgo. Según la sección 7.3, D se justifica si una hora en déficit cuesta al menos 4,34 veces una hora ordinaria. Este resultado expresa ese umbral como una probabilidad, que la empresa puede evaluar con su historial regulatorio. El cálculo usa el costo del año base. Con los flujos de cinco años, el umbral cambiaría en la medida en que crecen las horas no cubribles de cada escenario.

7.3. Rentabilidad del proyecto y retorno de la inversión

Esta subsección lleva a pesos las horas de los escenarios y evalúa si la inversión se recupera. El Cuadro 21 compara el costo anual de cada escenario en el año base con el de la línea base, y evalúa los flujos de los cinco años. Con cuadrillas de 4 personas y el SMMLV de 2026, una hora de cuadrilla cuesta $33.351, según la ecuación (10). La línea base cuesta $429,92 millones en el año base, de los cuales $51,86 millones son horas extra por déficit y $11,13 millones son traslados. La inversión inicial es de $37,89 millones (Cuadro 15). De ellos, $7,31 millones corresponden a la creación del modelo y $30,58 millones a la marcha blanca.

La Fig. 27 muestra que los flujos cambian de un año a otro. En C, el flujo neto pasa de $24,80 millones en el año 1 a $54,95 millones en el año 3 y cierra en $67,23 millones. El flujo crece porque A escala por redondeo la capacidad observada, y en el año 3, con una demanda 17 % mayor, sus días de 4 cuadrillas pasan a 5. C solo agrega cuadrillas cuando el pronóstico lo exige, y ese año paga $41,94 millones menos de nómina que A. Con ello, C alcanza un VPN de $99,36 millones, una TIR del 83,14 % y una relación B/C de 3,62, y recupera la inversión en 21,76 meses. La TIR es alta porque la inversión es pequeña frente al ahorro anual.

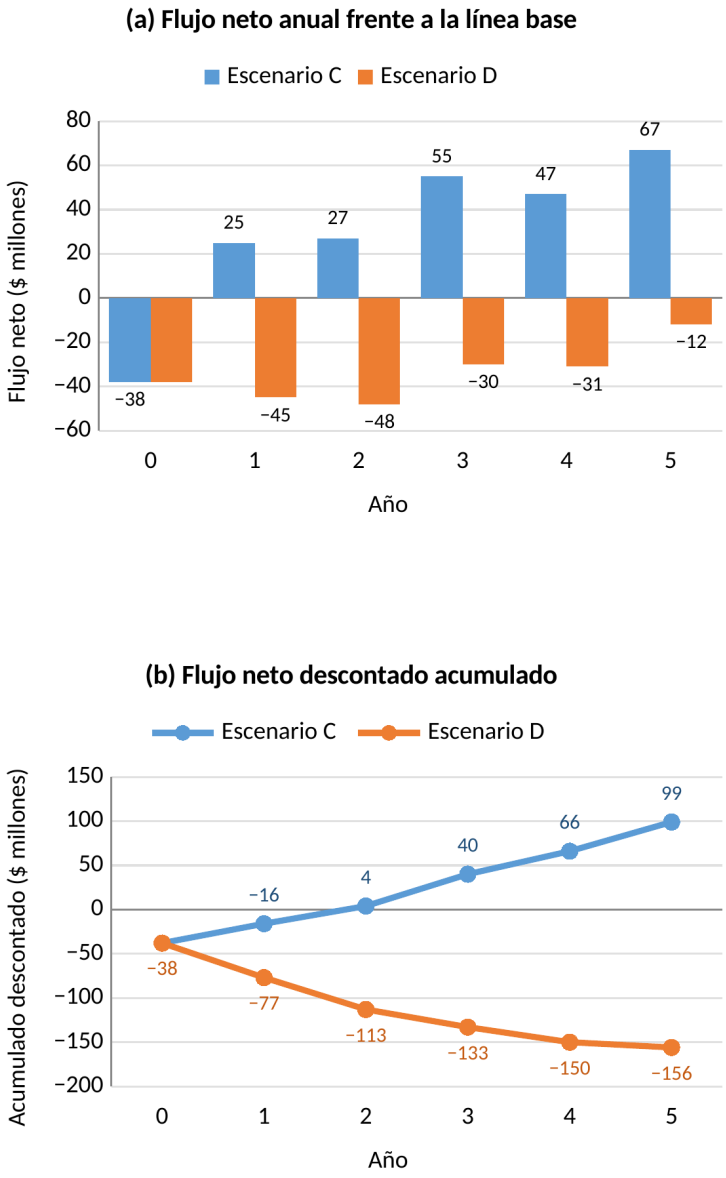


Figura 27. Flujo de caja de los escenarios C y D frente a la línea base, en millones de pesos ($) corrientes. (a) Flujo neto anual; el año 0 corresponde a la inversión inicial, igual en ambos escenarios, y el año 3 incluye el mantenimiento mayor. (b) Flujo neto descontado acumulado con la TMAR de 15 %; su valor en el año 5 es el VPN.

En el año base, C cuesta $29,60 millones menos que A. De ellos, $19,32 millones provienen del reparto por sectores, que no requiere el pronóstico, y $10,28 millones de fijar la capacidad con el pronóstico. El salto de A en el año 3 depende del crecimiento de la demanda. Sin ese crecimiento, el VPN de C sigue siendo positivo, de $73,55 millones (Cuadro 22).

Cuadro 22
Sensibilidad del VPN a los supuestos de la proyección

	VPN ($ millones)	
Caso	C	D
Caso base	99,36	−156,16
Demanda sin crecimiento	73,55	−195,40
Salarios +8 % anual	112,67	−163,90
Eficiencia del 80 %	87,78	−191,93
Mantenimiento mayor al doble	101,65	−160,02
Traslado a $600/km	87,72	−168,29
Traslado a $1.200/km	106,35	−148,89
Recargo dominical y festivo	101,98	−221,54

Cada caso cambia un supuesto del caso base. Eficiencia del 80 %: el escenario conserva solo el 80 % de la reducción del déficit frente a A. Recargo dominical y festivo: 90 % el primer año y 100 % desde el segundo, según la Ley 2466 de 2025. El caso base usa $975/km y una TMAR del 15,24 %.

Fuente: elaboración propia.

En C, el déficit no cubrible se mantiene entre 306 y 401 h en los cinco años, por debajo de las 509 h de A en el año 5.

El escenario D no es viable: su VPN es de $−156,16 millones, y como todos sus flujos netos son negativos, no tiene TIR. La cuadrilla de reserva aumenta la nómina mucho más de lo que ahorra en horas extra y traslados (Cuadro 21). A cambio, el déficit no cubrible de D no supera las 116 h en ninguno de los cinco años. Frente a C, D se justifica solo si una hora en déficit cuesta al menos 4,34 veces una hora ordinaria de cuadrilla. Este umbral es cercano al k de 3,38 del Cuadro 17 más uno. La razón es que, en pesos, la cuadrilla de reserva paga como horas ordinarias tanto las horas ociosas que agrega como las horas en déficit que cubre. Ese valor tendría que incluir el riesgo para la seguridad y el de incumplir el IRST, que el registro no permite valorar.

El Cuadro 22 muestra que C conserva un VPN positivo en el caso base y en los siete casos de sensibilidad.

Esos casos cambian un supuesto a la vez. Para medir el efecto conjunto de la incertidumbre, se hizo una simulación de Monte Carlo de 10 000 repeticiones con el mismo modelo y la misma TMAR. Cada repetición tomó seis supuestos de distribuciones triangulares independientes. La demanda creció de 0 a 11 % al año, con moda de 5 %. Los salarios crecieron de 3 a 8 %, con moda de 5 %. La fracción capturada del déficit evitado fue de 60 a 100 %, con moda de 100 %. El costo por kilómetro fue de $600 a $1.200, con moda de $975. El mantenimiento mayor fue de 1 a 2 veces el del caso base, y la inversión, de 0,9 a 1,5 veces, ambos con moda de 1. Estos rangos parten de los casos del Cuadro 22 y son supuestos declarados, pendientes de validar con Surtigas.

La Fig. 28 muestra el resultado. C obtuvo un VPN positivo en todas las repeticiones, con una mediana de $90,91 millones. Su intervalo de 90 % va de $40,66 a $134,79 millones, y el menor valor fue de $3,81 millones. D obtuvo un VPN negativo en todas, con un intervalo de −$248,06 a −$128,98 millones. El supuesto que más pesa es el crecimiento de la demanda, con una correlación de Spearman de 0,91 con el VPN de C. Este resultado no significa que el riesgo sea nulo, porque solo cubre los rangos declarados.

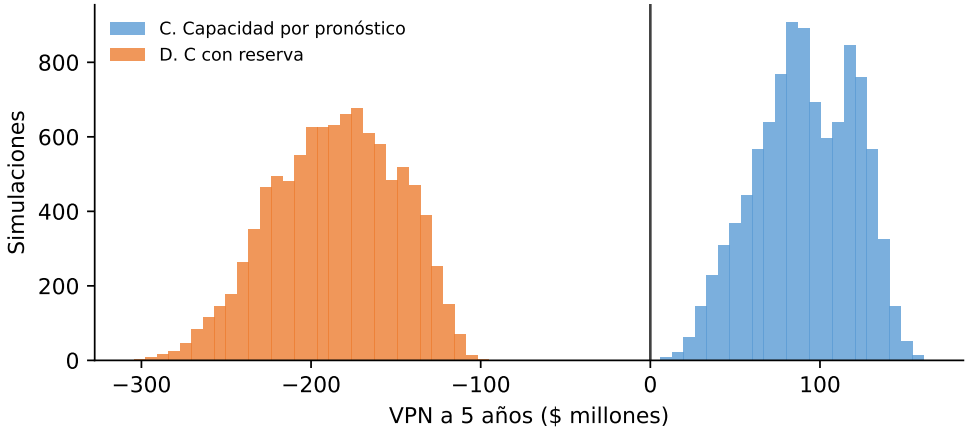


Figura 28. Distribución del VPN a cinco años de los escenarios C y D frente a la línea base, en 10 000 repeticiones de Monte Carlo. La línea vertical marca el VPN de cero.

El supuesto más influyente es el crecimiento de la demanda: sin él, el VPN de C bajaría a $73,55 millones. Si el esquema conservara solo el 80 % de la reducción del déficit, el VPN de C sería de $87,78 millones. Con un costo entre $600 y $1.200 por kilómetro, el VPN de C va de $87,72 a $106,35 millones. D no es viable en ningún caso. Se evaluó, además, el recargo dominical y festivo de la Ley 2466 de 2025 [35]. Ese recargo es del 90 % desde julio de 2026 y del 100 % desde julio de 2027. El caso base no incluye ese recargo en ningún escenario. Con él, el VPN de C sube a $101,98 millones, porque C programa menos turnos que A en domingos y festivos. El de D, en cambio, baja a $−221,54 millones. Por lo tanto, C es el escenario que equilibra rentabilidad y cumplimiento. D protege el cumplimiento a costa de la rentabilidad.

7.4. Discusión de los resultados económicos

La mayor parte del ahorro proviene del reparto por sectores. Esto sugiere que, en una operación reactiva, saber dónde ubicar las cuadrillas pesa más que afinar cuántas programar. El pronóstico aporta, en cambio, la anticipación de los días críticos.

Por último, la conveniencia de la cuadrilla de reserva depende del riesgo de sanción más que del costo de la hora extra. Por ello, reforzar la capacidad es una decisión más regulatoria que operativa. Estas comparaciones tienen un límite: los estudios citados analizan servicios médicos y eléctricos, con otra escala y otros datos.

8. Conclusiones y recomendaciones

El proyecto responde la pregunta de investigación con evidencia de un caso real. El registro de emergencias que Surtigas ya lleva basta para pronosticar la demanda del día siguiente con menos error que las referencias simples con que hoy programa la capacidad. Ese error puede traducirse, además, en horas de cuadrilla y en pesos, lo que lo convierte en un insumo para decidir. Así, el proyecto lleva a un distribuidor de gas un tipo de pronóstico que la literatura había aplicado a servicios médicos y eléctricos. También muestra que, bajo un protocolo sin fugas de información, la técnica pesa más que la ventana de entrada y que un modelo liviano como XGBoost es suficiente. La ZINB lo complementa con la probabilidad de cada nivel de demanda, y ambos modelos resultaron coherentes.

En la operación, la reducción del 34 % en el error equivale a unas 1468 h anuales menos de capacidad mal dimensionada. Su efecto más relevante está en los días críticos, que bajan de 94 a 61, porque en ellos una emergencia no controlada podría esperar más de una hora. Por su parte, en la simulación, el reparto de las cuadrillas por sectores reduce en 24 % las horas en déficit sin agregar personal. Con ambos cambios, la inversión se recupera en unos 22 meses. Ese resultado se mantuvo al variar a la vez los supuestos financieros en una simulación de Monte Carlo, aunque solo dentro de los rangos declarados.

Por ello, se recomienda a Surtigas, en primer lugar, programar la capacidad de cada día con el pronóstico y repartir las cuadrillas según la probabilidad de cada sector. Ambas medidas atacan el déficit sin aumentar la nómina. El reparto debe confirmarse con órdenes georreferenciadas, porque hoy se apoya solo en la parte de la demanda con barrio ubicado. El despliegue debe empezar por validar con la empresa las cifras de costo, construidas con su registro, con lo indicado por su personal y con supuestos declarados. El centro de control sería el responsable natural del uso diario, y la jefatura, de la capacidad y su costo. La LSTM y la BiLSTM pueden mantenerse como modelos retadores durante el monitoreo. Antes de agregar una cuadrilla de reserva, conviene estimar con el historial regulatorio la probabilidad de una sanción,

porque la reserva solo se justifica si esta supera el 3 %. Al entregar el tablero, se sugiere aplicar el cuestionario SUS al personal del centro de control y ajustar con sus respuestas los umbrales de las alarmas. Por último, conviene registrar el barrio en un campo estructurado, el tipo de evento del IRST de cada orden y la base y el turno de cada cuadrilla. Con ellos y el costo real de la hora de cuadrilla, se podrían afinar el reparto y la evaluación financiera.

9. Limitaciones e investigaciones futuras

Los resultados corresponden a la demanda registrada en Montería entre 2017 y 2026 y no deben generalizarse a otras ciudades sin revalidación. El registro recoge las emergencias que llegaron al centro de control y usa la fecha de registro, no la de ocurrencia, por lo que puede existir subregistro. El conjunto de prueba cubre un solo año. La diferencia entre el periodo de validación y el de prueba sugiere que el desempeño relativo de los modelos puede cambiar con el tiempo. Con un solo año de prueba, no es posible separar ese efecto de la variación aleatoria. Además, las horas en déficit tratan igual a las emergencias controladas, que admiten hasta 15 días, por lo que sobreestiman la atención que se debe dar el mismo día.

El análisis es diario y no ve la congestión dentro del día. Tampoco se evaluó el error a horizontes mayores de un día, por lo que la planeación mensual no cuenta con un pronóstico validado. Las restricciones contractuales y de turnos para variar las cuadrillas de un día a otro no se estudiaron. Si los turnos fueran rígidos, el pronóstico aún podría orientar las disponibilidades, las horas extra y la ubicación por sector. La carga automática del dato diario desde los sistemas de Surtigas tampoco se definió. Los umbrales de las alarmas son una propuesta, y el tablero aún no se ha evaluado con sus usuarios.

La dimensión geoespacial está limitada por el campo de barrio, que es texto libre. En el escenario de la sección 7.2.2, los barrios se ubicaron de forma aproximada con OpenStreetMap. Sus sectores deben contrastarse con el listado oficial de comunas de la Alcaldía de Montería. Ese escenario es una simulación que supone que las órdenes sin barrio se distribuyen como las identificadas. En el año de prueba, solo el 28 % de las órdenes quedó asignado de forma directa a su sector. Si se concentraran en la periferia, el resultado tendría un sesgo. Además, modela los traslados con la distancia esperada entre sectores y no considera el desplazamiento dentro de cada sector. Todas las órdenes tienen dirección en nomenclatura urbana o en formato de manzana y lote. Por lo tanto, georreferenciarlas permitiría asignar cada emergencia a su sector sin depender del campo de barrio.

La evaluación financiera supone cuadrillas de cuatro personas con el SMMLV, sin prestaciones sociales. La inversión se estimó con el salario de mercado de un analista de datos, y el costo por kilómetro es un supuesto declarado. La TMAR, en cambio, es la tasa regulatoria vigente ajustada con la inflación esperada. El caso base no incluye los recargos dominical, festivo y nocturno de la Ley 2466 de 2025. Su efecto se evaluó solo para el recargo dominical y festivo, en el análisis de sensibilidad. La simulación de Monte Carlo no incluye el costo de la hora ni la calidad de la asignación por sectores. Por eso, su intervalo no agota la incertidumbre del proyecto. La evaluación financiera también proyecta el crecimiento de la demanda y de los salarios y un mantenimiento mayor en el año 3 con supuestos declarados. Esos valores deben reemplazarse por los costos reales de Surtigas. El costo por incumplimiento supone un usuario afectado por emergencia, una tarifa tomada de una factura de Cartagena y un riesgo de sanción proporcional a las horas no cubribles. La probabilidad de sanción no pudo estimarse con datos y se evaluó como parámetro. El registro no incluye el número de usuarios conectados, por lo que el modelo no separa el crecimiento de la red del aumento de la demanda por usuario. El reajuste mensual puede absorber los cambios de nivel, pero no explica su causa.

Las investigaciones futuras pueden incorporar el número de usuarios y variables exógenas como la precipitación, y replicar el protocolo en otras ciudades atendidas por Surtigas. En cuanto a los modelos, conviene comparar SARIMA y ETS, que no se corrieron, y ajustar los hiperparámetros con validación cruzada temporal de varios orígenes. También conviene calcular la importancia de las variables de XGBoost, validar las redes con reajuste periódico y evaluar el reajuste con la receta del tablero. Un XGBoost cuantílico con $\tau = k/(k+1)$ o la predicción conformal unificarían el pronóstico y su intervalo. En la operación, un modelo de colas o una simulación por hora mediría la probabilidad de llegar en menos de una hora. Por último, faltan los pronósticos a 7 y 30 días y el diagrama BPMN del proceso rediseñado.

Referencias

[1] X. Wang, A. Li, Z. Lin, S. Li, and Y. Yang, "Natural gas transmission pipeline leak detection model based on acoustic emission and machine learning," *Journal of Pipeline Systems Engineering and Practice*, vol. 15, no. 4, p. 04024047, 2024.

[2] B. Rostami-Tabar and R. J. Hyndman, "Hierarchical time series forecasting in emergency medical services," *Journal of Service Research*, vol. 28, no. 2, pp. 278–295, 2024.

[3] R. J. Martin, R. Mousavi, and C. Saydam, "Predicting emergency medical service call demand: A modern spatiotemporal machine learning approach," *Operations Research for Health Care*, vol. 28, p. 100285, 2021.

[4] Comisión de Regulación de Energía y Gas (CREG), "Resolución 100 de 2003: por la cual se adoptan los estándares de calidad en el servicio público domiciliario de gas natural y GLP en sistemas de distribución por redes de tubería," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0100_2003.htm, 2003, vigente, modificada por las Resoluciones CREG 009 de 2005 y 005 de 2006 y complementada por la CREG 016 de 2006. Consultado el 8 de octubre de 2026.

[5]Surtigas S.A. E.S.P., "Historia," https://www.surtigas.co/historia, 2026, consultado el 4 de octubre de 2026.
[6]S. Studer, T. B. Bui, C. Drescher, A. Hanuschkin, L. Winkler, S. Peters, and K.-R. Müller, "Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology," *Machine Learning and Knowledge Extraction*, vol. 3, no. 2, pp. 392–413, 2021.
[7]J. A. Green, "Too many zeros and/or highly skewed? a tutorial on modelling health behaviour as count data with Poisson and negative binomial regression," *Health Psychology and Behavioral Medicine*, vol. 9, no. 1, pp. 436–455, 2021.
[8]C. X. Feng, "A comparison of zero-inflated and hurdle models for modeling zero-inflated count data," *Journal of Statistical Distributions and Applications*, vol. 8, no. 1, p. 8, 2021.
[9]F. Petropoulos, D. Apiletti, V. Assimakopoulos, M. Z. Babai, D. K. Barrow, S. Ben Taieb *et al.*, "Forecasting: theory and practice," *International Journal of Forecasting*, vol. 38, no. 3, pp. 705–871, 2022.
[10]C. Bentéjac, A. Csörgő, and G. Martínez-Muñoz, "A comparative analysis of gradient boosting algorithms," *Artificial Intelligence Review*, vol. 54, no. 3, pp. 1937–1967, 2020.
[11]G. Van Houdt, C. Mosquera, and G. Nápoles, "A review on the long short-term memory model," *Artificial Intelligence Review*, vol. 53, no. 8, pp. 5929–5955, 2020.
[12]B. Lindemann, T. Müller, H. Vietz, N. Jazdi, and M. Weyrich, "A survey on long short-term memory networks for time series prediction," *Procedia CIRP*, vol. 99, pp. 650–655, 2021.
[13]S. Siami-Namini, N. Tavakoli, and A. S. Namin, "The performance of LSTM and BiLSTM in forecasting time series," in *2019 IEEE International Conference on Big Data (Big Data)*, 2019, pp. 3285–3292.
[14]S. Kiranyaz, O. Avci, O. Abdeljaber, T. Ince, M. Gabbouj, and D. J. Inman, "1D convolutional neural networks and applications: A survey," *Mechanical Systems and Signal Processing*, vol. 151, p. 107398, 2021.
[15]N. K. Kitson, A. C. Constantinou, Z. Guo, Y. Liu, and K. Chobtham, "A survey of Bayesian network structure learning," *Artificial Intelligence Review*, vol. 56, no. 8, pp. 8721–8814, 2023.
[16]M. Schonlau and R. Y. Zou, "The random forest algorithm for statistical learning," *The Stata Journal: Promoting communications on statistics and Stata*, vol. 20, no. 1, pp. 3–29, 2020.
[17]N. V. S. Korlapati, F. Khan, Q. Noor, S. Mirza, and S. Vaddiraju, "Review and analysis of pipeline leak detection methods," *Journal of Pipeline Science and Engineering*, vol. 2, no. 4, p. 100074, 2022.
[18]D. Cerrai, M. Koukoula, P. Watson, and E. N. Anagnostou, "Outage prediction models for snow and ice storms," *Sustainable Energy, Grids and Networks*, vol. 21, p. 100294, 2020.
[19]H. T. Wong, "Forecasting daily emergency ambulance service demand using biometeorological indexes," *International Journal of Biometeorology*, vol. 67, no. 4, pp. 565–572, 2023.
[20]Allen Institute for AI, "Asta: asistente de investigación con inteligencia artificial," https://allenai.org/asta, 2025, consultado el 29 de octubre de 2026.
[21]N. Shahidian, P. Abreu, D. Santos, and A. P. Barbosa-Póvoa, "Short-term forecasting of emergency medical services demand exploring machine learning," *Computers & Industrial Engineering*, vol. 200, p. 110765, 2025.
[22]W. Balcazar-Quimi, C. Angulo, C. Cornejo, B. Salinas-Neira, J. Fernández-Bastías, M. Tupac-Yupanqui, and C. Vidal-Silva, "Chile-ED-Resp: A curated and reproducible weekly hospital dataset for respiratory emergency-demand forecasting in Chile," *Data*, vol. 11, no. 9, p. 229, 2026.
[23]R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne: OTexts, 2021. [Online]. Available: https://otexts.com/fpp3/
[24]S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "M5 accuracy competition: Results, findings, and conclusions," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1346–1364, 2022.
[25]H. Hewamalage, C. Bergmeir, and K. Bandara, "Recurrent neural networks for time series forecasting: Current status and future directions," *International Journal of Forecasting*, vol. 37, no. 1, pp. 388–427, 2021.
[26]S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023.
[27]H. Hewamalage, K. Ackermann, and C. Bergmeir, "Forecast evaluation for data scientists: common pitfalls and best practices," *Data Mining and Knowledge Discovery*, vol. 37, no. 2, pp. 788–832, 2022.
[28]Comisión de Regulación de Energía y Gas (CREG), "Resolución 067 de 1995: por la cual se establece el código de distribución de gas combustible por redes," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0067_1995.htm, 1995, texto compilado vigente, con modificaciones de las Resoluciones CREG 059 de 2012, 127 de 2013, 033 de 2015 y 240A de 2016; numerales 5.7 y 5.8 sin modificar. Consultado el 8 de octubre de 2026.
[29]Superintendencia de Servicios Públicos Domiciliarios (SSPD), "Informe de calidad de distribución del servicio público domiciliario de gas combustible por redes de tubería: vigencia 2024," https://www.superservicios.gov.co/sites/default/files/inline-files/Informe-de-calidad-de-distribucion-del-servicio-publico-domiciliario-de-gas-combustible-por-redes-de-tuberia-2024.pdf, 2026, Superintendencia Delegada para Energía y Gas, marzo de 2026. Consultado el 8 de octubre de 2026.
[30]Congreso de la República de Colombia, "Código sustantivo del trabajo," http://www.secretariasenado.gov.co/senado/basedoc/codigo_sustantivo_trabajo.html, 2026, texto compilado vigente. Límite de dos horas extra diarias y doce semanales; recargo del 25 % del trabajo extra diurno (art. 168). Consultado el 8 de octubre de 2026.
[31]M. Dumas, F. Fournier, L. Limonad, A. Marrella, M. Montali, J.-R. Rehse *et al.*, "AI-augmented business process management systems: A research manifesto," *ACM Transactions on Management Information Systems*, vol. 14, no. 1, pp. 1–19, 2023.
[32]D. C. Montgomery, *Design and Analysis of Experiments*, 10th ed. Hoboken, NJ: Wiley, 2020.
[33]M. Delacre, C. Leys, Y. L. Mora, and D. Lakens, "Taking parametric assumptions seriously: Arguments for the use of Welch's F-test instead of the classical F-test in one-way ANOVA," *International Review of Social Psychology*, vol. 32, no. 1, p. 13, 2019.
[34]D. I. Harvey, S. J. Leybourne, and Y. Zu, "Tests for equal forecast accuracy under heteroskedasticity," *Journal of Applied Econometrics*, vol. 39, no. 5, pp. 850–869, 2024.
[35]Congreso de la República de Colombia, "Ley 2466 de 2025: por medio de la cual se modifica parcialmente normas laborales y se adopta una reforma laboral para el trabajo decente y digno en Colombia," https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=260676, 2025, artículos 10, 13 y 14: trabajo nocturno desde las 7 p. m., límite de dos horas extra diarias y doce semanales, y recargo dominical y festivo gradual hasta 100 %. Consultado el 15 de octubre de 2026.
[36]OpenStreetMap contributors, "OpenStreetMap y servicio de geocodificación Nominatim," https://nominatim.openstreetmap.org, 2026, datos bajo licencia ODbL. Consultado el 7 de octubre de 2026.
[37]P. Reyes Bohórquez, "Una ciudad colombiana es la más congestionada del mundo, y no es ni Bogotá ni Medellín," https://www.elcarrocolombiano.com/?p=277442, 2025, El Carro Colombiano, 17 de enero de 2025. Datos del TomTom Traffic Index 2024 para Barranquilla.

[38]E. D. Saldivar-Carranza, J. Desai, A. Thompson, M. Taylor, J. Sturdevant, and D. M. Bullock, "Vehicle and pedestrian traffic signal performance measures using LiDAR-derived trajectory data," *Sensors*, vol. 24, no. 19, p. 6410, 2024.
[39]Congreso de la República de Colombia, "Ley 2101 de 2021: por medio de la cual se reduce la jornada laboral semanal de manera gradual," http://www.secretariasenado.gov.co/senado/basedoc/ley_2101_2021.html, 2021, jornada máxima de 42 horas semanales desde el 15 de julio de 2026. Consultado el 8 de octubre de 2026.
[40]Portafolio, "¿Va a tanquear? estas son las ciudades donde la gasolina y el ACPM están más caros desde octubre," https://www.portafolio.co/energia/va-a-tanquear-estas-son-las-ciudades-donde-la-gasolina-y-el-acpm-estan-mas-caros-desde-octubre-503652, 2026, precios de la Circular CREG 358 de 2026; ACPM en Montería: $11.506 por galón. Publicado el 30 de septiembre de 2026.
[41]U.S. Environmental Protection Agency and U.S. Department of Energy, "Fuel economy of the 2022 Chevrolet Colorado 2WD, 2.8 L diesel, automatic 6-speed," https://www.fueleconomy.gov/feg/noframes/44383.shtml, 2022, Rendimiento en ciudad de 20 millas por galón, unos 32 km por galón. Consultado el 19 de octubre de 2026.
[42]I. Shatnawi, N. Al Hosain, A. Muhsen, and L. Yaseen, "Impact of urban traffic on fuel consumption leveraging IoT data: Case study of Riyadh city," https://www.kapsarc.org/our-offerings/publications/impact-of-urban-traffic-on-fuel-consumption-leveraging-iot-data-case-study-of-riyadh-city, 2024, King Abdullah Petroleum Studies and Research Center (KAPSARC), 19 de diciembre de 2024.
[43]Comisión de Regulación de Energía y Gas (CREG), "Resolución 102 002 de 2023: por la cual se modifica la resolución CREG 103 de 2021," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_102-2_2023.htm, 2023, fija la tasa de descuento de 11,88 % en pesos constantes para la actividad de transporte de gas natural. Consultado el 15 de octubre de 2026.
[44]Congreso de la República de Colombia, "Ley 142 de 1994: por la cual se establece el régimen de los servicios públicos domiciliarios y se dictan otras disposiciones," https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=2752, 1994, texto compilado vigente. Artículo 81.2, multas de la Superintendencia de Servicios Públicos Domiciliarios; artículos 136 y 137, falla del servicio e indemnización no inferior al consumo de un día por cada día de falla. Consultado el 15 de octubre de 2026.
[45]Superintendencia de Servicios Públicos Domiciliarios (SSPD), "Resolución SSPD 20242400301975 del 25 de junio de 2024," https://www.superservicios.gov.co/sites/default/files/2024-07/Resolucion-SSPD-No.-20242400301975-del-25-de-junio-de-2024.pdf, 2024, aplica el numeral 81.2 de la Ley 142 de 1994 con un límite de 2000 salarios mínimos mensuales. Consultado el 15 de octubre de 2026.
[46]Corte Constitucional de Colombia, "Sentencia C-030 de 2021," https://www.corteconstitucional.gov.co/relatoria/2021/c-030-21.htm, 2021, declara inexequible el artículo 19 de la Ley 1955 de 2019, que modificaba el artículo 81 de la Ley 142 de 1994. Consultado el 15 de octubre de 2026.
[47]Unidad de Planeación Minero Energética (UPME), "Circular externa 000064 de 2023: ampliación de la información de costos de racionamiento de gas natural del estudio técnico del plan de abastecimiento de gas natural," https://www1.upme.gov.co/Hidrocarburos/publicaciones/Ampliacion_de_informacion_regiones.pdf, 2023, costos de racionamiento por regiones, entre ellas la Caribe. Consultado el 9 de octubre de 2026.
[48]Quantil, "Estimación costos de racionamiento: entregable 2, versión final," Unidad de Planeación Minero Energética (UPME), Bogotá, Tech. Rep., 2021, costo de un corte no programado de gas natural en el sector residencial de la región Caribe: $2.866,77/m^3 en el corto plazo. Consultado el 15 de octubre de 2026. [Online]. Available: https://docs.upme.gov.co/DemandayEficiencia/Doc_Hemeroteca/Informe_Final_Costos_Racionamiento_GN-GLP_Quantil_C-060-2021.pdf
[49]Surtigas S.A. E.S.P., "Factura del servicio de gas natural, usuario residencial estrato 4, Cartagena, periodo de junio de 2026," Documento físico emitido el 17 de junio de 2026, 2026, consumo de 33 m^3, tarifa aplicada de $2.687/m^3 y componente de confiabilidad igual a cero.
[50]M. Hyzy, R. Bond, M. Mulvenna, L. Bai, A. Dix, S. Leigh, and S. Hunt, "System usability scale benchmarking for digital health apps: Meta-analysis," *JMIR mHealth and uHealth*, vol. 10, no. 8, p. e37290, 2022.
[51]Levels.fyi, "Data analyst salary in Colombia," https://www.levels.fyi/t/data-analyst/locations/colombia, 2026, mediana de compensación anual de $34,9 millones. Consultado el 10 de octubre de 2026.
[52]Indeed, "Sueldos para data analyst en Colombia," https://co.indeed.com/career/data-analyst/salaries, 2026, promedio de $3.248.329 mensuales con 29 sueldos publicados. Consultado el 29 de octubre de 2026.