Analytical Model for the Characterization and Prediction of Emergency Demand in the Natural Gas Distribution Network of Montería, Colombia. Case Study: Surtigas

Germán Eduardo De Armas Castaño, Sebastián Enrique Delgado Solano,
Ángel Luis Vega Rodríguez, Victoria Sofía Ripoll Nieves

Universidad Tecnológica de Bolívar, Colombia
gdearmas@utb.edu.co, delgados@utb.edu.co, anvega@utb.edu.co, vripoll@utb.edu.co

Abstract. Surtigas handles the emergencies of its natural gas network in Montería reactively: crews are dispatched only after a user reports an incident. This study asks whether a predictive model trained on 50,195 emergency records (2017-2026) can reduce the error of the daily demand forecast compared with the reference methods. The CRISP-ML(Q) process model guided the work, with business process management as a cross-cutting framework. Seven techniques were trained under a leakage-free temporal protocol: XGBoost, LSTM, BiLSTM, a one-dimensional convolutional network and three count models (Poisson, negative binomial and zero-inflated negative binomial). Technique and input window were chosen with a 4×5 factorial experiment with three replicates on the validation block, and the test set was consulted once. The technique explained 59 % of the variation in validation error, while the window had no significant effect. XGBoost achieved the lowest validation error (MAE 5.46). On the test year its mean absolute error was 4.22 emergencies per day, 34 % lower than the best reference method (6.40). It was significantly better than the count models and the references, and not significantly different from the neural networks. Translated into crew time, the forecast reduces mis-sized crew hours by an estimated 1468 hours per year. In a simulated scenario, allocating crews across districts by their emergency probability cuts deficit hours by 24 % with the same staffing. When late responses are valued under current regulation, a reserve crew pays off only if the annual probability of a maximum regulatory fine exceeds 3,2 %. The zero-inflated model provides the probability of high-demand days, and a Bayesian network shows that holidays and weekends account for most of the low-demand days. The results support a planning scheme with daily forecasts and monthly retraining, to be integrated into a decision dashboard.

Keywords. emergency demand forecasting, natural gas distribution, count models, XGBoost, CRISP-ML(Q), Surtigas, Montería.

Modelo analítico para la caracterización y predicción de la demanda de emergencias en la red de distribución de gas natural de Montería, Colombia. Caso de estudio: Surtigas

Germán Eduardo De Armas Castaño, Sebastián Enrique Delgado Solano,
Ángel Luis Vega Rodríguez, Victoria Sofía Ripoll Nieves
Universidad Tecnológica de Bolívar, Colombia

Resumen. Surtigas atiende las emergencias de su red de gas natural en Montería de forma reactiva, ya que las cuadrillas se despachan solo después del reporte del usuario. En este contexto, el estudio evalúa si un modelo predictivo entrenado con 50 195 registros de emergencias (2017-2026) reduce el error del pronóstico diario frente a métodos de referencia. El trabajo siguió el modelo de proceso CRISP-ML(Q), con la gestión de procesos de negocio como marco transversal. Con base en él, se compararon siete técnicas bajo un protocolo temporal sin fugas de información. Cuatro de ellas son de aprendizaje automático: XGBoost, una red de memoria a corto y largo plazo (LSTM), su variante bidireccional (BiLSTM) y una red convolucional unidimensional. Las otras tres son modelos de conteo: Poisson, binomial negativa y su versión inflada en ceros. La técnica y la ventana de entrada se eligieron con un diseño factorial 4×5 con tres réplicas sobre el bloque de validación. El conjunto de prueba, en cambio, se reservó para una única evaluación final. La técnica explicó el 59 % de la variación del error de validación, mientras que la ventana no tuvo efecto significativo. XGBoost obtuvo el menor error de validación. En el año de prueba alcanzó un error absoluto medio de 4,22 emergencias por día, un 34 % menor que el del mejor método de referencia. Fue significativamente mejor que los modelos de conteo y las referencias, y sin diferencia significativa frente a las redes neuronales. Traducida a tiempo de cuadrilla, esa mejora equivale a unas 1468 horas anuales menos de dotación mal dimensionada. En un escenario simulado, repartir las cuadrillas entre sectores según la probabilidad de cada uno reduce en 24 % las horas en déficit con la misma dotación. Las emergencias atendidas fuera de la hora se valoraron con la regulación vigente. Con esa valoración, la cuadrilla de reserva solo conviene si la probabilidad anual de una sanción máxima supera el 3,2 %. Además, el modelo inflado en ceros estima la probabilidad de los días de alta demanda. Una red bayesiana, por su parte, indica que festivos y fines de semana concentran la mayor parte de los días de demanda baja. Por lo tanto, los resultados respaldan un esquema de planificación con pronóstico diario y reajuste mensual, integrado en un tablero de control.

Palabras clave. predicción de demanda de emergencias, distribución de gas natural, modelos de conteo, XGBoost, CRISP-ML(Q), Surtigas, Montería.

1. Introducción

La aplicación de la analítica de datos en redes de gas se ha concentrado en la detección física de fugas. Por ejemplo, se han propuesto modelos que detectan fugas en gasoductos a partir de señales de emisión acústica y aprendizaje automático [1]. Sin embargo, pocos estudios han abordado una pregunta distinta: cuántas emergencias llegarán cada día al centro de control del distribuidor. Ese pronóstico sí se ha desarrollado en los servicios médicos de emergencia, donde la demanda diaria de ambulancias se pronostica para planificar el personal y la flota [2], [3]. En cambio, no se encontró un trabajo equivalente para la distribución de gas en una ciudad intermedia de Colombia.

Esta brecha tiene consecuencias prácticas. En Colombia, la Comisión de Regulación de Energía y Gas (CREG) define los indicadores de calidad de la distribución de gas [4]. Uno de ellos es el índice de respuesta a servicio técnico (IRST). Este índice es el porcentaje de solicitudes atendidas dentro de un tiempo de referencia según el tipo de evento. Cumplirlo exige que haya cuadrillas disponibles cuando llega la demanda y, por lo tanto, conviene anticiparla.

Surtigas, fundada en 1968 en Cartagena, distribuye gas natural desde 1979 y en la década de 1990 extendió su red a 32 municipios de Bolívar, Sucre y Córdoba [5]. En Montería, la empresa conserva un registro de 50 195 emergencias atendidas entre 2017 y 2026. No obstante, ese registro se emplea hoy con fines descriptivos, y la asignación de cuadrillas comienza solo cuando el usuario reporta el incidente.

Con base en lo anterior, este trabajo propone un modelo analítico que caracteriza la demanda de emergencias y la pronostica con un día de anticipación. El desarrollo siguió el modelo de proceso CRISP-ML(Q) (*Cross-Industry Standard Process for Machine Learning with Quality assurance*) [6]. Además, se compararon siete técnicas mediante un diseño de experimentos, bajo un protocolo temporal sin fugas de información, y se estimó el beneficio operativo en horas de cuadrilla. Cada técnica evaluada responde a un rasgo de la demanda que el análisis exploratorio mostró en los datos.

El documento se organiza de la siguiente manera. La sección 2 revisa la literatura y presenta el marco teóri-

co, y la sección 3 plantea el problema y la pregunta de investigación. Las secciones 4 y 5 exponen los objetivos y la metodología, mientras que las secciones 6 y 7 presentan los resultados y el análisis costo-beneficio. La sección 7.2 desarrolla un escenario simulado de asignación de cuadrillas por sector, y la sección 7.5 valora el costo por incumplimiento del tiempo de atención. Por último, se exponen las conclusiones y las limitaciones del estudio.

2. Revisión de la literatura y marco teórico

2.1. Estado del arte

En las redes de gas, la mayor parte de los desarrollos con aprendizaje automático se orienta a la vigilancia de la infraestructura. Una revisión reciente recopila los métodos de detección de fugas en tuberías y analiza sus ventajas y limitaciones [7]. Estos sistemas buscan localizar amenazas físicas, pero no anticipan la carga de trabajo que esas amenazas generan para el operador.

El pronóstico de llegadas de emergencias, en cambio, cuenta con antecedentes en el sector salud. En Gran Bretaña, la demanda diaria de ambulancias se pronosticó por región, prioridad y tipo de incidente, con pronósticos puntuales y probabilísticos coherentes entre niveles [2]. Otros trabajos predicen la demanda de llamadas con aprendizaje automático espaciotemporal [3] o con índices biometeorológicos [8]. Estos antecedentes muestran que la demanda de emergencias tiene regularidades que permiten anticiparla, y orientaron la búsqueda de patrones de calendario en este trabajo.

En cuanto a los métodos, la regresión de Poisson es el punto de partida para modelar conteos. Cuando la varianza supera a la media se emplea la binomial negativa [9]. Cuando los ceros exceden lo esperado se recurre a los modelos inflados en ceros [10]. Para series de tiempo, los modelos autorregresivos integrados de media móvil (ARIMA) y su versión estacional (SARIMA) son la referencia clásica [11], [12]. Sin embargo, su forma lineal limita la captura de interacciones entre el calendario y los rezagos. Para capturar esas interacciones se emplean métodos no lineales, como los ensambles de árboles con gradiente, que dominaron competencias recientes de pronóstico [13], [14], y las redes recurrentes [15].

Por último, un aspecto que los estudios aplicados suelen omitir es el protocolo de evaluación. Elegir el modelo con el error del conjunto de prueba produce estimaciones optimistas de su desempeño [16]. Además, en series de tiempo la partición de los datos debe respetar el orden cronológico [12], [16]. En consecuencia, este trabajo aporta en dos frentes: aplica estos métodos a la demanda de emergencias de un distribuidor de gas y documenta un protocolo de selección sin fugas.

2.2. Marco teórico

2.2.1. Distribución de Poisson: La distribución de Poisson describe el número de eventos en un intervalo cuando ocurren de forma independiente y con tasa constante. Una variable X sigue una distribución de Poisson con parámetro $\lambda > 0$ si

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \qquad k = 0, 1, 2, \ldots \tag{1}$$

con $E[X] = \mathrm{Var}(X) = \lambda$. Esta igualdad, llamada equidispersión, rara vez se cumple en datos reales. En regresión, la media se vincula con las covariables mediante $\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$ [9].

2.2.2. Binomial negativa e inflación de ceros: La binomial negativa (BN) añade un parámetro de dispersión r, de modo que $\mathrm{Var}(Y) = \mu + \mu^2/r$ [9]. El modelo binomial negativo inflado en ceros (ZINB) mezcla un proceso que genera ceros estructurales, con probabilidad π_i, y un proceso BN [10]:

$$P(Y_i = y) = \begin{cases} \pi_i + (1-\pi_i)\, f_{\mathrm{BN}}(0 \mid \mu_i, r), & y = 0, \\ (1-\pi_i)\, f_{\mathrm{BN}}(y \mid \mu_i, r), & y > 0, \end{cases} \tag{2}$$

donde $\log(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$ y $\mathrm{logit}(\pi_i) = \mathbf{z}_i^\top \boldsymbol{\gamma}$. Su media es $(1-\pi_i)\mu_i$. La Fig. 1 compara las tres distribuciones con la misma media: la BN tiene colas más pesadas que la Poisson y la ZINB concentra además masa en el cero.

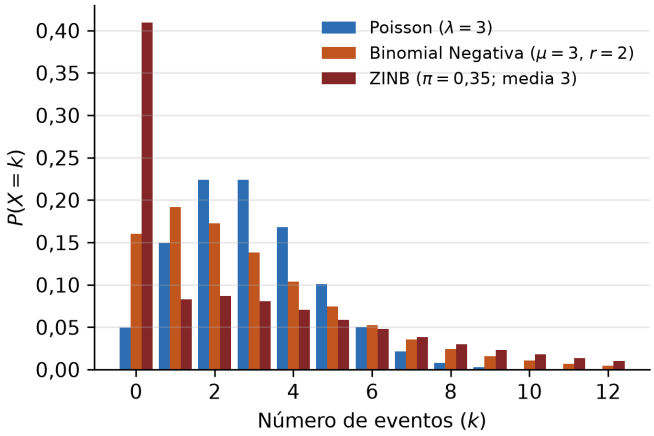


Figura 1. Distribuciones de Poisson, BN y ZINB con media igual a 3. Los parámetros son ilustrativos: la inflación de ceros ($\pi = 0{,}35$) se exageró para que se distinga, mientras que la estimada en los datos es cercana a 0,005.

2.2.3. Evaluación de distribuciones de conteo: Además del error puntual, un modelo de conteo se evalúa por la calidad de la distribución que predice. La log-verosimilitud negativa media (NLL) premia asignar alta probabilidad al valor observado. El puntaje de probabilidad continua ordenada (CRPS) compara toda la distribución predicha con la observación [12].

2.2.4. XGBoost: XGBoost (*extreme gradient boosting*) construye un pronóstico aditivo $\hat{y}_i = \sum_m f_m(\mathbf{x}_i)$ en el que cada árbol corrige los residuos del anterior [13]. Su función objetivo incluye la regularización $\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_j w_j^2$, que penaliza el número de hojas T y la magnitud de sus pesos w_j. Como no procesa secuencias, la dependencia temporal se incorpora con rezagos de la serie.

2.2.5. Redes LSTM y BiLSTM: Las redes recurrentes simples pierden la señal del error en secuencias largas [17]. La red de memoria a corto y largo plazo (LSTM) mitiga ese problema con compuertas de olvido, entrada y salida [17], [18]. La variante bidireccional (BiLSTM) recorre la ventana en ambos sentidos [19]. En este trabajo la ventana solo contiene días anteriores al día pronosticado, por lo que la lectura bidireccional no introduce información futura.

2.2.6. Red convolucional unidimensional: La red convolucional unidimensional (1D-CNN) aplica filtros sobre el eje temporal y extrae patrones locales de la serie [20].

2.2.7. Red bayesiana y bosque aleatorio: Una red bayesiana (RB) representa la distribución conjunta de variables discretas mediante un grafo acíclico dirigido y permite consultar la probabilidad de una variable dadas otras [21]. El bosque aleatorio promedia árboles de decisión entrenados sobre submuestras [22]; aquí se usó para imputar tiempos de respuesta y para pronosticarlos.

3. Planteamiento del problema y preguntas de investigación

3.1. Generalidades del sector y de la empresa

La distribución de gas natural por redes en Colombia está regulada por la CREG y vigilada por la Superintendencia de Servicios Públicos Domiciliarios (SSPD). Este trabajo se ajusta al marco vigente en 2026, que combina dos normas. La primera es el Código de Distribución de Gas Combustible por Redes, adoptado con la Resolución CREG 067 de 1995 [23]. Las Resoluciones CREG 059 de 2012, 127 de 2013, 033 de 2015 y 240A de 2016, entre otras, modificaron este código. Esos cambios tocaron la puesta en servicio, la medición, la facturación y el cálculo de pérdidas. Su numeral 5.7, sin embargo, conserva el texto original y fija en una hora el tiempo máximo entre el reporte de una emergencia y la llegada del equipo. Además, el numeral 5.8 obliga a registrar todas las emergencias con su causa y su correctivo, y un registro de ese tipo es la fuente de datos de este trabajo. La segunda es la Resolución CREG 100 de 2003, modificada por las Resoluciones CREG 009 de 2005 y 005 de 2006 y complementada por la CREG 016 de 2006 [4]. Esta norma define el IRST como el porcentaje de solicitudes atendidas dentro del tiempo de referencia de su tipo de evento. Los tipos de evento son escape de gas, incendio, calidad de la llama e interrupción del servicio.

Sin embargo, la CREG no ha fijado esos tiempos de referencia por tipo de evento. Por ello, la SSPD evalúa el IRST con el límite de una hora del Código de Distribución y solo para los incendios [24]. En 2024, el cumplimiento nacional de ese indicador en gas natural fue del 99,3 %. En consecuencia, este trabajo toma una hora como tiempo de referencia para la atención de emergencias. Ese tiempo depende, entre otros factores, de que haya cuadrillas disponibles cuando llega la solicitud.

Surtigas atiende la región Caribe colombiana y opera en Montería, capital de Córdoba [5]. Su centro de control recibe las solicitudes, asigna una cuadrilla y registra las marcas de tiempo de asignación, llegada, control y finalización de cada orden.

3.2. Identificación del problema

La operación es reactiva: la asignación de cuadrillas empieza con el reporte del usuario. Sin embargo, la demanda no es estable. El promedio diario pasó de 12,1 emergencias en 2017 a 20,2 en 2024, y un lunes registra en promedio 4,4 veces la demanda de un domingo. Si la dotación se planifica con promedios fijos, los días de alta demanda quedan con déficit de cuadrillas y los de baja demanda con capacidad ociosa. El registro histórico contiene la información necesaria para anticipar esa variación, pero no se ha empleado con ese fin.

3.3. Pregunta de investigación

¿En qué medida un modelo predictivo entrenado con el registro de emergencias de Surtigas en Montería reduce el error del pronóstico diario frente a los métodos de referencia?

4. Objetivo general y objetivos específicos

4.1. Objetivo general

Desarrollar un modelo analítico predictivo para caracterizar y proyectar la demanda operativa de emergencias en la infraestructura de gas natural de Montería.

4.2. Objetivos específicos

OE1. Realizar un análisis exploratorio de datos (EDA) del registro histórico de emergencias operativas, con el fin de identificar sus patrones espacio-temporales y establecer la línea base del estudio.

OE2. Comparar técnicas estadísticas y de aprendizaje automático mediante un diseño de experimentos con validación temporal, para seleccionar el modelo de pronóstico de menor error.

OE3. Evaluar el beneficio operativo del modelo seleccionado mediante un análisis costo-beneficio a partir de la reducción de horas de cuadrilla mal asignadas.

OE4. Integrar los pronósticos y sus indicadores en un tablero interactivo, como herramienta de apoyo a la toma de decisiones del Centro de Control de Surtigas.

5. Metodología

El trabajo siguió el modelo de proceso CRISP-ML(Q), que organiza un proyecto de aprendizaje automático en seis fases. A cada fase le asocia tareas de aseguramiento de la calidad [6]. La Fig. 2 relaciona esas fases con los objetivos específicos, y las subsecciones siguientes describen cómo se aplicó cada una.

5.1. Marco conceptual transversal: gestión de procesos de negocio

Mientras CRISP-ML(Q) guía la construcción del modelo, la gestión de procesos de negocio (BPM, por sus siglas en inglés) aporta el marco para integrarlo a la operación. BPM entiende la mejora como un ciclo que identifica,



Figura 2. Fases de CRISP-ML(Q) aplicadas al proyecto, con la gestión de procesos de negocio (BPM) como marco conceptual transversal, y su relación con los objetivos específicos.

analiza, rediseña, implementa y monitorea los procesos de una organización [25].

En este trabajo, BPM actúa de forma transversal sobre el proceso de atención de emergencias, que va desde la recepción de la solicitud hasta el cierre de la orden. El análisis del proceso actual se apoya en las marcas de tiempo del registro, que reflejan una asignación reactiva de cuadrillas. El rediseño consiste en anteponer una etapa de planificación, en la que la dotación diaria se ajusta al pronóstico. Por último, el análisis costo-beneficio del OE3 mide el efecto de ese rediseño, y el tablero interactivo del OE4 cumple la función de monitoreo del ciclo.

5.2. Comprensión del negocio y de los datos

La primera fase definió el problema operativo y su indicador regulatorio, el IRST. A partir de ella se realizó el EDA del OE1. Primero se auditó la calidad del registro. Después se examinaron la tendencia de la demanda, su estacionalidad semanal, mensual y horaria, las causales, los barrios, la dependencia temporal, la dispersión del conteo y los tiempos de respuesta. En todas las pruebas se usó un nivel de significancia de 0,05: un valor p menor indica que el resultado difícilmente se explica por azar. La estacionariedad se contrastó con dos pruebas de hipótesis opuestas [11]. La prueba de Dickey-Fuller aumentada (ADF) parte de que la serie tiene raíz unitaria, es decir, de que cada choque cambia su nivel de forma permanente. La de Kwiatkowski, Phillips, Schmidt y Shin (KPSS) parte de lo contrario: que la serie fluctúa alrededor de un nivel fijo. Su combinación indica si un promedio histórico fijo sirve para pronosticar o si hay que usar el nivel reciente. El efecto del calendario se evaluó con la prueba de Kruskal-Wallis [26]. Esta prueba compara la demanda de varios grupos de días sin suponer una distribución normal, que los conteos no siguen. La dependencia temporal se evaluó con la autocorrelación y la prueba de Ljung-Box [11]. Esta última indica si, en conjunto, las autocorrelaciones difieren de cero, es decir, si los días previos ayudan a pronosticar.

La relación entre las variables categóricas de la serie diaria se evaluó con la prueba chi-cuadrado de independencia. Esta prueba contrasta si la distribución de una variable cambia según las categorías de otra. La intensidad de la relación se midió con la V de Cramér, con corrección de sesgo, que va de 0 (independencia) a 1 (asociación perfecta). En los pares de variables binarias se usó además el coeficiente Phi, que indica también el sentido de la relación. Cuando las dos variables son ordinales, como el año y el nivel de demanda, se estimó la correlación policórica. Esta medida supone que cada variable ordinal agrupa en categorías una variable continua normal y estima la correlación entre ambas. Cada hallazgo del EDA se vinculó con una técnica candidata, de modo que la selección de técnicas partiera de los datos.

5.3. Ingeniería de datos

La Fig. 3 resume la preparación de los datos.

El registro original contenía 50 198 órdenes y 32 columnas. De ellas se eliminaron 3 con fecha de 1970, producto de errores de carga, y se corrigió una orden que cruzaba la medianoche. Las 880 órdenes con tiempo de respuesta negativo se conservaron y su tiempo se imputó con un bosque aleatorio. Ese modelo se evaluó en las órdenes

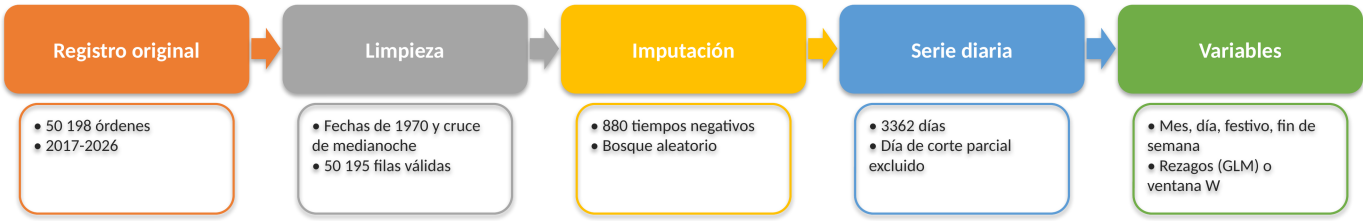


Figura 3. Flujo de preparación de los datos, desde el registro original hasta las variables de los modelos. Los rezagos de 1 y 7 días y la media móvil se usan en los modelos de conteo. XGBoost y las redes reciben la ventana de los W días anteriores.

posteriores al 3 de octubre de 2024, que no se usaron para ajustarlo. En ellas obtuvo un error absoluto medio (MAE) de 1,06 h, frente a 1,14 h de la mediana por año y tipo de emergencia. Esta validación es independiente del pronóstico de tiempos de respuesta de la sección 6, que emplea otra partición y otra referencia.

Con los datos depurados, la serie diaria se construyó contando las emergencias por fecha de registro y asignando cero a los días sin registros. Se excluyó el último día del extracto (18 de marzo de 2026), que termina a las 17:05 con 13 registros cuando un miércoles promedia 22. Así, la serie final abarca 3362 días, del 2 de enero de 2017 al 17 de marzo de 2026, y suma 50 182 emergencias.

Como variables de entrada se emplearon el mes y el día de la semana, en codificación cíclica, junto con los indicadores de festivo nacional y de fin de semana. Los modelos de conteo incorporan además los rezagos de 1 y 7 días y la media móvil de los 7 días previos, que excluye el día pronosticado. Todas las variables se escalaron con el mínimo y el máximo del bloque de entrenamiento.

5.4. *Ingeniería del modelo*

A partir del estado del arte se seleccionaron siete técnicas, cuatro de aprendizaje automático y tres modelos de conteo. XGBoost se configuró con 500 árboles, una tasa de aprendizaje de 0,03 y una profundidad máxima de 5. Las redes LSTM y BiLSTM tienen dos capas recurrentes de 64 y 32 unidades con abandono del 20 %. La 1D-CNN, en cambio, tiene dos capas convolucionales de 64 y 32 filtros. Las tres redes minimizan el error absoluto, y las cuatro técnicas reciben como entrada una ventana de los W días anteriores, con $W \in \{10, 20, 30, 40, 50\}$.

Los modelos de conteo son modelos lineales generalizados (GLM) Poisson, BN y ZINB con enlace logarítmico, estimados por máxima verosimilitud. Como punto de comparación se emplearon cuatro métodos de referencia. Dos repiten la demanda pasada: la del día anterior o la del mismo día de la semana anterior. Los otros dos la resumen con la mediana o la media móvil de 7 días.

Los supuestos de los GLM se verificaron con el bloque de entrenamiento. La equidispersión de la Poisson se contrastó con la razón entre el estadístico chi-cuadrado de Pearson y sus grados de libertad, que vale 1 si se cumple. También se aplicó la prueba de Cameron y Trivedi, una regresión auxiliar que estima si la varianza crece más rápido que la media. La necesidad del parámetro de dispersión de la BN se evaluó con una prueba de razón de verosimilitud. El exceso de ceros se evaluó con los ceros que espera cada familia y con la prueba de Vuong entre la ZINB y la BN. La independencia de las observaciones se contrastó con la prueba de Ljung-Box sobre los residuos de Pearson. La forma del enlace logarítmico se evaluó con la prueba de enlace de Pregibon, que agrega al modelo el cuadrado del predictor lineal. Por último, la multicolinealidad se midió con el factor de inflación de la varianza (VIF).

5.5. *Evaluación*

La Fig. 4 resume el protocolo de evaluación. La serie se dividió en orden cronológico. El 80 % se destinó a entrenamiento (2689 días, hasta el 13 de mayo de 2024). El 10 % se destinó a validación (336 días, hasta el 14 de abril de 2025). El resto se reservó para prueba: 336 días, del 16 de abril de 2025 al 17 de marzo de 2026. El día intermedio quedó como frontera y no se usó como objetivo.

Cada modelo se ajustó con el bloque de entrenamiento. La parada temprana (*early stopping*) de las redes y de XGBoost se aplicó sobre el último 10 % de ese bloque. Así, la validación no intervino en el ajuste.

La técnica y la ventana se eligieron con un diseño factorial completo 4×5 con tres réplicas [26]. El factor A es la técnica de aprendizaje automático, con cuatro niveles, y el factor B es la ventana W, con cinco niveles. Las réplicas son tres semillas aleatorias, para un total de 60 corridas, y la variable de respuesta es el MAE de validación. Los efectos se contrastaron con un análisis de varianza (ANOVA) de dos factores. Este análisis indica qué parte de la variación del error se debe a la técnica, a la ventana o a su interacción. Sus supuestos se verificaron con la prueba de Shapiro-Wilk, que contrasta la normalidad de los residuos, y con la de Levene, que contrasta la igualdad de sus varianzas. Como respaldo, el efecto de la técnica se contrastó también con dos pruebas que relajan esos supuestos. La de Kruskal-Wallis no requiere normalidad, y el ANOVA de Welch no requiere igualdad de varianzas [27]. Las técnicas se compararon por pares con la prueba de Tukey, que controla el error de hacer varias comparaciones

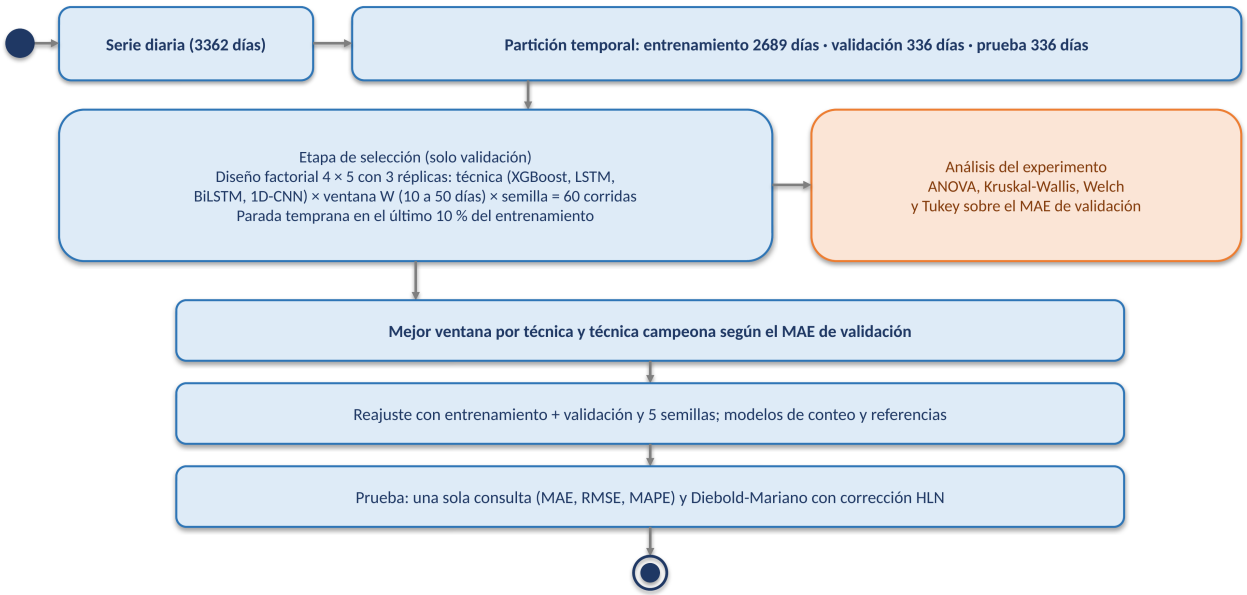


Figura 4. Protocolo experimental: partición temporal, diseño factorial sobre validación, reajuste con cinco semillas y prueba única.

a la vez. Los modelos de conteo, al ser deterministas, se compararon directamente por su MAE de validación.

Solo después de esta selección, la combinación ganadora de cada técnica se reajustó con entrenamiento y validación, usando cinco semillas, y el conjunto de prueba se consultó una única vez. Este orden evita el sesgo de selección que se produce al elegir con el conjunto de prueba [16]. Las diferencias de prueba entre XGBoost y los demás modelos se contrastaron con la prueba de Diebold-Mariano sobre la pérdida absoluta [16]. Esta prueba compara, día a día, los errores absolutos de dos modelos y determina si la diferencia media entre ellos puede deberse al azar. Se aplicó la corrección para muestras pequeñas de Harvey, Leybourne y Newbold (HLN), base de las variantes recientes de esta prueba [28]. Para cada técnica de aprendizaje automático se usó el promedio de las predicciones de sus cinco semillas.

El desempeño se midió con tres métricas: el MAE, la raíz del error cuadrático medio (RMSE) y el error porcentual absoluto medio (MAPE), definidas como

$$\mathrm{MAE} = \frac{1}{n}\sum_{t}|\hat{y}_t - y_t|, \quad \mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{t}(\hat{y}_t - y_t)^2}, \tag{3}$$

$$\mathrm{MAPE} = \frac{100}{n^{+}}\sum_{t:\, y_t>0}\frac{|\hat{y}_t - y_t|}{y_t}. \tag{4}$$

El MAPE se calcula sobre los n^{+} días con demanda positiva. En los GLM se calcularon además la NLL, el CRPS y la cobertura del intervalo de predicción de 80 %. Para comprobar la estabilidad del modelo en producción, XGBoost y los GLM se reajustaron cada 30 días con toda la historia previa, en una validación con origen móvil [16].

El pronóstico también se evaluó como clasificación en tres niveles de demanda, definidos con los terciles del bloque de entrenamiento. Para ello se calculó un costo ordinal $C_{ij} = |i - j|$ y una variante asimétrica que duplica el peso de la subestimación. Como complemento explicativo, se aprendió una RB con búsqueda voraz y puntaje BDeu sobre el mes, el día de la semana, el festivo y el nivel de demanda [21].

Por último, los tiempos de respuesta se pronosticaron por orden, con una partición por fecha (entrenamiento hasta el 30 de abril de 2024) y solo con órdenes de tiempo real. En este caso se compararon la mediana por tipo de emergencia, el bosque aleatorio, el *gradient boosting* de histogramas y XGBoost. Ambos pronósticos se evaluaron también por tipo de emergencia, porque solo las no controladas comprometen la seguridad y el límite de una hora. Para la demanda de no controladas se comparó un XGBoost entrenado con esa serie con el reparto del pronóstico total según la proporción histórica de cada tipo.

5.6. *Análisis costo-beneficio*

Para el OE3, el beneficio del pronóstico se midió primero en horas de cuadrilla y después en pesos colombianos (COP). El análisis tiene cuatro partes. La primera son las horas mal dimensionadas por el pronóstico, y la segunda, su efecto en un escenario simulado de asignación por sector. Las otras dos son la evaluación financiera de ese escenario y el costo por incumplimiento y por confiabilidad.

5.6.1. Horas en déficit y horas ociosas: Sea $\bar{h}$ el tiempo tipo de atención, es decir, el tiempo que una cuadrilla necesita para atender una emergencia, desde la asignación hasta la finalización de la orden. El registro no permite un estudio de tiempos con valoración del ritmo y suplementos, por lo que el tiempo tipo se estimó con la mediana de los tiempos registrados. A diferencia de la media, la mediana

no se deja arrastrar por las órdenes atípicas de larga duración. Si el día t se planifica para $\hat{y}_t$ emergencias y ocurren y_t, la capacidad preparada es $\bar{h}\hat{y}_t$ horas y la demanda exige $\bar{h}y_t$. Las horas en déficit son el trabajo de emergencias que excede la capacidad planificada. Las horas ociosas, en cambio, son capacidad planificada que no recibe emergencias. En un periodo de n días,

$$\begin{aligned} H_D &= \bar{h}\sum_{t=1}^{n} \max(0,\, y_t - \hat{y}_t), \\ H_O &= \bar{h}\sum_{t=1}^{n} \max(0,\, \hat{y}_t - y_t), \end{aligned} \tag{5}$$

y el total de horas mal dimensionadas es

$$H = H_D + H_O = \bar{h}\sum_{t=1}^{n} |\hat{y}_t - y_t|. \tag{6}$$

Las dos clases de horas tienen consecuencias distintas. Una hora en déficit obliga a esperar, a trasladar una cuadrilla o a pagar horas extra, y pone en riesgo el límite de una hora del IRST. Una hora ociosa es capacidad pagada sin emergencias, que puede destinarse a otras labores, como revisiones.

Dado que la empresa no emplea un pronóstico, el escenario actual se representó con la media móvil de 7 días, que equivale a planificar con el promedio reciente. El escenario propuesto usa el pronóstico del modelo campeón, y ambos se evaluaron sobre el año de prueba. Las horas ahorradas, $\Delta H = H^{\text{act}} - H^{\text{prop}}$, se descompusieron en horas en déficit (ΔH_D) y horas ociosas (ΔH_O). Las cifras de los 336 días de prueba se anualizaron con el factor 365/336.

5.6.2. Indicadores operativos: Además de H_D, H_O y su reducción porcentual, se calcularon tres indicadores operativos. Los turnos equivalentes expresan las horas ahorradas en turnos de 8 h. Los días críticos son aquellos en que la demanda supera al pronóstico en más de 5 emergencias. Por último, el punto de equilibrio es la dotación diaria con la que las horas en déficit igualan a las horas ociosas, es decir, la intersección de ambas curvas. Como las cuadrillas no se pueden fraccionar, ese valor se redondea hacia arriba al entero siguiente. Con menos cuadrillas predomina el déficit, y con más, la capacidad ociosa. La forma de ambas curvas se interpretó con la productividad marginal de la cuadrilla, definida como las horas en déficit que evita cada cuadrilla adicional. Todas las cuadrillas aportan la misma capacidad, un turno de 8 h por día. Lo que cambia es la parte de esa capacidad que atiende emergencias y la parte que queda ociosa.

La legislación laboral limita las horas extra a dos diarias y doce semanales por trabajador, límite que la reforma laboral de 2025 mantuvo [29], [30]. Por ello, el déficit de un día que excede dos horas por cuadrilla activa se consideró no cubrible con horas extra. Este indicador aproxima el trabajo que no podría atenderse ese día sin incumplir la norma laboral.

5.6.3. Costos y evaluación financiera: El costo de una hora de cuadrilla se calculó como

$$c_h = \frac{P\,S}{H_m}, \tag{7}$$

donde P es el número de personas por cuadrilla, S el salario mensual de cada una y H_m las horas ordinarias del mes. Las cuadrillas de Surtigas tienen entre 3 y 4 personas, y se tomó el caso conservador de $P = 4$. Cada trabajador devenga el salario mínimo legal mensual vigente (SMMLV) de 2026, de \$1 750 905. Con la jornada de 42 horas semanales vigente desde julio de 2026, $H_m = 210$ h [31]. El costo anual de la dotación de un escenario es

$$C = \frac{365}{336}\left(8\,c_h\,T + 1{,}25\,c_h\,D + c_{km}\,L\right), \tag{8}$$

donde T es el número de turnos de 8 h del año de prueba, D las horas en déficit y L los kilómetros recorridos en traslados entre sectores. El factor 1,25 corresponde al recargo del 25 % de la hora extra diurna [29], [30], con la que se cubre el déficit. Las horas ociosas no suman costo, porque ya están pagadas en la nómina. El cálculo excluye las prestaciones sociales y los aportes del empleador. Esos rubros elevarían en una proporción parecida la nómina y las horas extra, por lo que no cambiarían el orden de los escenarios.

El costo por kilómetro, $c_{km} = 975$ COP, corresponde a una camioneta diésel. En octubre de 2026, el galón de ACPM costaba 11 506 COP en Montería [32], y una camioneta de este tipo recorre unos 38 km por galón en ciudad [33]. El combustible representa, así, unos 300 COP/km en circulación fluida. En tráfico de arranque y frenado, la congestión aumenta el consumo hasta en 29 % [34]. Por eso, el costo del combustible se elevó un 25 %, hasta unos 375 COP/km. Los 600 COP/km restantes cubren llantas, mantenimiento y desgaste. Como ese componente es incierto, el análisis de sensibilidad evaluó también 600 y 1200 COP/km.

El flujo neto del año j de un escenario es la reducción de su gasto frente a la línea base: $F_j = C_{A,j} + M_{A,j} - C_{X,j} - M_{X,j}$. En ella, M agrupa el mantenimiento mayor y la operación del sistema. La inversión inicial, I_0, tiene dos componentes (Cuadro 1). El primero es la creación del modelo, en la que dos personas dedican 8 h semanales durante 32 semanas. Esas horas se valoraron con el salario de un analista de datos, de 3 000 000 COP mensuales, cercano a la mediana del mercado colombiano en 2026 [35]. Para que su valor hora sea comparable con el de las cuadrillas, el salario se dividió también entre 210 h. El segundo componente es la marcha blanca, un mes de nómina de la línea base. Durante ese mes, el esquema propuesto opera en paralelo con el actual mientras se calibra. La operación del sistema cuesta 599 900 COP al año por la licencia de Office 365, porque el editor de código, Visual Studio Code, es gratuito. El cómputo no agrega costos relevantes, porque el reajuste mensual del modelo tarda segundos en un computador personal.

Cuadro 1
Desglose de la inversión inicial y de los costos anuales de operación del sistema

Concepto	Cálculo	COP
Valor hora del analista de datos	3 000 000 / 210 h	14 285,71
Creación del modelo	2 personas × 8 h/semana × 32 semanas = 512 h	7 314 285,71
Marcha blanca	Un mes de nómina de A	30 577 312,60
Inversión inicial		**37 891 598,32**
Office 365	Costo anual	599 900,00
Editor de código (VS Code)	Costo anual	0

Precios de 2026. Los costos anuales se aplican a B, C y D, indexados con la inflación esperada.
Fuente: elaboración propia.

Los flujos no se suponen constantes, porque cuatro factores cambian de un año a otro. Primero, los salarios crecen un 5 % anual, que corresponde a la meta de inflación del 3 % más un ajuste del SMMLV de dos puntos. Segundo, la demanda crece un 5,42 % anual, la tasa de crecimiento compuesta de la serie entre 2017 y 2025. Cada año se recalculan entonces las horas en déficit y ociosas de cada escenario. La evaluación compara la operación con el proyecto y sin él, y no antes y después. Sin el proyecto, la empresa seguiría reaccionando a la demanda observada y ajustaría su dotación. Por eso, A y B escalan la dotación observada con el crecimiento de la demanda, mientras que C y D la ajustan con el pronóstico. Tercero, en el año 3 se incluye un mantenimiento mayor de los equipos y vehículos de cada dotación, equivalente a un mes de su nómina. La operación del sistema, en cambio, se paga cada año y se indexa con la inflación. Cuarto, la eficiencia del esquema se supone constante, porque el reajuste mensual mantiene el error del modelo. Su efecto se evaluó, junto con los demás supuestos, en un análisis de sensibilidad.

Los flujos se descontaron con una tasa mínima atractiva de rendimiento (TMAR) de $i = 15{,}24\,\%$ efectiva anual, en un horizonte de $N = 5$ años. Esta TMAR proviene de la tasa regulatoria vigente. La CREG fijó para el transporte de gas natural una tasa de descuento de 11,88 % en pesos constantes [36]. Como los flujos están en pesos corrientes, esa tasa se ajustó con la inflación esperada del 3 %. Todos los indicadores financieros de este trabajo usan esa tasa ajustada. Con ellos se calcularon el valor presente neto (VPN) y el valor anual equivalente (VAE):

$$\begin{aligned} \mathrm{VPN} &= -I_0 + \textstyle\sum_{j=1}^{N} F_j\,(1+i)^{-j}, \\ \mathrm{VAE} &= \mathrm{VPN}\,\frac{i}{1-(1+i)^{-N}}. \end{aligned} \tag{9}$$

El VPN es la ganancia del proyecto expresada en pesos de hoy, y el VAE la reparte en cuotas anuales iguales. La tasa interna de retorno (TIR) es la tasa i con la que el VPN se anula. La relación beneficio-costo (B/C) divide el valor presente de los flujos positivos entre el de los negativos, incluida la inversión. Por último, el periodo de recuperación de la inversión (PRI) es el tiempo, en meses, que tarda el flujo descontado acumulado en volverse positivo de forma definitiva. Un escenario es viable si su VPN es positivo, su TIR supera la TMAR y su B/C es mayor que 1.

5.6.4. Costo por incumplimiento y costo por confiabilidad: La ecuación (8) valora el déficit con la hora extra que lo cubre. Sin embargo, el déficit no cubrible no puede atenderse dentro del límite legal de horas extra. Corresponde, por tanto, a emergencias que no se atienden dentro de la hora y que incumplen el IRST. La Resolución CREG 100 de 2003 fija en 100 % el valor de referencia de ese indicador, pero no establece una compensación propia por incumplirlo [4]. Por ello, su costo se estimó con tres elementos que sí tienen respaldo normativo.

El primero es la indemnización al usuario. Según la Ley 142 de 1994, la falla del servicio da derecho a una indemnización [37]. Esta no puede ser menor que el consumo de un día del usuario afectado por cada día de falla total. El segundo es la exposición regulatoria. La SSPD puede imponer a los prestadores multas de hasta 2000 SMMLV, según la naturaleza y la gravedad de la falta [37], [38]. Ese tope rige porque la Corte Constitucional declaró inexequible el artículo de la Ley 1955 de 2019 que lo elevaba [39]. El tercero es el costo por confiabilidad, es decir, el valor que la sociedad asigna al gas que el usuario deja de recibir. La fórmula tarifaria vigente incluye un componente de confiabilidad, pero lo fija en cero mientras la CREG define su metodología [40]. La CREG sometió a consulta nuevas fórmulas tarifarias [41]. Ese proyecto aún no está en firme y tampoco incluye un componente de confiabilidad, por lo que el supuesto se mantiene. La CREG fija, además, un costo de interrupción para compensar a los usuarios [42]. Ese valor, sin embargo, está expresado en pesos de octubre de 2004 y se actualiza con el índice de precios del productor. Por ello, el costo por confiabilidad se valoró con el costo de racionamiento estimado para la UPME en el sector residencial de la región Caribe [43], [44].

Si D_x^{nc} son las horas no cubribles del escenario x en el año de prueba, el número anual de emergencias atendidas fuera de la hora se aproximó como

$$N_x^{nc} = \frac{365}{336}\,\frac{D_x^{nc}}{\bar{h}}. \tag{10}$$

Con ello, el costo anual por incumplimiento es

$$C_x^{inc} = c_{ind}\,u\,N_x^{nc} + p_x\,M_s, \qquad p_x = p_0\,\frac{D_x^{nc}}{D_A^{nc}}, \tag{11}$$

donde c_{ind} es la indemnización mínima por usuario y u el número de usuarios afectados por emergencia. M_s es la multa máxima, y p_0, la probabilidad anual de recibirla en la línea base. El riesgo de sanción de cada escenario se supuso proporcional a sus horas no cubribles. El costo por confiabilidad es

$$C_x^{conf} = CR\,DP_h\,t_f\,u\,N_x^{nc}, \tag{12}$$

donde CR es el costo de racionamiento, DP_h la demanda horaria promedio de un usuario y t_f el tiempo sin servicio por emergencia. Este costo es social y no un gasto de la

empresa, por lo que no entra en los flujos. Su función es acotar el peso k de la sección 5.7. Como cada hora en déficit equivale a $1/\bar{h}$ emergencias, con $t_f = 1$ h y $u = 1$ ese peso es

$$k = 1{,}25 + \frac{CR\,DP_h}{\bar{h}\,c_h}. \tag{13}$$

La tarifa y el consumo de un usuario se tomaron de una factura residencial de Surtigas en Cartagena, de junio de 2026 [45]. El usuario consumió 33 m^3 en el mes, equivalentes a 1,10 m^3 diarios y a $DP_h = 0{,}0458$ m^3/h, con una tarifa de 2687 COP/m^3. Así, $c_{ind} = 2956$ COP por usuario y día de falla. Se supuso que esos valores representan a un usuario residencial de Montería, porque la misma empresa atiende ambas ciudades y las dos están en la región Caribe. Además, se tomó $u = 1$, que es conservador para un escape en el centro de medición. El costo de racionamiento fue $CR = 2866{,}77$ COP/m^3, que corresponde a un corte no programado en el corto plazo [44]. La multa máxima es $M_s = 2000 \times 1\,750\,905 = 3501{,}8$ millones de COP. Como no hay registros públicos que permitan estimar p_0, este parámetro se evaluó entre 0 y 10 %. Para cada par de escenarios X e Y, con $D_Y^{nc} > D_X^{nc}$, se calculó además la probabilidad de equilibrio con la que ambos tienen el mismo costo anual esperado,

$$p_0^* = \frac{\left(C_X + c_{ind}\,u\,N_X^{nc}\right) - \left(C_Y + c_{ind}\,u\,N_Y^{nc}\right)}{M_s\left(D_Y^{nc} - D_X^{nc}\right)/D_A^{nc}}, \tag{14}$$

donde C es el costo anual de la ecuación (8). Por encima de p_0^* conviene el escenario X, que deja menos horas no cubribles.

5.7. Escenario simulado de asignación por sector

Para mostrar el alcance del pronóstico en la operación, se construyó un escenario simulado que reparte las cuadrillas entre los sectores de la ciudad. El escenario combina datos reales del registro con supuestos declarados y se desarrolló en siete pasos.

Paso 1: barrio de cada orden. El barrio se tomó del campo de observaciones. Se descartaron los textos de más de 30 caracteres, que corresponden a fragmentos de la observación y no a nombres de barrio. En las órdenes sin barrio en ese campo, se tomó de las direcciones en formato de manzana y lote, que suelen incluir el nombre del barrio. Los nombres se normalizaron (mayúsculas, sin tildes ni prefijos como «Urb.» o «B.»).

Paso 2: probabilidad por barrio. Se calculó la participación p_b de cada barrio entre las órdenes con barrio identificado en los 12 meses previos al año de prueba, para no usar información de ese periodo. Si el pronóstico del día es $\hat{y}_t$ y las emergencias siguen un proceso de Poisson, las de cada barrio también lo siguen, con media $\lambda_{b,t} = \hat{y}_t\,p_b$. Así, la probabilidad de que el barrio tenga al menos una emergencia ese día es

$$P_{b,t} = 1 - e^{-\hat{y}_t\,p_b}. \tag{15}$$

Paso 3: sectores. Los 60 barrios más frecuentes se ubicaron con el servicio Nominatim de OpenStreetMap [46], que devuelve un punto aproximado y la comuna a la que pertenece. Cada comuna se tomó como un sector de atención. Se aceptó el resultado cuando su nombre coincidía con el del barrio o cuando era un lugar (tienda, parque, colegio) que lleva su nombre. La participación p_z de cada sector es la suma de las de sus barrios ubicados.

Paso 4: demanda por sector en el año de prueba. Las órdenes de prueba cuyo barrio se ubicó se asignaron a su sector. Las demás se repartieron entre sectores con una distribución multinomial de probabilidades p_z, en 300 repeticiones de Monte Carlo.

Paso 5: dotación y capacidad. Se consideró como cuadrilla a cada persona distinta del campo «Persona ejecuta», con un turno de 8 h. La dotación observada es la mediana de personas activas durante el año de prueba, calculada para cada día de lunes a sábado y para el conjunto de domingos y festivos. Se usó la mediana y no el conteo de cada día porque este depende de la demanda que se quiere atender. La capacidad de un sector es el número de cuadrillas asignadas multiplicado por 8 h, y su demanda es el número de emergencias multiplicado por $\bar{h}$.

Paso 6: escenarios. Los escenarios difieren en cuántas cuadrillas se programan cada día y en cómo se reparten entre sectores. El escenario A es la línea base y representa la situación actual. Usa la dotación observada en el año de prueba y la reparte por igual entre sectores, porque hoy la asignación no usa información sobre dónde ocurren las emergencias. Los demás escenarios cambian un elemento a la vez frente a A. El escenario B conserva la dotación observada, pero la reparte según la participación p_z de cada sector. Aísla, por tanto, el efecto de la información geográfica. El escenario C fija además la dotación de cada día con el pronóstico, $N_t = \lceil \hat{y}_t\,\bar{h}/8 \rceil$, y la reparte según p_z. Mide así el efecto conjunto del pronóstico y del reparto. El escenario D agrega a C una cuadrilla de reserva cada día, como margen frente al error del pronóstico. Para ubicar el punto de equilibrio se evaluaron, además, dotaciones fijas de 1 a 8 cuadrillas diarias, con el mismo reparto.

Paso 7: métricas. Para cada día t y sector z, con capacidad $K_{t,z}$ y demanda $Q_{t,z}$ en horas, el déficit es $d_{t,z} = \max(0,\, Q_{t,z} - K_{t,z})$ y las horas ociosas son $o_{t,z} = \max(0,\, K_{t,z} - Q_{t,z})$. Las horas ociosas de un sector pueden cubrir el déficit de otro mediante traslados. La distancia entre dos sectores se midió entre sus centros, ponderados por la demanda de sus barrios, con un factor de 1,3 por el trazado vial. Cada día, un traslado recorre la distancia esperada entre los sectores con horas ociosas y los sectores con déficit, ponderados por esas horas. El criterio se debe a que solo una cuadrilla con tiempo libre puede atender una emergencia de otro sector, y ese tiempo libre está en los sectores con horas ociosas. Así, la distancia depende del reparto: si sobran cuadrillas en sectores alejados de la demanda, los traslados son más largos. El tiempo de viaje se descuenta de la capacidad ociosa y tiene dos componentes. El primero es el recorrido a 15 km/h, una velocidad de hora pico. El 86,0 % de las órdenes se registra entre las 8:00 y las 18:59, cuando el

tráfico es mayor. Como referencia, Barranquilla registró en 2024 un promedio anual de 16,6 km/h [47]. El segundo componente es la espera en semáforos. Se supusieron cuatro intersecciones semaforizadas por traslado, con 30 s de demora en cada una. Ese valor está en el rango de 20 a 35 s del nivel de servicio C, que corresponde a un flujo estable con demoras aceptables [48]. Cada traslado suma, así, 2 min de espera. Si r_t es el tiempo de viaje del día t por hora de trabajo trasladada, ese día se trasladan $M_t = \min\big(\sum_z d_{t,z},\, \sum_z o_{t,z}/(1+r_t)\big)$ horas. Las horas en déficit y las horas ociosas del periodo son, entonces,

$$D = \sum_t \big(\sum_z d_{t,z} - M_t\big), \qquad O = \sum_t \big(\sum_z o_{t,z} - (1+r_t)\, M_t\big). \tag{16}$$

Esta ecuación aplica la ecuación (5) a la ciudad, con la capacidad de las cuadrillas en lugar del pronóstico y con los traslados entre sectores. Una hora en déficit no cuesta solo la hora extra con que se cubre. También pone en riesgo la seguridad de los usuarios y el cumplimiento del IRST. Ese costo adicional es un gasto por confiabilidad: lo que la empresa está dispuesta a pagar para atender a tiempo. El sector de gas ya reconoce gastos de este tipo. La Unidad de Planeación Minero Energética (UPME) estima costos de racionamiento para evaluar la confiabilidad del abastecimiento [43]. La CREG, por su parte, remunera en la tarifa de distribución las inversiones y los gastos de confiabilidad y seguridad de la red [49]. Además, compensa a los usuarios cuando la duración de las interrupciones supera el estándar [4]. Ninguna de estas normas, sin embargo, fija un valor para una hora de retraso en la atención de emergencias. La sección 5.6.4 muestra, además, que los valores regulados disponibles apenas lo acotan. Por ello, el gasto por confiabilidad se representó con un peso k, que indica cuántas veces cuenta una hora en déficit frente a una hora ociosa. Los escenarios se compararon con el costo ponderado $kD + O$ para $k = 1$, 2 y 3. Con $k = 1$ ambas horas pesan igual, y con $k = 2$ o $k = 3$ una hora en déficit cuenta el doble o el triple. El mismo criterio se aplicó a cada cuadrilla adicional de las dotaciones fijas. Si una cuadrilla evita ΔD horas en déficit y agrega ΔO horas ociosas, reduce el costo ponderado cuando $k\,\Delta D > \Delta O$. Es decir, conviene agregarla cuando k supera su k mínimo,

$$k_{\text{mín}} = \frac{\Delta O}{\Delta D}. \tag{17}$$

Después se valoraron con el costo anual de la ecuación (8) y con los indicadores financieros de la sección 5.6. El escenario se apoya en tres supuestos. Las órdenes sin barrio se distribuyen como las identificadas, los traslados recorren la distancia esperada entre los sectores que ceden y los que reciben capacidad, y cada persona del registro equivale a una cuadrilla.

5.8. Despliegue y monitoreo

La Fig. 5 presenta el sistema propuesto para el OE4. Cada día, la ventana se actualiza con el dato real y el modelo pronostica el día siguiente sin reentrenarse; cada mes, el modelo se reajusta con toda la historia. El tablero de control reúne el pronóstico, la probabilidad de alta demanda y la explicación del nivel.

6. Resultados y discusión

6.1. Análisis exploratorio

El EDA parte del registro de emergencias y busca describir la demanda diaria que se quiere pronosticar. Cada orden contiene la fecha y la hora de registro, el tipo de emergencia, la causal, el barrio y las marcas de tiempo de la atención. Al contar las órdenes por fecha se obtiene la variable objetivo: el número de emergencias por día, un conteo no negativo. Las variables predictoras son el día de la semana, el mes, el indicador de festivo y el de fin de semana, junto con los rezagos de la propia serie. El nivel de demanda agrupa la variable objetivo en tres categorías y es la variable que explica la RB. Las demás variables de la orden describen la demanda, pero no entran en los modelos de la serie diaria. El Cuadro 2 resume el tipo, la naturaleza y el papel de cada una.

Cuadro 2
Variables disponibles: tipo, naturaleza y papel en el estudio

Variable	Tipo	Naturaleza	Papel
Emergencias por día	Cuantitativa discreta	Conteo de 0 a 97	Objetivo
Nivel de demanda	Cualitativa ordinal	Bajo, medio o alto	Objetivo de la RB
Día de la semana	Cualitativa nominal	Siete categorías, cíclica	Predictora
Mes	Cualitativa nominal	Doce categorías, cíclica	Predictora
Festivo	Cualitativa binaria	Sí o no	Predictora
Fin de semana	Cualitativa binaria	Sí o no	Predictora
Rezagos y media móvil	Cuantitativa	Demanda de días anteriores	Predictora derivada
Año	Cualitativa ordinal	2017 a 2026	Descriptiva
Tipo de emergencia	Cualitativa binaria	Controlada o no controlada	Descriptiva
Causal	Cualitativa nominal	Categorías del registro	Descriptiva
Barrio	Cualitativa nominal	Texto libre	Escenario por sector
Tiempo de respuesta	Cuantitativa continua	Horas, de la asignación a la llegada	Objetivo del modelo de tiempos

Fuente: elaboración propia.

6.1.1. Calidad del registro: El Cuadro 3 resume los problemas encontrados en el registro original y el tratamiento de cada uno. El registro no tiene órdenes duplicadas ni fechas futuras, y la fecha de registro, con la que se construye la serie, está completa. Los problemas se concentran en la secuencia de tiempos de atención y en campos administrativos que no se usan para pronosticar.

6.1.2. Tendencia y nivel: La Fig. 6 muestra la serie diaria completa.

La demanda promedio fue de 14,9 emergencias por día, con una mediana de 14 y un máximo de 97 el 6 de junio

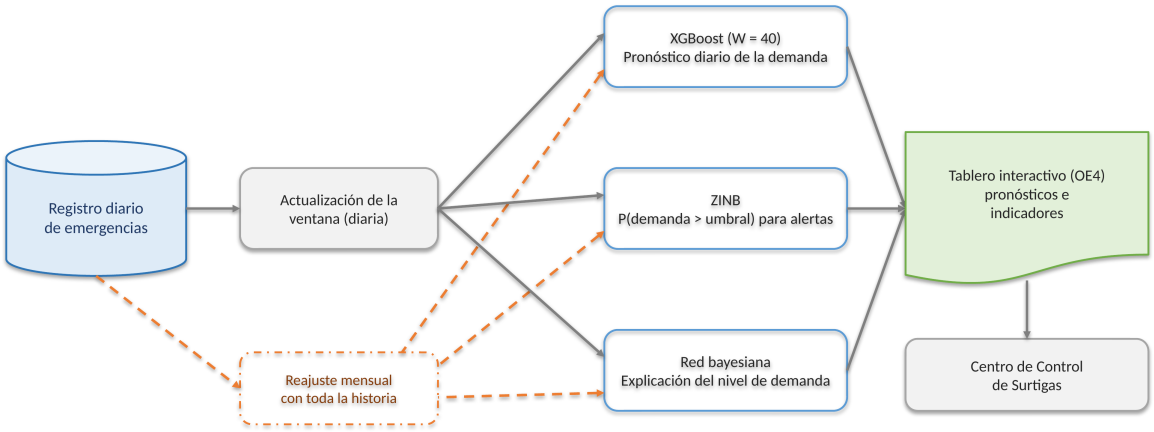


Figura 5. Sistema propuesto: actualización diaria, modelos de pronóstico, alerta y explicación, y tablero de control.

Cuadro 3
Problemas de calidad del registro original y tratamiento aplicado

Problema	Órdenes	Tratamiento
Fechas de 1970 (campo vacío)	3	Eliminadas
Llegada anterior a la asignación	880	Imputadas; excluidas de la evaluación
Control anterior a la llegada	21	Tiempo de control anulado
Cruce de medianoche	1	Corregida (+1 día)
Campo «Persona legaliza» vacío	44 400	Variable descartada
Contrato vacío	7070	Sin imputación
Barrio no extraíble de la dirección	24 462	Sin imputación

Fuente: elaboración propia.

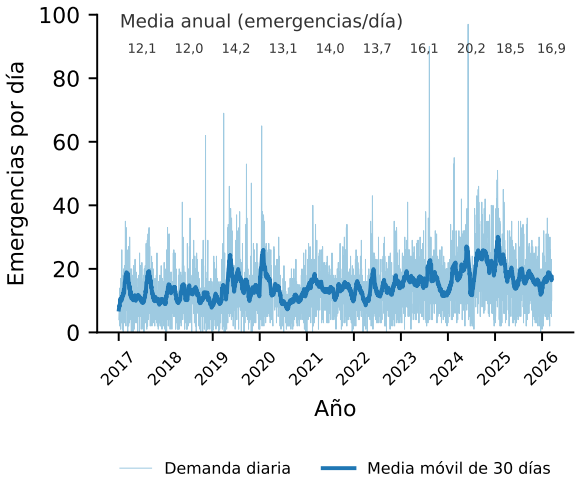


Figura 6. Demanda diaria de emergencias en Montería, enero de 2017 a marzo de 2026. La línea gruesa es la media móvil centrada de 30 días y los números superiores son la media anual (2026 llega hasta el 17 de marzo).

de 2024. El promedio anual pasó de 12,1 en 2017 a 20,2 en 2024 y bajó a 18,5 en 2025. La prueba ADF rechaza la raíz unitaria ($p < 0{,}001$): los choques de demanda son transitorios y la serie tiende a volver a su media. La prueba KPSS, en cambio, rechaza que esa media sea constante ($p \leq 0{,}01$). En conjunto, la serie vuelve a su media local, pero ese nivel cambia con el tiempo. Por eso, un promedio histórico fijo queda desactualizado, y todos los candidatos reciben como entrada los días recientes.

6.1.3. Estacionalidad semanal, mensual y horaria: El calendario es el rasgo más fuerte de la serie (Fig. 7).

De lunes a viernes llegan entre 17,4 y 20,5 emergencias por día, el sábado 10,8, el domingo 4,6 y los festivos 5,7. Un lunes recibe, en promedio, 4,4 veces la demanda de un domingo. La prueba de Kruskal-Wallis confirma que la diferencia entre días de la semana es significativa, es decir, que no se explica por la variación aleatoria ($H = 1395$, $p < 0{,}001$). El efecto del mes es menor, pero también significativo ($H = 72{,}2$, $p < 0{,}001$). Con la tendencia descontada, enero, mayo y agosto quedan cerca de 10 % por encima del promedio anual, y diciembre 12 % por debajo.

Con los terciles del entrenamiento se definieron tres niveles de demanda: bajo (10 o menos emergencias), medio (11 a 16) y alto (17 o más). Esos niveles abarcan el 33,9 %, el 27,5 % y el 38,6 % de los días de la serie. Según la Fig. 8, el 89,4 % de los festivos y el 75,4 % de los fines de semana tienen nivel bajo. En cambio, el 54,7 % de los días laborables tiene nivel alto. Los 35 días sin emergencias son 25 domingos y 10 festivos, por lo que corresponden a ceros de calendario y no a vacíos de captura.

Dentro del día, la operación es diurna. El 86,0 % de las órdenes se registra entre las 8:00 y las 18:59, con el pico a las 9:00. Los sábados, la actividad se corta hacia el mediodía. Este patrón no se modela, porque el pronóstico es de totales diarios, pero indica que la capacidad planeada debe concentrarse en el turno de la mañana. Este patrón horario puede integrarse como indicador en el tablero del

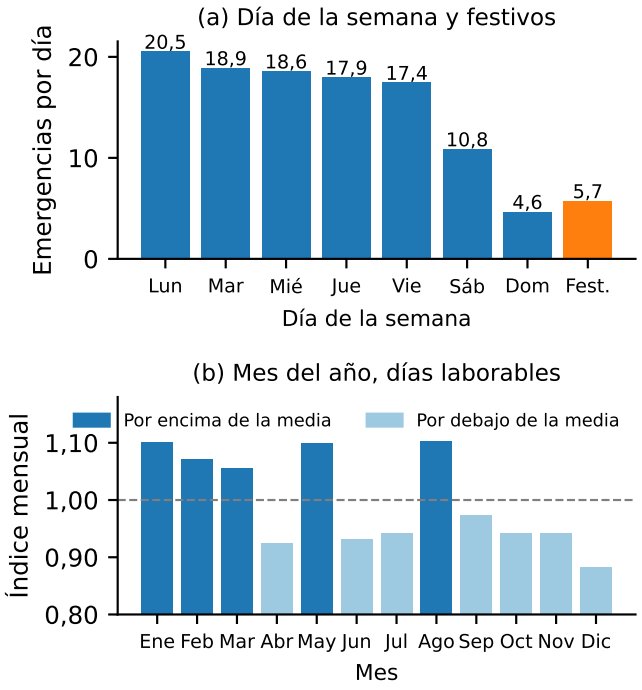


Figura 7. Perfiles de calendario. (a) Media de emergencias por día según el día de la semana (sin festivos) y en festivos. (b) Índice mensual de los días hábiles: demanda del día dividida por la media de los días hábiles de su año. El tono oscuro marca los meses por encima de esa media, y el eje vertical empieza en 0,80 para que se aprecien las diferencias.

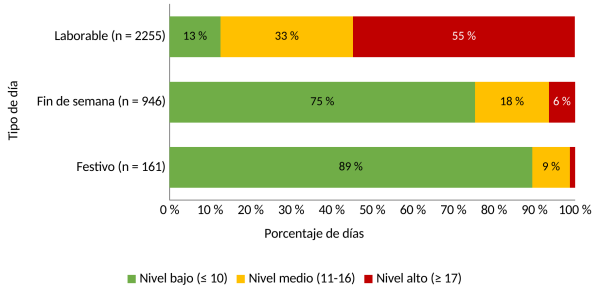


Figura 8. Nivel de demanda diaria según el tipo de día, con colores de semáforo: verde para el nivel bajo, ámbar para el medio y rojo para el alto. Los niveles se definieron con los terciles del bloque de entrenamiento.

OE4.

6.1.4. Asociación entre variables categóricas: El Cuadro 4 resume la asociación entre las variables categóricas de los 3362 días de la serie. El fin de semana es la variable más asociada con el nivel de demanda ($V = 0{,}57$). Le siguen el día de la semana ($V = 0{,}44$) y el festivo ($V = 0{,}26$), y en los tres casos la prueba chi-cuadrado rechaza la independencia ($p < 0{,}001$). El año tiene una asociación menor ($V = 0{,}18$), con una correlación policórica positiva ($\rho_{pc} = 0{,}26$). Este valor refleja la tendencia creciente de la demanda entre 2017 y 2024. El mes, en cambio, apenas se asocia con el nivel ($V = 0{,}08$). Su relación es significativa por el tamaño de la muestra, pero débil.

Cuadro 4
Asociación entre pares de variables categóricas de la serie diaria (prueba chi-cuadrado de independencia, 3362 días)

Par de variables	χ^2	gl	p	V	Otra
Fin de semana × nivel de demanda	1093,48	2	$< 0{,}001$	0,57	–
Día de la semana × nivel de demanda	1322,17	12	$< 0{,}001$	0,44	–
Festivo × nivel de demanda	234,90	2	$< 0{,}001$	0,26	–
Año × nivel de demanda	240,14	18	$< 0{,}001$	0,18	$\rho_{pc} = 0{,}26$
Mes × nivel de demanda	66,19	22	$< 0{,}001$	0,08	–
Día de la semana × festivo	311,88	6	$< 0{,}001$	0,30	–
Festivo × fin de semana	32,69	1	$< 0{,}001$	0,10	$\phi = -0{,}10$
Mes × festivo	41,34	11	$< 0{,}001$	0,09	–
Mes × año	233,09	99	$< 0{,}001$	0,07	–

V: V de Cramér con corrección de sesgo; ϕ: coeficiente Phi; ρ_{pc}: correlación policórica; –: el coeficiente no aplica al par (Phi exige dos variables binarias y la policórica, dos ordinales). Los pares no listados son independientes ($p > 0{,}05$).
Fuente: elaboración propia.

La Fig. 9 muestra la matriz completa. Entre las predictoras, el día de la semana y el fin de semana tienen una relación estructural, porque la segunda se deriva de la primera. El festivo se asocia con el día de la semana ($V = 0{,}30$), ya que buena parte de los festivos colombianos se trasladan al lunes. Su coeficiente Phi con el fin de semana es negativo ($\phi = -0{,}10$), porque un festivo rara vez cae en sábado o domingo. El mes y el año son independientes del día de la semana, como corresponde a un calendario. En conjunto, la información del calendario se concentra en el tipo de día, y el mes aporta poco por sí solo. Por eso los modelos combinan el tipo de día con los rezagos, que recogen el nivel reciente de la demanda.

6.1.5. Composición y patrón geoespacial: El 57,6 % de las órdenes corresponde a emergencias controladas y el 42,4 % a no controladas. Las diez causales más frecuentes concentran el 96 % de los casos. La composición por causal también cambió en el tiempo (Fig. 10). El escape en centro de medición pasó del 27,2 % de las emergencias en 2017 al 45,1 % en 2024. El robo de medidor, por su parte, pasó del 2,0 % en 2017 al 11,5 % en 2023. Estos cambios sugieren que parte del crecimiento de la demanda responde a causas específicas que podrían atenderse con acciones preventivas.

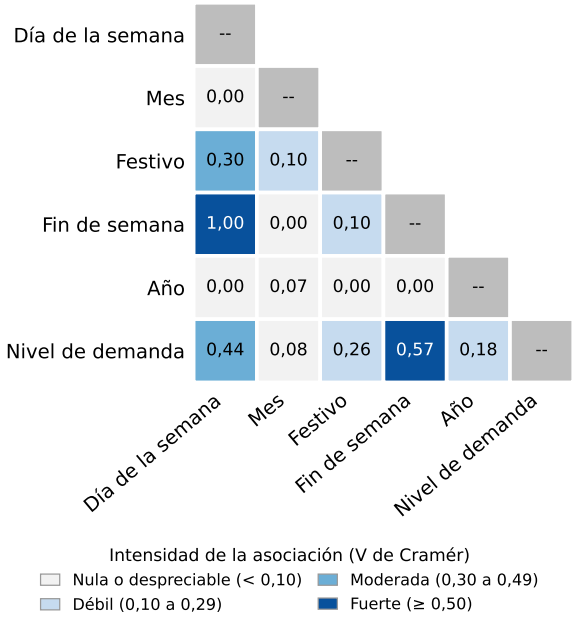


Figura 9. V de Cramér entre las variables categóricas de la serie diaria (3362 días). Un valor de 0 indica independencia y uno de 1, asociación perfecta. La diagonal (–) cruza cada variable consigo misma, y la relación entre el día de la semana y el fin de semana es estructural.

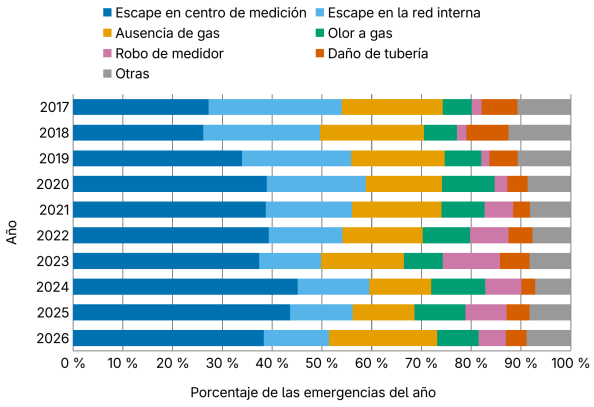


Figura 10. Composición anual de las emergencias según la causal registrada (2026 llega hasta el 17 de marzo).

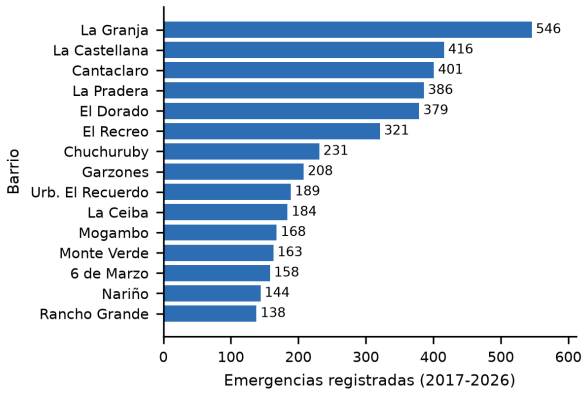


Figura 11. Quince barrios con más emergencias registradas entre 2017 y 2026, entre las órdenes con barrio identificable.

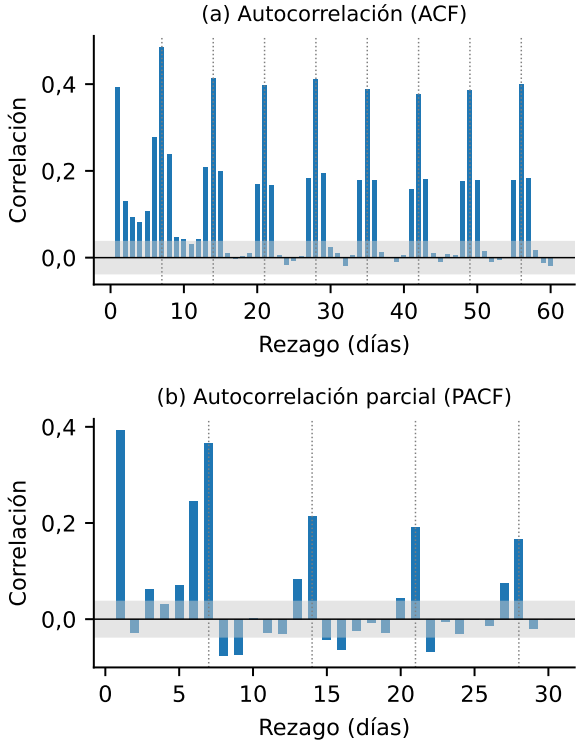


Figura 12. Autocorrelación (a) y autocorrelación parcial (b) de la demanda diaria, 2018–2026. La banda sombreada es el intervalo de 95 % bajo ruido blanco, y las líneas punteadas marcan múltiplos de siete días.

En la dimensión geoespacial, el barrio solo pudo extraerse en el 50,9 % de las órdenes, porque el campo es texto libre. Entre esas órdenes, La Granja (546), La Castellana (416) y Cantaclaro (401) concentran el mayor número de emergencias (Fig. 11). Con la mitad de las órdenes sin ubicación, el pronóstico se hizo para la ciudad completa. La sección 7.2 explora, como escenario simulado, cómo usar la distribución por barrio para asignar cuadrillas por sector.

6.1.6. Dependencia temporal: La Fig. 12 muestra la autocorrelación de la serie desde 2018, para excluir el arranque del sistema.

La correlación con el día anterior es de 0,39 y con el mismo día de la semana anterior de 0,49. En los múltiplos de siete días entre 14 y 56 se mantiene entre 0,38 y 0,41, mientras que en los demás rezagos es cercana a cero. La autocorrelación parcial, que aísla el efecto de cada rezago descontando el de los intermedios, tiene picos en los rezagos 1, 7, 14, 21 y 28. Además, la prueba de Ljung-Box rechaza que la serie sea ruido blanco, es decir, una secuencia sin memoria en la que el pasado no ayuda a pronosticar ($Q_{28} = 3758$, $p < 0{,}001$). Lo ocurrido en las

cuatro a ocho semanas anteriores informa, por tanto, sobre el día que se pronostica. Este resultado fijó el rango de ventanas del diseño experimental, entre 10 y 50 días.

6.1.7. Naturaleza estadística de la demanda: La demanda diaria tiene media de 14,9 y una razón varianza/media de 5,5, lejos de la equidispersión de la Poisson. Buena parte de esa varianza, sin embargo, viene de mezclar días hábiles con domingos y años de baja demanda con años de alta. Para separar ambos efectos, los días se agruparon por año, mes y día de la semana. Dentro de los grupos, la mediana de la razón varianza/media es 1,33, y en el 63 % de ellos la varianza supera a la media. La relación se ajusta a una BN con $r \approx 9{,}8$. Una vez descontado el calendario, queda entonces una sobredispersión moderada pero real.

El Cuadro 5 resume el ajuste de las tres familias sobre la serie completa. La Poisson espera cero días sin emergencias, la BN espera 15,6 y la ZINB reproduce los 35 observados con el menor criterio de información de Akaike (AIC). El AIC premia el buen ajuste y penaliza el número de parámetros, de modo que un valor menor indica un mejor equilibrio entre ambos. Este ajuste es descriptivo. Repetido solo con el bloque de entrenamiento, conserva el mismo orden (AIC de 25 027, 18 654 y 18 630). Por lo tanto, la elección de familia no depende del conjunto de prueba.

Cuadro 5
Ajuste por máxima verosimilitud de las familias de conteo ($n = 3362$ días). ✓: familia con mejor ajuste (menor criterio de información de Akaike, AIC)

Familia	μ	r	ψ	Ceros esperados	LL	AIC
Poisson	14,93	–	–	0	−16 509,17	33 020,35
BN	14,93	3,01	–	15,55	−11 919,30	23 842,61
ZINB ✓	15,03	3,19	0,01	35	−11 908,52	23 823,05

Fuente: elaboración propia.

El parámetro r del Cuadro 5 (≈ 3) es menor que el obtenido al agrupar por calendario ($\approx 9{,}8$). La razón es que el ajuste marginal absorbe como dispersión la variación entre días hábiles, fines de semana y años.

La Fig. 13 complementa el cuadro. El histograma muestra dos modas, una de fines de semana y festivos y otra de días laborables. Una distribución marginal no reproduce esa forma, lo que justifica incluir el calendario en los modelos.

6.1.8. Tiempos de respuesta: El tiempo de respuesta, desde la asignación de la cuadrilla hasta su llegada, tiene una mediana de 0,72 h y un percentil 95 de 7,1 h. La Fig. 14 muestra que esa cola resulta de mezclar dos poblaciones. Las emergencias no controladas se atienden con una mediana de 0,48 h y las controladas con una de 2,10 h. Medido desde el registro de la orden, el 99,9 % de las no controladas tuvo llegada en menos de una hora, frente al 9,1 % de las controladas. La correlación de Spearman entre la carga del día y la mediana del tiempo de respuesta es

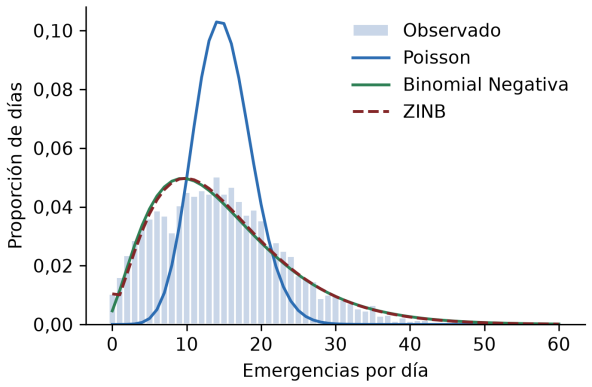


Figura 13. Histograma de la demanda diaria y distribuciones de Poisson, BN y ZINB ajustadas por máxima verosimilitud.

débil ($\rho_s = 0{,}06$, en una escala de -1 a 1). Esto sugiere que el tipo de emergencia, más que la congestión, determina la duración.

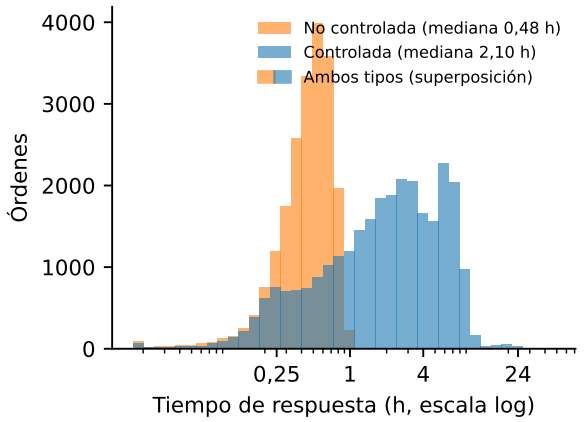


Figura 14. Distribución del tiempo de respuesta (asignación a llegada) según el tipo de emergencia, en escala logarítmica.

6.1.9. De los hallazgos a las técnicas: El Cuadro 6 conecta cada hallazgo del EDA con la técnica que se incluyó para aprovecharlo y con su respaldo en la literatura.

6.2. Supuestos de los modelos de conteo

El Cuadro 7 resume la verificación de los supuestos de los GLM con los 2682 días del bloque de entrenamiento. La equidispersión de la Poisson no se cumple. El estadístico de Pearson es 2,57 veces sus grados de libertad, y la prueba de Cameron y Trivedi estima una dispersión positiva ($\alpha = 0{,}10$, $t = 12{,}49$, $p < 0{,}001$). La prueba de razón de verosimilitud confirma que la BN mejora el ajuste de la Poisson ($LR = 1432{,}35$, $p < 0{,}001$). Por lo tanto, la Poisson no describe bien la distribución de la demanda, aunque su pronóstico puntual sea parecido al de las otras familias.

Cuadro 6
Relación entre los hallazgos del EDA y las técnicas evaluadas

Hallazgo del EDA	Implicación para el modelo	Técnica	Respaldo
Conteo con sobredispersión moderada ($r \approx 9{,}77$) y ceros en domingos y festivos (Cuadro 5)	El modelo debe producir una distribución de conteo, no solo un valor	Poisson, BN y ZINB	[9], [10]
El efecto del día depende del calendario y del nivel reciente (Fig. 7)	Hay que capturar interacciones no lineales entre calendario y rezagos	XGBoost con ventana de rezagos y calendario	[13], [14]
Autocorrelación significativa hasta cuatro u ocho semanas (Fig. 12)	Conviene que el modelo lea una secuencia larga de días	LSTM y BiLSTM	[17], [19]
Patrón semanal repetido con forma estable (Figs. 7 y 12)	Sirve un detector de patrones locales dentro de la ventana	1D-CNN	[20]
Fuerte persistencia de un día a otro y de una semana a otra	Un modelo útil debe superar la repetición del pasado	Métodos de referencia	[11]

Fuente: elaboración propia.

Cuadro 7
Verificación de los supuestos de los modelos de conteo en el bloque de entrenamiento (2682 días)

Supuesto	Prueba	Resultado	Conclusión
Equidispersión	χ^2 de Pearson/gl; Cameron-Trivedi	2,57; $t = 12{,}49$, $p < 0{,}001$	No se cumple: hay sobredispersión
Parámetro de dispersión nulo	Razón de verosimilitud, Poisson frente a BN	$LR = 1432{,}35$, $p < 0{,}001$	La BN es preferible
Ceros explicados por el modelo	Ceros observados frente a esperados; Vuong, ZINB frente a BN	34 frente a 2,81, 8,25 y 33,50; $z = 0{,}86$, $p = 0{,}391$	La ZINB reproduce los ceros, sin diferencia significativa con la BN
Independencia de los residuos	Ljung-Box sobre los residuos de Pearson de la BN	$Q_7 = 99{,}02$, $Q_{28} = 550{,}31$, $p < 0{,}001$	No se cumple: queda dependencia semanal
Enlace logarítmico adecuado	Prueba de enlace de Pregibon	$\hat{\eta}^2$: $-0{,}13$, $p < 0{,}001$	No se cumple del todo: hay no linealidad
Ausencia de multicolinealidad	Factor de inflación de la varianza (VIF)	VIF máximo 2,04	Se cumple

Fuente: elaboración propia.

En entrenamiento hubo 34 días sin emergencias. La Poisson espera 2,81 y la BN 8,25, mientras que la ZINB reproduce la cifra observada (33,50). Sin embargo, la prueba de Vuong no distingue la ZINB de la BN ($z = 0{,}86$, $p = 0{,}391$). Su probabilidad media de inflación es de 0,01, de modo que la mejora afecta a pocos días del año.

Dos supuestos no se cumplen en la BN. Sus residuos conservan dependencia semanal ($Q_7 = 99{,}02$ y $Q_{28} = 550{,}31$, $p < 0{,}001$), aunque su autocorrelación con el día anterior es casi nula (-0,02). La prueba de enlace indica, además, que el efecto de las covariables no es del todo lineal en la escala logarítmica ($p < 0{,}001$). La multicolinealidad, en cambio, no es un problema, con un VIF máximo de 2,04. En consecuencia, los GLM describen la dispersión y los ceros, pero no capturan toda la estructura semanal ni las relaciones no lineales. Esa limitación respalda la inclusión de XGBoost y de las redes, que leen la ventana completa de días anteriores.

6.3. Diseño de experimentos y selección del modelo

El Cuadro 8 presenta el ANOVA del diseño factorial. La técnica explica el 59 % de la variación del MAE de validación ($F = 26{,}53$, $p < 0{,}001$). La ventana no tiene un efecto significativo ($p = 0{,}581$), y tampoco su interacción con la técnica ($p = 0{,}419$). Los residuos no cumplen del todo los supuestos del ANOVA: la prueba de Shapiro-Wilk rechaza la normalidad ($p = 0{,}015$) y la de Levene rechaza la igualdad de varianzas ($p = 0{,}023$). Por ello, el efecto de la técnica se confirmó con dos pruebas que no dependen de esos supuestos: Kruskal-Wallis ($H = 39{,}6$, $p < 0{,}001$) y el ANOVA de Welch ($F = 58{,}7$, $p < 0{,}001$). Ambas confirman que la técnica influye en el error.

Cuadro 8
ANOVA del diseño factorial 4×5 con tres réplicas (respuesta: MAE de validación)

Fuente	SC	gl	F	p	η^2
Técnica (A)	19,06	3	26,53	$< 0{,}001$	0,59
Ventana W (B)	0,69	4	0,72	0,581	0,02
Interacción A×B	3,04	12	1,06	0,419	0,09
Error	9,58	40			0,30

Fuente: elaboración propia.

La Fig. 15 muestra el resultado de cada combinación. XGBoost obtuvo el menor MAE de validación en todas las ventanas y con la menor variación entre semillas. Según la prueba de Tukey, XGBoost (5,46 con $W = 40$) es significativamente mejor que las otras tres técnicas ($p \leq 0{,}002$). Le sigue BiLSTM (5,89 con $W = 20$), que supera a la 1D-CNN ($p < 0{,}001$) pero no se distingue de

la LSTM ($p = 0{,}130$). Los GLM quedaron prácticamente empatados, con un MAE de validación entre 6,21 (Poisson) y 6,28 (BN), lejos del de XGBoost. Por lo tanto, el protocolo selecciona a XGBoost con $W = 40$ como modelo campeón.

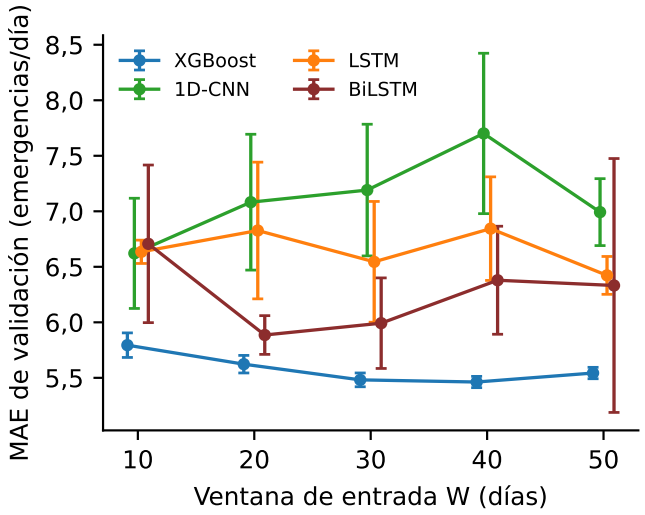


Figura 15. MAE de validación por técnica y ventana de entrada. Cada punto es la media de tres semillas, y las barras indican una desviación estándar.

6.4. Desempeño en el conjunto de prueba

El Cuadro 9 reúne los errores de entrenamiento, validación y prueba. En prueba, XGBoost tuvo un MAE de 4,22, 34 % menos que el mejor método de referencia, que repite la demanda del mismo día de la semana anterior (6,40). Las cuatro técnicas de aprendizaje automático quedaron entre 4,14 y 4,24, y los GLM entre 4,57 y 4,61. Con reajuste mensual, el MAE de XGBoost fue de 4,31, de modo que el régimen de producción conserva el desempeño.

La Fig. 16 compara entrenamiento y prueba por modelo. XGBoost pasa de 3,52 en entrenamiento a 4,22 en prueba, una brecha que indica un ajuste más estrecho a la historia que el de las demás técnicas. En las redes y en los GLM, en cambio, ambos errores son parecidos.

El Cuadro 10 contrasta XGBoost con cada modelo.

XGBoost es significativamente mejor que los tres GLM ($p \leq 0{,}002$) y que todas las referencias ($p < 0{,}001$). Frente a las redes, en cambio, las diferencias no son significativas. La LSTM obtuvo el menor MAE de prueba (4,14). Sin embargo, la prueba de Diebold-Mariano no distingue a XGBoost de la LSTM ($p = 0{,}170$), de la BiLSTM ($p = 0{,}440$) ni de la 1D-CNN ($p = 0{,}423$). Elegir la LSTM por ese resultado reintroduciría además el sesgo que el protocolo evita [16].

El modelo pronostica la demanda total, pero la atención urgente depende de las no controladas, que promediaron 7,24 emergencias diarias en prueba. El pronóstico de XGBoost, multiplicado por la proporción histórica de no controladas (42,2 %), obtuvo un MAE de 2,57 (Cuadro 11). Un XGBoost entrenado solo con esa serie obtuvo 2,65, sin diferencia significativa (Diebold-Mariano, $p = 0{,}067$). Ambos superan a la mejor referencia ingenua, la media de los últimos siete días (3,35). En las controladas, los dos enfoques empatan. Basta, entonces, un solo modelo de demanda total, cuyo pronóstico se reparte por tipo sin perder precisión.

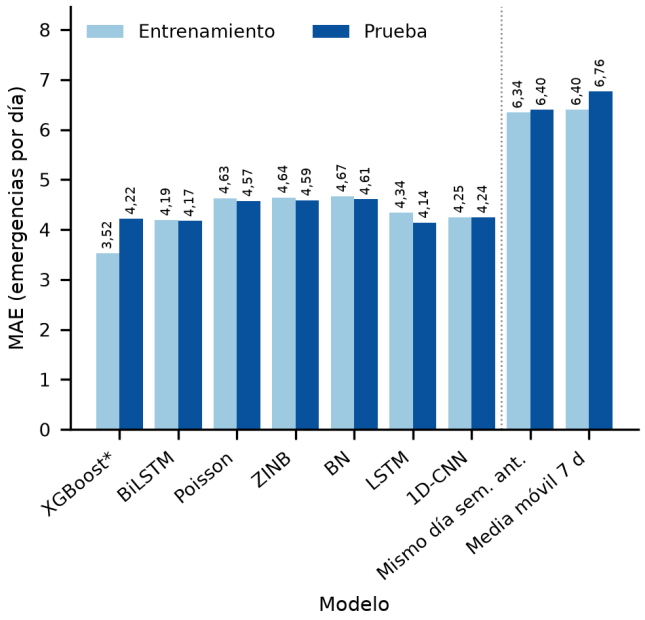


Figura 16. MAE en entrenamiento y en prueba por modelo. Los modelos se ordenan de izquierda a derecha según su MAE de validación, que se reporta en el Cuadro 9. A la derecha de la línea punteada están los dos mejores métodos de referencia (los cuatro aparecen en el Cuadro 9), y el asterisco marca el modelo campeón.

Cuadro 11
MAE de prueba de la demanda diaria por tipo de emergencia (336 días)

Método	Controladas	No controladas
Pronóstico total × proporción histórica	**2,74**	**2,57**
XGBoost entrenado por tipo	**2,74**	2,65
Media de los últimos 7 días	4,25	3,35
Mismo día de la semana anterior	4,13	3,77
Media diaria observada	9,42	7,24

Fuente: elaboración propia.

Una explicación probable de que la ventaja de XGBoost en validación no se trasladara a la prueba es la diferencia entre los periodos. El bloque de validación, de mayo de 2024 a abril de 2025, fue el más alto y variable de la

Cuadro 9
Error de los modelos en entrenamiento, validación y prueba (emergencias por día); NLL y CRPS solo aplican a los GLM. El asterisco marca el modelo campeón; la validación de las técnicas de aprendizaje automático es la media de tres semillas del diseño factorial

		Entrenamiento	Validación	Prueba (336 días)				
Modelo	W	MAE	MAE	MAE	RMSE	MAPE (%)	NLL	CRPS
Aprendizaje automático (media ± d.e. de 5 semillas)								
XGBoost*	40	3,52 ± 0,05	5,46	4,22 ± 0,03	5,59	35,44	–	–
BiLSTM	20	4,19 ± 0,06	5,89	4,17 ± 0,07	5,65	30,85	–	–
LSTM	50	4,34 ± 0,05	6,42	4,14 ± 0,06	5,57	30,83	–	–
1D-CNN	10	4,25 ± 0,27	6,62	4,24 ± 0,07	5,68	32,49	–	–
Modelos de conteo (GLM)								
ZINB	–	4,64	6,22	4,59	6,07	39,68	3,21	3,40
BN	–	4,67	6,28	4,61	6,10	39,74	3,22	3,42
Poisson	–	4,63	6,21	4,57	6,03	39,84	3,43	3,40
Métodos de referencia								
Mismo día, semana anterior	–	6,34	8,25	6,40	8,49	55,42	–	–
Media de 7 días	–	6,40	8,47	6,76	8,21	82,28	–	–
Mediana de 7 días	–	6,61	8,65	7,02	8,58	87,71	–	–
Día anterior	–	7,36	9,82	8,29	10,54	76,61	–	–

Fuente: elaboración propia.

Cuadro 10
Prueba de Diebold-Mariano (DM) con corrección HLN entre XGBoost y los demás modelos (pérdida absoluta en prueba). Un ΔMAE positivo indica que XGBoost tiene mayor error

XGBoost frente a	ΔMAE	DM (HLN)	p
BiLSTM	0,07	0,77	0,440
LSTM	0,12	1,37	0,170
1D-CNN	0,07	0,80	0,423
ZINB	−0,38	−3,13	0,002
BN	−0,40	−3,23	0,001
Poisson	−0,37	−3,10	0,002
Mismo día, semana anterior	−2,19	−7,95	< 0,001
Media de 7 días	−2,56	−10,45	< 0,001
Mediana de 7 días	−2,81	−10,44	< 0,001
Día anterior	−4,09	−11,87	< 0,001

Las diferencias usan el promedio de las predicciones de las cinco semillas (MAE de XGBoost 4,20; BiLSTM 4,14; LSTM 4,09; 1D-CNN 4,13), por lo que no coinciden con la resta de las medias del Cuadro 9.

Fuente: elaboración propia.

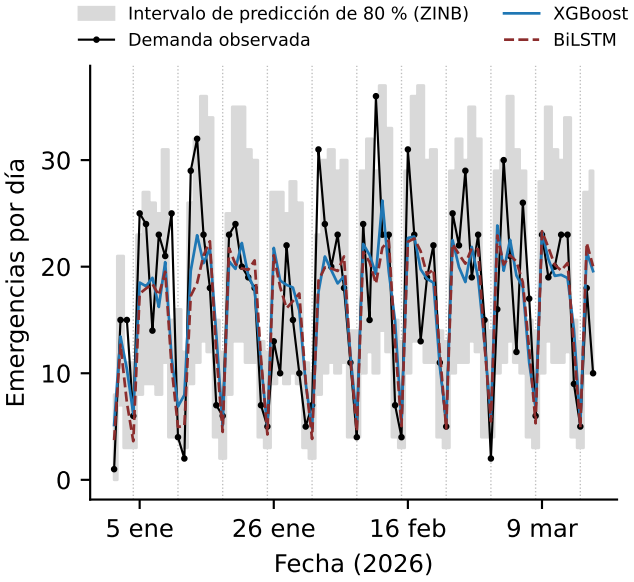


Figura 17. Demanda observada, pronósticos de XGBoost y BiLSTM (promedio de cinco semillas) e intervalo de predicción de 80 % de la ZINB. El periodo, del 1 de enero al 17 de marzo de 2026, es el trimestre más representativo del año de prueba. Las líneas punteadas verticales marcan los domingos.

serie. Tuvo una media de 22,0 emergencias por día, una desviación estándar de 11,6 y el pico de 97. El de prueba volvió a una media de 16,7, con desviación de 8,1. En el periodo agitado XGBoost se distinguió de las redes, y en el estable las cuatro técnicas rindieron igual. La Fig. 17 lo ilustra con el trimestre de enero a marzo de 2026, el más parecido al año de prueba completo. En él, XGBoost tuvo un error de 4,25 y BiLSTM de 4,16, frente a 4,20 y 4,14 en el año completo. La cobertura del intervalo de la ZINB fue de 85,5 %, frente a 84,8 % en el año. En ese trimestre, los pronósticos de ambas técnicas casi se superponen y siguen el ciclo semanal observado: caen cada domingo y se recuperan el lunes.

Entre los GLM, la ZINB obtuvo la menor NLL (3,21), seguida muy de cerca por la BN (3,22). Ambas superan con claridad a la Poisson (3,43) (Cuadro 9). Esto indica que la sobredispersión es la propiedad que más pesa. En el CRPS, en cambio, los tres modelos quedan prácticamente empatados, entre 3,40 y 3,42. Su parámetro de forma ($r = 10{,}2$) es cercano al que el EDA encontró al agrupar los días por calendario ($r \approx 9{,}8$). La probabilidad de inflación estimada fue de 0,005: una vez incluido el calendario, casi no quedan ceros sin explicar. El intervalo de 80 % de la ZINB contuvo el 84,8 % de los días de prueba,

una cobertura cercana a la nominal. Por su mayor error puntual, los GLM no son la herramienta de pronóstico. Su aporte es la distribución completa, de la que se obtiene la probabilidad de superar un umbral de demanda.

6.5. Clasificación por niveles y red bayesiana

Discretizado en los tres niveles, el pronóstico de XGBoost acierta en el 74,1 % de los días de prueba y la RB en el 72,9 % (Fig. 18). Predecir siempre la clase más frecuente acierta en el 52,7 %. La RB nunca predice el nivel medio, porque asigna cada día a la moda de su distribución condicional. El Cuadro 12 muestra que XGBoost tiene menor costo ordinal en ambas variantes. La RB supera a XGBoost en la sensibilidad de los niveles extremos: 0,89 frente a 0,70 en el bajo y 0,95 frente a 0,92 en el alto. Además, lo iguala en el F1 del nivel alto (0,84 frente a 0,83). Lo consigue a costa de no predecir nunca el nivel medio: clasifica 25 de esos días como bajos y 47 como altos.

Cuadro 12
Desempeño por nivel de demanda y costo ordinal en prueba

Modelo	F1 bajo	F1 medio	F1 alto	Sensibilidad alto	Costo simétrico	Costo asimétrico
RB	0,78	0	0,84	0,95	0,33	0,46
XGBoost	0,80	0,40	0,83	0,92	0,29	0,35

Fuente: elaboración propia.

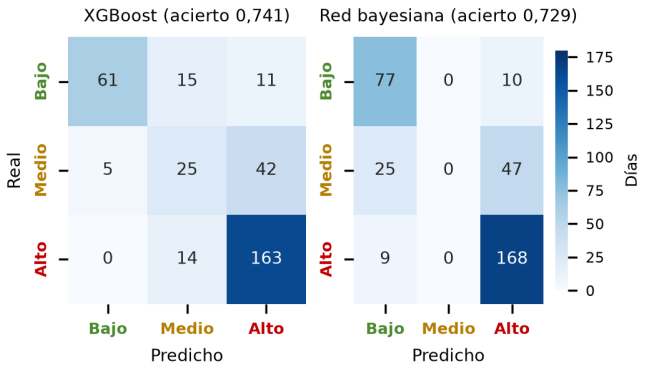


Figura 18. Matrices de confusión de los niveles de demanda en el conjunto de prueba.

En la estructura aprendida por la RB, el festivo se vincula con el nivel de demanda, con el mes y con el día de la semana. El nivel, a su vez, se vincula con el día de la semana. Esta estructura coincide con el EDA: los festivos y los fines de semana concentran los días de nivel bajo. Por ello, la RB se propone como capa explicativa para el comité técnico y no como herramienta de pronóstico.

6.6. Pronóstico del tiempo de respuesta

El Cuadro 13 resume el pronóstico de tiempos de respuesta sobre 13 112 órdenes de prueba. La mediana por tipo de emergencia obtuvo el menor MAE (1,06 h) y el mayor acierto dentro de 1 h. El bosque aleatorio tuvo menor RMSE y fue el único método que identificó respuestas de más de 4 h (F1 de 0,25). La mediana, en cambio, nunca predice ese intervalo. Con las variables disponibles, el tipo de emergencia explica la mayor parte del tiempo de respuesta.

Cuadro 13
Pronóstico del tiempo de respuesta en prueba (13 112 órdenes)

	Todas las órdenes				MAE por tipo (h)	
Método	MAE (h)	RMSE (h)	Error ≤ 1 h	F1 > 4 h	Contr.	No contr.
Mediana por tipo	1,06	1,87	67,16 %	0	1,81	0,15
Bosque aleatorio	1,11	1,74	60,44 %	0,25	1,90	0,15
Gradient boosting de histogramas	1,13	1,74	59,26 %	–	1,94	0,15
XGBoost	1,19	1,82	58,23 %	–	2,04	0,15

Fuente: elaboración propia.

El error global, sin embargo, oculta una diferencia marcada entre tipos (Cuadro 13). En las no controladas, los cuatro métodos tienen un MAE de 0,15 h y aciertan dentro de una hora en todas las órdenes. Su tiempo de respuesta es muy estable. En las controladas, el MAE sube a 1,81 h con la mediana por tipo, que sigue siendo el mejor método. La incertidumbre del tiempo proviene, por tanto, de las emergencias sin urgencia normativa. Para planear la atención urgente, la variable crítica es cuántas no controladas habrá, no cuánto tardará cada una.

6.7. Síntesis de resultados

El Cuadro 14 asigna a cada necesidad operativa el modelo que mejor la atiende según los resultados anteriores.

Cuadro 14
Modelo recomendado según la necesidad operativa

Necesidad operativa	Modelo recomendado	Métrica clave
Pronóstico diario de la demanda	XGBoost ($W = 40$)	MAE de prueba 4,22
Probabilidad de alta demanda	ZINB	NLL 3,21; CRPS 3,40
Explicación del nivel de demanda	RB	Acierto 0,73
Tiempo de respuesta esperado	Mediana por tipo	MAE 1,06 h
Alerta de respuesta mayor de 4 h	Bosque aleatorio	F1 0,25

Fuente: elaboración propia.

7. Análisis costo-beneficio

Esta sección aplica la metodología de la sección 5.6. Primero cuantifica las horas que el pronóstico deja de dimensionar mal y después las lleva a un escenario simulado de asignación por sector. Con ese escenario se ubica el

punto de equilibrio entre déficit y número de cuadrillas y se evalúa la viabilidad financiera. Por último, se valora el costo por incumplimiento y por confiabilidad.

7.1. Horas mal dimensionadas por el pronóstico

El tiempo tipo de atención es de 1,57 h por emergencia, desde la asignación hasta la finalización. Este valor se midió en 43 732 órdenes reales del periodo de entrenamiento y validación, sin usar el año de prueba. El Cuadro 15 aplica la ecuación (6) a los dos escenarios. El escenario propuesto usa el promedio de las predicciones de las cinco semillas de XGBoost.

Cuadro 15
Horas de cuadrilla mal dimensionadas en el año de prueba (336 días)

Indicador	Actual (media 7 días)	Propuesto (XGBoost)
MAE (emergencias por día)	6,76	4,20
Horas ociosas	1803	927
Horas en déficit	1767	1292
Horas en prueba (336 días)	3570	2219
Horas por año	3878	2410
Días con déficit de más de 5 emergencias	94	61

El MAE propuesto (4,20) usa el promedio de las predicciones de las cinco semillas; el 4,22 del Cuadro 9 es la media de los MAE por semilla.

Fuente: elaboración propia.

El escenario propuesto reduce en 38 % las horas mal dimensionadas. En el año de prueba ahorra 1351 h: 876 son horas ociosas, que bajan de 1803 a 927, y 475 son horas en déficit, que bajan de 1767 a 1292. Anualizado, el ahorro es de 1468 h, equivalentes a 183 turnos de 8 h, de las cuales 951 son ociosas y 517 en déficit. El 65 % del ahorro proviene, entonces, de la capacidad que la media móvil asigna de más. Además, los días en que la demanda supera al pronóstico en más de 5 emergencias bajan de 94 a 61. Son los días con mayor riesgo para el cumplimiento del IRST.

7.2. Escenario simulado de asignación de cuadrillas por sector

Esta subsección aplica el procedimiento de la sección 5.7. Sus resultados corresponden a un escenario simulado. La demanda, el pronóstico y la dotación provienen del registro, pero la asignación de cuadrillas por sector no se ha aplicado en la operación.

7.2.1. Ubicación de los barrios y probabilidad por barrio: En los 12 meses previos al año de prueba, el barrio se identificó en el 48,4 % de las órdenes, con 426 nombres distintos. Esta cifra es menor que el 50,9 % del EDA porque aquí se descartaron los fragmentos de observación que no son nombres de barrio. De los 60 barrios más frecuentes se ubicaron 47: 35 por su nombre y 12 por un lugar que lo lleva. Esos barrios reúnen el 55,8 % de las órdenes con barrio identificado. Los 13 restantes no aparecen en OpenStreetMap con el nombre del registro o están mal escritos en él. Entre ellos hay variantes abreviadas de barrios ubicados, como «Rep de Panamá», cuyas órdenes se repartieron con la simulación del paso 4.

Los barrios ubicados pertenecen a 9 sectores de la ciudad. Entre las emergencias con barrio ubicado, el Sector 4 concentra el 35 % y el Sector 6 el 22 %. En el año de prueba, el 28,0 % de las órdenes quedó asignado directamente a su sector, y el resto se repartió con la simulación del paso 4.

La Fig. 19 aplica la ecuación (15) a un lunes con el pronóstico medio de los lunes de prueba (18,8 emergencias). La Pradera y El Recuerdo tienen una probabilidad del 54 % y del 53 % de registrar al menos una emergencia, y ningún otro barrio supera el 40 %. Como la demanda está repartida entre muchos barrios, la unidad útil para asignar cuadrillas es el sector y no el barrio.

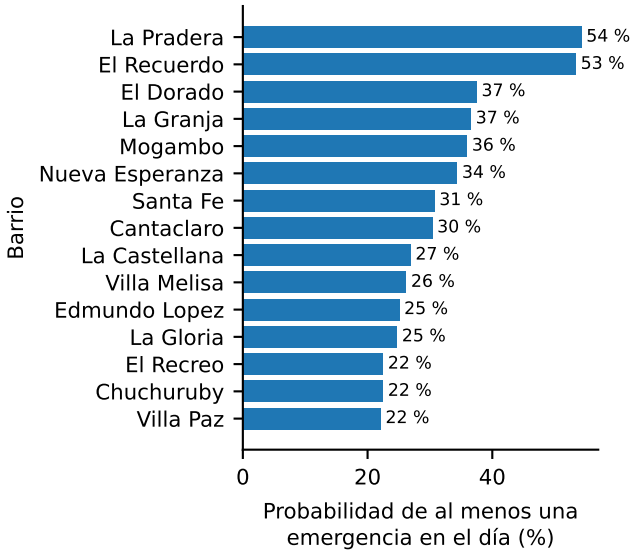


Figura 19. Probabilidad de que cada barrio registre al menos una emergencia en un lunes con el pronóstico medio de los lunes del año de prueba (18,8 emergencias). Quince barrios con mayor probabilidad.

7.2.2. Comparación de escenarios: La dotación observada en el año de prueba fue de 4 a 5 cuadrillas de lunes a viernes, 4 los sábados y 2 los domingos y festivos. El Cuadro 16 compara los cuatro escenarios en el total del periodo y en promedio por día. La Fig. 20 muestra, además, el tiempo que cada escenario pierde en traslados entre sectores.

Con la misma dotación, repartir las cuadrillas según la probabilidad de cada sector (B) reduce en 24 % las horas en déficit frente a la línea base (A). Esas horas bajan de 1145 a 875 h, y los días con déficit de más de 8 h pasan de 57 a 43. La mejora proviene de los traslados: con el reparto igual, A necesita 1633 traslados entre sectores en el año, y B solo 705. Además, los traslados de A son más largos, de 6,4 km en promedio frente a 5,4 km en B. La razón es

Cuadro 16
Escenarios simulados de asignación de cuadrillas por sector en el año de prueba (336 días)

Escenario	Cuadrillas por día	Turnos de 8 h	Total (336 días, h) Déficit	Total (336 días, h) Ociosas	Promedio diario (h) Déficit	Promedio diario (h) Ociosas	Días con déficit > 8 h	Costo ponderado, $kD + O$ $k = 1$	$k = 2$	$k = 3$
A. Línea base: dotación observada, reparto igual entre sectores	4	1266	1145	1724	3,41	5,13	57	2870	4015	5160
B. Dotación observada, reparto por probabilidad	4	1266	875	1932	2,60	5,75	43	2807	3682	4558
C. Dotación según pronóstico, reparto por probabilidad	4	1228	889	1635	2,65	4,87	44	**2525**	**3414**	**4304**
D. Como C, más una cuadrilla de reserva	5	1564	270	3733	0,80	11,11	12	4003	4272	4542

Costo ponderado: horas en déficit multiplicadas por el peso k del gasto por confiabilidad más las horas ociosas; en negrita, el menor de cada columna. Cuadrillas por día redondeadas al entero superior.

Fuente: elaboración propia.

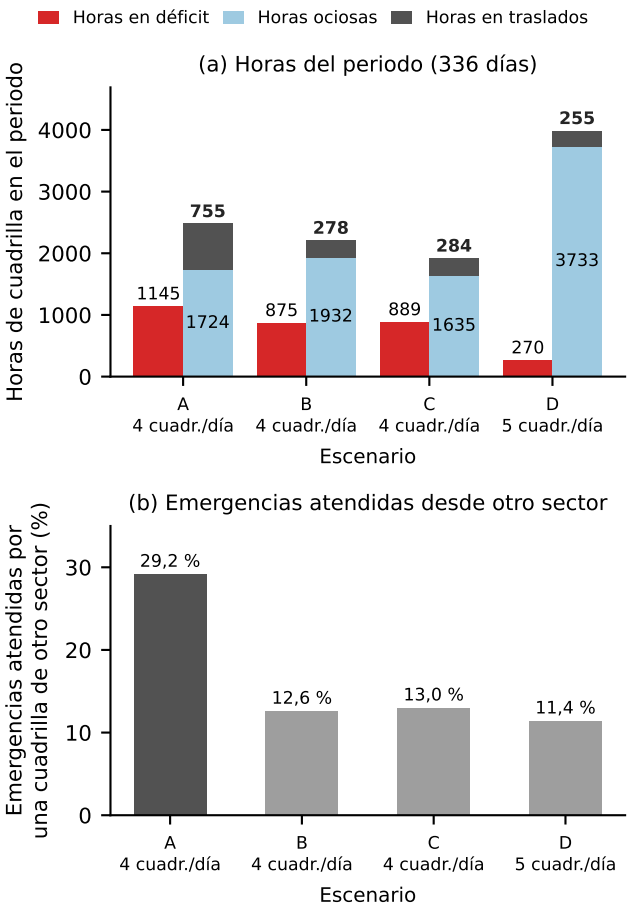


Figura 20. Horas de cuadrilla en déficit y horas ociosas por escenario, sumadas sobre los sectores. (a) Horas en déficit, horas en traslados entre sectores y horas ociosas en el año de prueba, del 16 de abril de 2025 al 17 de marzo de 2026. (b) Porcentaje de emergencias atendidas por una cuadrilla de otro sector. A: línea base, con la dotación observada y reparto igual; B: dotación observada con reparto por probabilidad; C: dotación según el pronóstico con reparto por probabilidad; D: escenario C con una cuadrilla de reserva.

que las cuadrillas que le sobran están en sectores alejados de la demanda. Por eso, A pierde 755 h en viajes, frente a 278 h en B. La Fig. 20b muestra la consecuencia para la atención. En A, una cuadrilla de otro sector atiende el 29,2 % de las emergencias, frente al 12,6 % en B. Cada una de esas emergencias recibe la cuadrilla unos 28 min más tarde. Esta es la mejora principal del escenario y no requiere más cuadrillas.

La dotación fijada con el pronóstico (C) usa un 3 % menos de turnos que la observada y obtiene un déficit similar (889 frente a 875 h). Es decir, el pronóstico reproduce la dotación que la empresa ya ajusta por tipo de día, pero la fija con un día de anticipación y día por día. Agregar una cuadrilla de reserva (D) reduce el déficit en 69 % frente a B, hasta 270 h, y los días críticos a 12. A cambio, usa un 24 % más de turnos.

El Cuadro 17 resume lo que cada escenario ahorra frente a la línea base.

Los tres necesitan entre 900 y 1000 traslados menos que A en el año. En B, que conserva la dotación, el déficit baja 270 h y las horas ociosas suben 208 h. La razón es que los traslados evitados ya no consumen capacidad ociosa. En C, el déficit baja 256 h y las horas ociosas 89 h, porque además se programan menos turnos. En D, el déficit baja 876 h, pero la cuadrilla de reserva agrega 2009 h ociosas.

El costo ponderado del Cuadro 16 muestra el papel del gasto por confiabilidad. C tiene el menor costo con $k = 1$, 2 y 3. D solo lo supera cuando $k > 3{,}38$, es decir, cuando una hora en déficit vale más de 3,38 horas ociosas. La elección entre ambos depende, entonces, de cuánto valore Surtigas una hora en déficit.

El resultado depende de la dotación supuesta. Con el reparto por probabilidad y 3, 4 o 5 cuadrillas de lunes a viernes, el déficit sería de 2286, 1061 y 402 h, respectivamente. La simulación mide el tiempo de los traslados entre sectores, pero no el desplazamiento dentro de cada sector ni su efecto sobre el tiempo de respuesta y el IRST.

7.3. Punto de equilibrio entre déficit y número de cuadrillas

La Fig. 21 muestra cómo cambian las horas y el costo anual al variar la dotación diaria, con el reparto por probabilidad. Al agregar cuadrillas, las horas en déficit bajan y las ociosas suben. Las dos curvas se cortan en 3,36 cuadrillas por día, con unas 1862 h de cada clase en el año de prueba. Como no es posible programar una fracción de cuadrilla, el punto de equilibrio se redondea hacia arriba, a 4 cuadrillas por día. Con 3 todavía predomina el déficit (2320 h), mientras que con 4 baja a 1035 h y ya es menor que las horas ociosas (2735 h). Por encima de él, cada cuadrilla adicional agrega más horas ociosas que las que quita al déficit. Ese valor coincide con la dotación que Surtigas programa de lunes a viernes, entre 4 y 5 cuadrillas, lo que respalda el modelo.

Cuadro 17
Horas ahorradas frente a la línea base por escenario en el año de prueba (336 días)

		Ahorro frente a A			
Escenario	Turnos	Déficit (h)	Ociosas (h)	Traslados	Déficit no cubrible (h)
A. Línea base	1266	–	–	–	337
B. Reparto por probabilidad	1266	270	−208	928	239
C. Dotación por pronóstico	1228	256	89	906	257
D. C con reserva	1564	876	−2009	994	48

A es la referencia de la comparación, por lo que no tiene horas ahorradas (–); un valor negativo indica más horas que en A. Déficit no cubrible: horas en déficit que exceden el límite legal de dos horas extra diarias por cuadrilla.
Fuente: elaboración propia.

La productividad marginal explica la forma de las curvas (Fig. 22 y Cuadro 18).

Cuadro 18
Productividad marginal de cada cuadrilla adicional en el año de prueba, con la misma dotación todos los días y reparto por probabilidad

Cuadrillas por día	Déficit evitado (h)	Ociosas añadidas (h)	k mínimo	Ahorro extra (M COP)	No cubribles evitadas (h)
1 a 2	2176	446	0,21	98,53	2556
2 a 3	1772	848	0,48	80,25	1858
3 a 4	1286	1356	1,05	58,22	937
4 a 5	692	2004	2,90	31,34	270
5 a 6	256	2485	9,72	11,57	46
6 a 7	80	2661	33,14	3,64	0
7 a 8	7	2725	386,76	0,32	0

Cada cuadrilla adicional aporta 2688 h de capacidad en el periodo y cuesta 97,38 millones de COP al año en nómina. Parte de esa capacidad se consume en traslados entre sectores. k mínimo: peso de una hora en déficit con el que la cuadrilla adicional reduce el costo ponderado $kD + O$.
Fuente: elaboración propia.

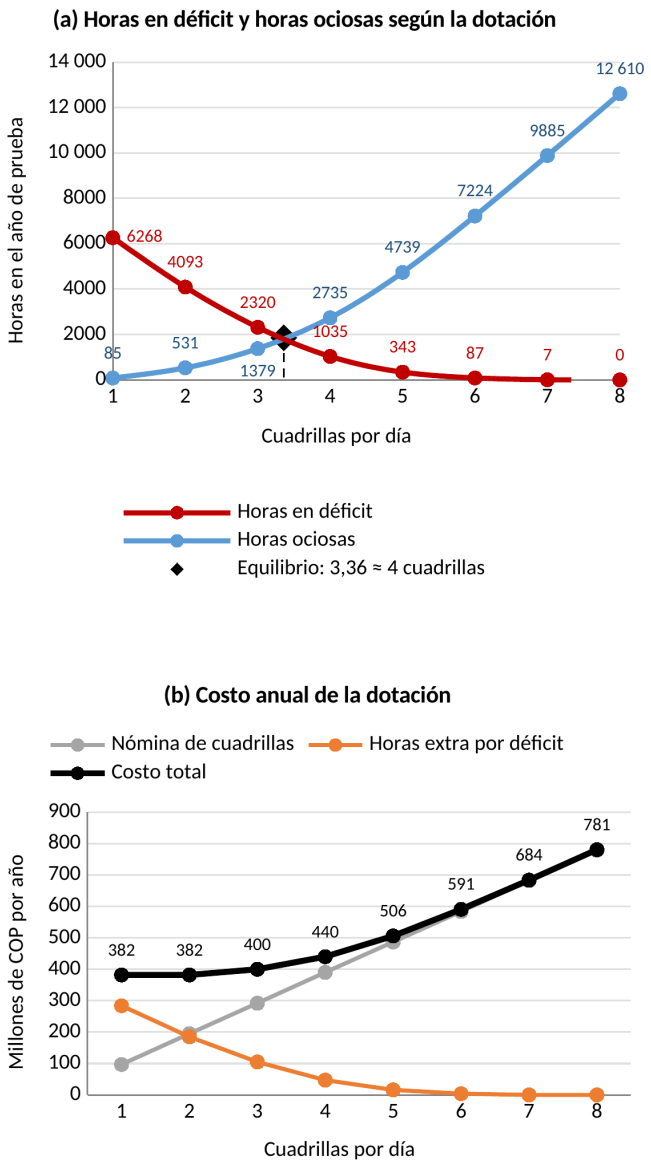


Figura 21. Efecto del número de cuadrillas por día en el año de prueba, con la misma dotación todos los días y reparto por probabilidad. (a) Horas en déficit y horas ociosas; el rombo marca su intersección, en 3,36 cuadrillas, que se redondea a 4. (b) Costo anual de la dotación, en millones de COP: nómina, horas extra por déficit y total, que incluye los traslados.

Cada cuadrilla adicional aporta la misma capacidad, 2688 h en el periodo, pero evita cada vez menos déficit. La segunda cuadrilla evita 2176 h, la tercera 1772, la cuarta 1286 y la quinta 692. El resto de su capacidad queda ociosa, porque atiende emergencias que las demás cuadrillas ya cubrían. Estos rendimientos decrecientes aplanan la curva de déficit y empinan la de horas ociosas. La tercera cuadrilla todavía evita más déficit del que deja ocioso, y la cuarta ya no. Por eso las curvas se cortan entre 3 y 4 cuadrillas. Redondear a 4 se justifica si una hora en

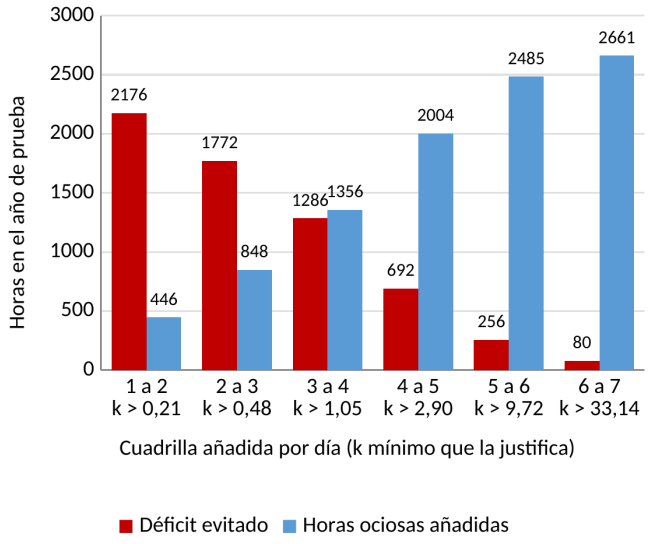


Figura 22. Productividad marginal de la cuadrilla en el año de prueba: horas en déficit que evita y horas ociosas que agrega cada cuadrilla adicional. Debajo de cada par se indica el k mínimo que la justifica, según la ecuación (17).

déficit pesa más que una ociosa. Según el Cuadro 18, la cuarta cuadrilla reduce el costo ponderado $kD+O$ cuando $k > 1{,}05$, y la quinta cuando $k > 2{,}90$. El k mínimo de la ecuación (17) sirve, entonces, como regla de decisión. Si Surtigas fija el peso de una hora en déficit, conviene programar cuadrillas hasta la última cuyo k mínimo quede por debajo de ese peso. Con $k = 2$, la dotación fija adecuada es de 4 cuadrillas por día, y con $k = 3$ es de 5, porque la quinta se justifica desde $k > 2{,}90$. El resultado es coherente con el Cuadro 16. C ajusta la dotación cada día, con un promedio de 3,65 cuadrillas, y por eso conserva el menor costo ponderado incluso con $k = 3$. D, que agrega una cuadrilla todos los días, solo gana cuando $k > 3{,}38$.

En pesos, el costo anual sería mínimo con 2 cuadrillas por día (382,21 millones de COP). La productividad marginal también explica este resultado (Fig. 21b). Cada cuadrilla adicional cuesta 97,38 millones de COP al año en nómina. La segunda ahorra 98,53 millones en horas extra, algo más de lo que cuesta, y por eso se paga sola. Desde la tercera, el ahorro baja a 80,25 millones o menos, y cada cuadrilla cuesta más de lo que ahorra. Una hora en déficit pagada como extra cuesta solo un 25 % más que una ordinaria. Por eso, una cuadrilla tendría que evitar al menos 2150 h de déficit para pagarse sola. En el déficit no cubrible, en cambio, la cuarta cuadrilla todavía evita 937 h, de modo que su aporte al cumplimiento sigue siendo alto. La dotación de menor costo, sin embargo, no es operable. Con 2 cuadrillas, el déficit excede el límite legal de horas extra en 3111 h del periodo, frente a 337 h en la línea base. Con las 4 cuadrillas del equilibrio, ese exceso baja a 316 h, menos que en la línea base. Es la menor dotación fija que mejora el cumplimiento, con un costo de 440,16 millones por año.

El escenario C mejora esa dotación fija. Programa entre 1 y 6 cuadrillas según el pronóstico del día, con un promedio de 3,65. Así cuesta 400,32 millones por año y deja 257 h no cubribles, menos que la dotación fija de 4 en ambos indicadores. De igual forma, D cuesta 36,89 millones menos que una dotación fija de 5 cuadrillas y deja casi el mismo déficit no cubrible (48 frente a 46 h). Ajustar la dotación al pronóstico rinde más, por tanto, que fijar un número de cuadrillas.

7.4. Evaluación financiera

El Cuadro 19 compara el costo anual de cada escenario en el año base con el de la línea base, y evalúa los flujos de los cinco años. Con cuadrillas de 4 personas y el SMMLV de 2026, una hora de cuadrilla cuesta 33 351 COP, según la ecuación (7). La línea base cuesta 429,92 millones de COP en el año base, de los cuales 51,86 millones son horas extra por déficit y 11,13 millones son traslados. La inversión inicial es de 37,89 millones (Cuadro 1). De ellos, 7,31 millones corresponden a la creación del modelo y 30,58 a la marcha blanca.

Cuadro 19
Costo anual de la dotación y evaluación financiera de los escenarios frente a la línea base

Indicador (millones de COP)	A	B	C	D
Nómina de cuadrillas	366,93	366,93	355,91	453,30
Horas extra por déficit	51,86	39,63	40,28	12,21
Traslados entre sectores	11,13	4,04	4,13	3,71
Costo anual total	429,92	410,60	400,32	469,21
VPN	–	45,15	99,36	−156,16
VAE	–	13,55	29,81	−46,85
TIR (%)	–	55,64	83,14	–
Relación B/C	–	2,19	3,62	0,00
PRI descontado (meses)	–	25,57	21,76	–
Déficit no cubrible, año 5 (h)	509	376	401	116

Costos del año base a precios de 2026. Indicadores con flujos nominales frente a la línea base A, TMAR de 15,24 % efectiva anual, horizonte de 5 años e inversión inicial de 37,89 millones. VPN: valor presente neto; VAE: valor anual equivalente; TIR: tasa interna de retorno; PRI: periodo de recuperación de la inversión. En A los indicadores no aplican (–), porque es la línea base; en D, la TIR y el PRI no existen porque todos sus flujos netos son negativos y la inversión no se recupera.
Fuente: elaboración propia.

La Fig. 23 muestra que los flujos cambian de un año a otro. En C, el flujo neto pasa de 24,80 millones en el año 1 a 54,95 millones en el año 3 y cierra en 67,23 millones. El flujo crece porque A escala por redondeo la dotación observada, y en el año 3, con una demanda 17 % mayor, sus días de 4 cuadrillas pasan a 5. C solo agrega cuadrillas cuando el pronóstico lo exige, y ese año paga 41,94 millones menos de nómina que A. Con ello, C alcanza un VPN de 99,36 millones, una TIR del 83,14 % y una relación B/C de 3,62, y recupera la inversión en 21,76 meses. La TIR es alta porque la inversión es pequeña frente al ahorro anual.

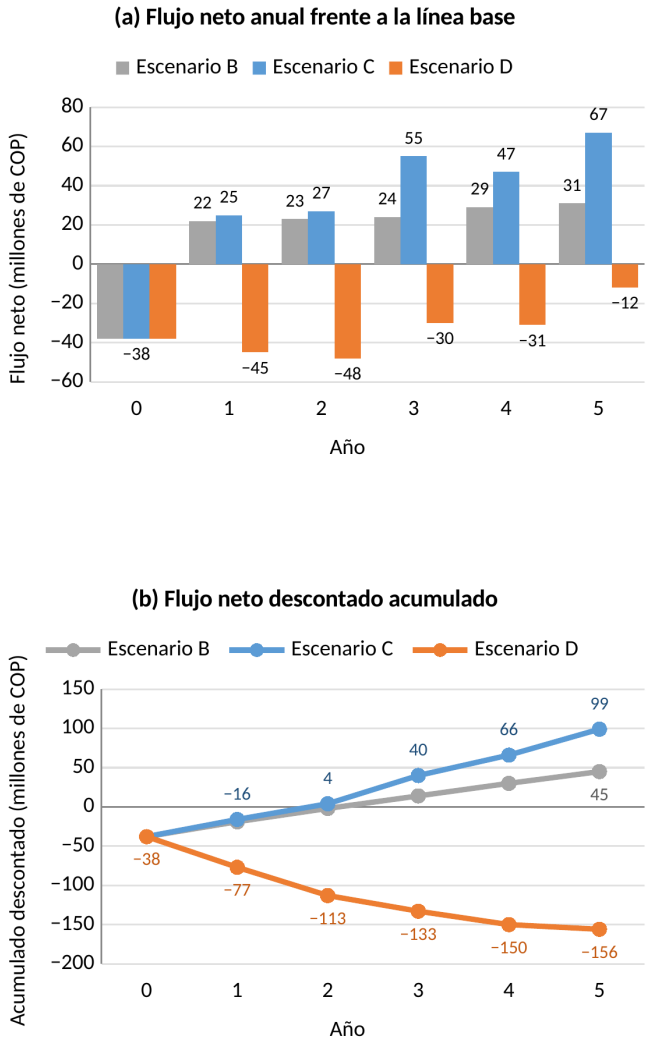


Figura 23. Flujo de caja de los escenarios B, C y D frente a la línea base, en millones de COP corrientes. (a) Flujo neto anual; el año 0 corresponde a la inversión inicial, igual en los tres escenarios, y el año 3 incluye el mantenimiento mayor. (b) Flujo neto descontado acumulado con la TMAR de 15,24 %; su valor en el año 5 es el VPN.

El escenario B también es viable: su VPN es de 45,15 millones y su TIR del 55,64 %. Su ahorro proviene solo de los traslados que evita, porque su nómina es la misma de A. Con un costo de 600 COP/km, su VPN baja a 33,20 millones. Su déficit no cubrible pasa de 351 h en el año 1 a 376 h en el año 5, por debajo de las 509 h de A en ese año. En C, ese déficit se mantiene entre 306 y 401 h.

El escenario D no es viable: su VPN es de −156,16 millones, y como todos sus flujos netos son negativos, no tiene TIR. La cuadrilla de reserva aumenta la nómina mucho más de lo que ahorra en horas extra y traslados (Cuadro 19). A cambio, el déficit no cubrible de D no supera las 116 h en ninguno de los cinco años. Frente a C, D se justifica solo si una hora en déficit cuesta al menos 4,34 veces una hora ordinaria de cuadrilla. Ese costo tendría que incluir el gasto por confiabilidad, es decir, el riesgo para la seguridad y el de incumplir el IRST, que el registro no permite valorar.

El Cuadro 20 muestra que C conserva un VPN positivo en todos los casos evaluados. El supuesto más influyente es el crecimiento de la demanda: sin él, el VPN de C bajaría a 73,55 millones y el de B a 33,65. Si el esquema conservara solo el 80 % de la reducción del déficit, el VPN de C sería de 87,78 millones. El costo por kilómetro afecta sobre todo a B, cuyo VPN va de 33,20 a 52,33 millones entre 600 y 1200 COP/km. D no es viable en ningún caso. Se evaluó, además, el recargo dominical y festivo de la Ley 2466 de 2025 [30]. Ese recargo es del 90 % desde julio de 2026 y del 100 % desde julio de 2027. El caso base no incluye ese recargo en ningún escenario. Con él, el VPN de B no cambia, porque A y B programan las mismas cuadrillas en esos días. El de C sube a 101,98 millones, porque C programa menos turnos que A en domingos y festivos. El de D, en cambio, baja a −221,54 millones. Por lo tanto, C es el escenario que equilibra rentabilidad y cumplimiento. B es rentable, pero menos que C, y D protege el cumplimiento a costa de la rentabilidad.

Cuadro 20
Sensibilidad del VPN a los supuestos de la proyección

	VPN (millones de COP)		
Caso	B	C	D
Caso base	45,15	99,36	−156,16
Demanda sin crecimiento	33,65	73,55	−195,40
Salarios +8 % anual	52,49	112,67	−163,90
Eficiencia del 80 %	34,33	87,78	−191,93
Mantenimiento mayor al doble	45,15	101,65	−160,02
Traslado a 600 COP/km	33,20	87,72	−168,29
Traslado a 1200 COP/km	52,33	106,35	−148,89
Recargo dominical y festivo	45,15	101,98	−221,54

Cada caso cambia un supuesto del caso base. Eficiencia del 80 %: el escenario conserva solo el 80 % de la reducción del déficit frente a A. Recargo dominical y festivo: 90 % el primer año y 100 % desde el segundo, según la Ley 2466 de 2025. El caso base usa 975 COP/km y una TMAR del 15,24 %.
Fuente: elaboración propia.

7.5. Costo por incumplimiento y riesgo regulatorio

Esta subsección aplica la metodología de la sección 5.6.4 a los escenarios simulados. Según la ecuación (10), cada hora no cubrible equivale a 0,64 emergencias atendidas fuera de la hora. En el año de prueba, la línea base deja 337 h no cubribles, B 239, C 257 y D 48. Anualizadas, esas horas corresponden a 233, 166, 178 y 33 emergencias por año, respectivamente (Cuadro 21).

Los componentes tangibles del incumplimiento son pequeños. La indemnización mínima suma 0,69 millones de COP al año en la línea base y 0,52 millones en C. El valor social del gas no suministrado, según la ecuación (12), no supera 0,03 millones en ningún escenario. En consecuencia, la ecuación (13) da $k = 1{,}2525$, prácticamente igual al recargo de la hora extra. Es decir, el gas que deja de recibir

Cuadro 21
Costo por incumplimiento y costo anual esperado de la dotación según la probabilidad de sanción

Indicador	A	B	C	D
Horas no cubribles, año de prueba (h)	337	239	257	48
Emergencias fuera de la hora por año	233	166	178	33
Indemnización mínima (millones de COP)	0,69	0,49	0,52	0,10
Costo anual esperado (millones de COP) según p_0				
0 %	430,61	411,09	**400,85**	469,31
1 %	465,63	435,94	**427,51**	474,28
3 %	535,66	485,65	**480,82**	484,22
5 %	605,70	535,36	534,14	**494,16**
10 %	780,79	659,63	667,43	**519,01**

p_0: probabilidad anual de una multa de 2000 SMMLV en la línea base. El costo anual esperado suma al costo del año base del Cuadro 19 la indemnización mínima y la exposición regulatoria $p_x M_s$. En negrita, el menor de cada fila. D supera a C desde $p_0 = 3{,}2\,\%$ y a B desde $p_0 = 2{,}9\,\%$.

Fuente: elaboración propia.

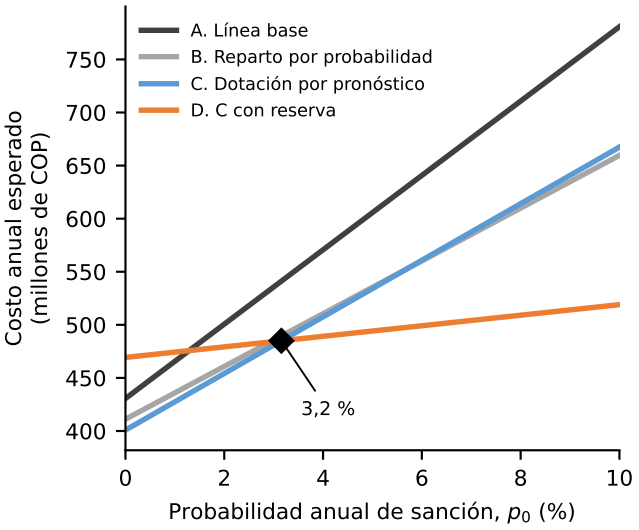


Figura 24. Costo anual esperado de cada escenario según la probabilidad anual p_0 de una multa de 2000 SMMLV en la línea base. El rombo marca el cruce entre C y D, en $p_0 = 3{,}2\,\%$. Costos del año base a precios de 2026, con la indemnización mínima incluida.

el usuario no justifica por sí solo una dotación mayor. El costo relevante del incumplimiento es, entonces, el riesgo para la seguridad de los usuarios y la exposición a una sanción.

El Cuadro 21 y la Fig. 24 incorporan esa exposición al costo anual. Sin riesgo de sanción, C conserva el menor costo, como en el Cuadro 19. A medida que crece p_0, el costo de A, B y C aumenta más rápido que el de D, porque D casi no deja horas no cubribles. Según la ecuación (14), D supera a C desde $p_0 = 3{,}2\,\%$ y a B desde $p_0 = 2{,}9\,\%$, mientras que B supera a C solo desde $p_0 = 5{,}7\,\%$. Con $p_0 = 1\,\%$, cada hora no cubrible de la línea base cuesta en valor esperado unos 95 556 COP, es decir, 2,87 horas de cuadrilla. Ese valor cae dentro del rango de k evaluado en el Cuadro 16.

Por lo tanto, la elección entre C y D no depende del costo de la hora extra, sino del riesgo que Surtigas asigne al incumplimiento del IRST. Si la empresa estima que la probabilidad anual de una sanción máxima es menor de 3,2 %, el esquema con pronóstico (C) tiene el menor costo esperado. Si la estima mayor, la cuadrilla de reserva se paga con la reducción de ese riesgo. Según la sección 7.4, D se justifica si una hora en déficit cuesta al menos 4,34 veces una hora ordinaria. Este resultado expresa ese umbral como una probabilidad, que la empresa puede evaluar con su historial regulatorio. El cálculo usa el costo del año base. Con los flujos de cinco años, el umbral cambiaría en la medida en que crecen las horas no cubribles de cada escenario.

8. Conclusiones y recomendaciones

El diseño de experimentos mostró que la técnica explica el 59 % de la variación del error de validación y que la ventana de entrada no tiene efecto significativo. XGBoost, seleccionado por su error de validación, redujo el MAE del pronóstico diario a 4,22 emergencias por día, un 34 % menos que el mejor método de referencia (6,40). Fue significativamente mejor que los GLM y las referencias, y sin diferencia significativa frente a las redes neuronales en el año de prueba. Su desempeño se mantuvo con reajuste mensual (4,31). En términos operativos, el pronóstico reduce en unas 1468 las horas de cuadrilla mal dimensionadas por año. En el escenario simulado por sectores, el punto de equilibrio entre déficit y horas ociosas es de 4 cuadrillas por día. Ajustar la dotación al pronóstico (C) cuesta menos que fijar ese número y deja menos déficit sin cubrir. Los flujos incorporan los traslados entre sectores, los costos de implementación y el crecimiento de la demanda y de los salarios. Con ellos, C tiene un VPN de 99,36 millones de COP a cinco años y una TIR del 83,14 %. Además, recupera la inversión en 21,76 meses y mantiene estable su déficit no cubrible. La cuadrilla de reserva (D) protege más el cumplimiento, pero no es rentable con esos supuestos. Al valorar el incumplimiento con la regulación vigente, la indemnización a los usuarios y el gas no suministrado resultan marginales. La elección entre C y D depende, entonces, del riesgo de sanción. D solo conviene si la probabilidad anual de una multa máxima supera el 3,2 %.

La demanda es sobredispersa y está dominada por el calendario: los festivos y los fines de semana concentran los días de demanda baja y los 35 días sin emergencias. Por ello, la ZINB describe bien la distribución, pero el pronóstico puntual requiere un modelo que combine calendario y rezagos de forma no lineal. La ZINB y la RB complementan al modelo campeón con la probabilidad de

alta demanda y con la explicación del nivel. El tiempo de respuesta de las no controladas se predice con un error de 0,15 h. La incertidumbre operativa se concentra, entonces, en el número de emergencias y en las controladas.

Se recomienda a Surtigas desplegar el pronóstico con actualización diaria y reajuste mensual, y mantener la LSTM y la BiLSTM como modelos retadores durante el monitoreo. También se recomienda registrar el costo real de la hora de cuadrilla, con prestaciones, y la base y el turno de cada cuadrilla. Conviene registrar además el número de cuadrillas dedicadas a emergencias y el tipo de evento del IRST de cada orden. Con esos datos el análisis costo-beneficio podrá expresarse en valor monetario y en cumplimiento regulatorio. Por último, se recomienda que la empresa estime la probabilidad de una sanción por incumplimiento del IRST con su historial de requerimientos y sanciones. De ella depende la conveniencia de la cuadrilla de reserva.

9. Limitaciones e investigaciones futuras

Los resultados corresponden a la demanda registrada en Montería entre 2017 y 2026 y no deben generalizarse a otras ciudades sin revalidación. El registro recoge las emergencias que llegaron al centro de control y usa la fecha de registro, no la de ocurrencia, por lo que puede existir subregistro. El conjunto de prueba cubre un solo año. La diferencia entre el periodo de validación y el de prueba sugiere que el desempeño relativo de los modelos puede cambiar con el tiempo. Con un solo año de prueba, no es posible separar ese efecto de la variación aleatoria.

La dimensión geoespacial está limitada por el campo de barrio, que es texto libre. En el escenario de la sección 7.2, los barrios se ubicaron de forma aproximada con OpenStreetMap. Sus sectores deben contrastarse con el listado oficial de comunas de la Alcaldía de Montería. Ese escenario es una simulación que supone que una persona del registro equivale a una cuadrilla y que las órdenes sin barrio se distribuyen como las identificadas. Además, modela los traslados con la distancia esperada entre sectores y no considera el desplazamiento dentro de cada sector. La evaluación financiera supone cuadrillas de cuatro personas con el SMMLV, sin prestaciones sociales. La inversión se estimó con el salario de mercado de un analista de datos, y el costo por kilómetro es un supuesto declarado. La TMAR, en cambio, es la tasa regulatoria vigente ajustada con la inflación esperada. El caso base no incluye los recargos dominical, festivo y nocturno de la Ley 2466 de 2025. Su efecto se evaluó solo para el recargo dominical y festivo, en el análisis de sensibilidad. También proyecta el crecimiento de la demanda y de los salarios y un mantenimiento mayor en el año 3 con supuestos declarados. Esos valores deben reemplazarse por los costos reales de Surtigas. El costo por incumplimiento supone un usuario afectado por emergencia, una tarifa tomada de una factura de Cartagena y un riesgo de sanción proporcional a las horas no cubribles. La probabilidad de sanción no pudo estimarse con datos y se evaluó como parámetro. Todas las órdenes tienen dirección en nomenclatura urbana o en formato de manzana y lote. Por lo tanto, georreferenciarlas permitiría asignar cada emergencia a su sector sin depender del campo de barrio. El tablero de control se encuentra en desarrollo y no se evaluó en este trabajo.

No se incorporaron variables exógenas como la precipitación. Las investigaciones futuras pueden abordar esa extensión, validar las redes recurrentes con reajuste periódico y replicar el protocolo en otras ciudades atendidas por Surtigas.

Referencias

[1] X. Wang, A. Li, Z. Lin, S. Li, and Y. Yang, "Natural gas transmission pipeline leak detection model based on acoustic emission and machine learning," *Journal of Pipeline Systems Engineering and Practice*, vol. 15, no. 4, p. 04024047, 2024.

[2] B. Rostami-Tabar and R. J. Hyndman, "Hierarchical time series forecasting in emergency medical services," *Journal of Service Research*, vol. 28, no. 2, p. 278–295, 2024.

[3] R. J. Martin, R. Mousavi, and C. Saydam, "Predicting emergency medical service call demand: A modern spatiotemporal machine learning approach," *Operations Research for Health Care*, vol. 28, p. 100285, 2021.

[4] Comisión de Regulación de Energía y Gas (CREG), "Resolución 100 de 2003: por la cual se adoptan los estándares de calidad en el servicio público domiciliario de gas natural y GLP en sistemas de distribución por redes de tubería," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0100_2003.htm, 2003, vigente, modificada por las Resoluciones CREG 009 de 2005 y 005 de 2006 y complementada por la CREG 016 de 2006. Consultado el 8 de octubre de 2026.

[5] Surtigas S.A. E.S.P., "Historia," https://www.surtigas.co/historia, 2026, consultado el 4 de octubre de 2026.

[6] S. Studer, T. B. Bui, C. Drescher, A. Hanuschkin, L. Winkler, S. Peters, and K.-R. Müller, "Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology," *Machine Learning and Knowledge Extraction*, vol. 3, no. 2, pp. 392–413, 2021.

[7] N. V. S. Korlapati, F. Khan, Q. Noor, S. Mirza, and S. Vaddiraju, "Review and analysis of pipeline leak detection methods," *Journal of Pipeline Science and Engineering*, vol. 2, no. 4, p. 100074, 2022.

[8] H. T. Wong, "Forecasting daily emergency ambulance service demand using biometeorological indexes," *International Journal of Biometeorology*, vol. 67, no. 4, p. 565–572, 2023.

[9] J. A. Green, "Too many zeros and/or highly skewed? a tutorial on modelling health behaviour as count data with poisson and negative binomial regression," *Health Psychology and Behavioral Medicine*, vol. 9, no. 1, p. 436–455, 2021.

[10] C. X. Feng, "A comparison of zero-inflated and hurdle models for modeling zero-inflated count data," *Journal of Statistical Distributions and Applications*, vol. 8, no. 1, p. 8, 2021.

[11] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne: OTexts, 2021. [Online]. Available: https://otexts.com/fpp3/

[12] F. Petropoulos, D. Apiletti, V. Assimakopoulos, M. Z. Babai, D. K. Barrow, S. Ben Taieb *et al.*, "Forecasting: theory and practice," *International Journal of Forecasting*, vol. 38, no. 3, p. 705–871, 2022.

[13] C. Bentéjac, A. Csörgő, and G. Martínez-Muñoz, "A comparative analysis of gradient boosting algorithms," *Artificial Intelligence Review*, vol. 54, no. 3, p. 1937–1967, 2020.

[14] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "M5 accuracy competition: Results, findings, and conclusions," *International Journal of Forecasting*, vol. 38, no. 4, p. 1346–1364, 2022.

[15]H. Hewamalage, C. Bergmeir, and K. Bandara, "Recurrent neural networks for time series forecasting: Current status and future directions," *International Journal of Forecasting*, vol. 37, no. 1, p. 388–427, 2021.

[16]H. Hewamalage, K. Ackermann, and C. Bergmeir, "Forecast evaluation for data scientists: common pitfalls and best practices," *Data Mining and Knowledge Discovery*, vol. 37, no. 2, p. 788–832, 2022.

[17]G. Van Houdt, C. Mosquera, and G. Nápoles, "A review on the long short-term memory model," *Artificial Intelligence Review*, vol. 53, no. 8, p. 5929–5955, 2020.

[18]B. Lindemann, T. Müller, H. Vietz, N. Jazdi, and M. Weyrich, "A survey on long short-term memory networks for time series prediction," *Procedia CIRP*, vol. 99, p. 650–655, 2021.

[19]S. Siami-Namini, N. Tavakoli, and A. S. Namin, "The performance of lstm and bilstm in forecasting time series," in *2019 IEEE International Conference on Big Data (Big Data)*, 2019, p. 3285–3292.

[20]S. Kiranyaz, O. Avci, O. Abdeljaber, T. Ince, M. Gabbouj, and D. J. Inman, "1d convolutional neural networks and applications: A survey," *Mechanical Systems and Signal Processing*, vol. 151, p. 107398, 2021.

[21]N. K. Kitson, A. C. Constantinou, Z. Guo, Y. Liu, and K. Chobtham, "A survey of bayesian network structure learning," *Artificial Intelligence Review*, vol. 56, no. 8, p. 8721–8814, 2023.

[22]M. Schonlau and R. Y. Zou, "The random forest algorithm for statistical learning," *The Stata Journal: Promoting communications on statistics and Stata*, vol. 20, no. 1, p. 3–29, 2020.

[23]Comisión de Regulación de Energía y Gas (CREG), "Resolución 067 de 1995: por la cual se establece el código de distribución de gas combustible por redes," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0067_1995.htm, 1995, texto compilado vigente, con modificaciones de las Resoluciones CREG 059 de 2012, 127 de 2013, 033 de 2015 y 240A de 2016; numerales 5.7 y 5.8 sin modificar. Consultado el 8 de octubre de 2026.

[24]Superintendencia de Servicios Públicos Domiciliarios (SSPD), "Informe de calidad de distribución del servicio público domiciliario de gas combustible por redes de tubería: vigencia 2024," https://www.superservicios.gov.co/sites/default/files/inline-files/Informe-de-calidad-de-distribucion-del-servicio-publico-domiciliario-de-gas-combustible-por-redes-de-tuberia-2024.pdf, 2026, superintendencia Delegada para Energía y Gas, marzo de 2026. Consultado el 8 de octubre de 2026.

[25]M. Dumas, F. Fournier, L. Limonad, A. Marrella, M. Montali, J.-R. Rehse *et al.*, "Ai-augmented business process management systems: A research manifesto," *ACM Transactions on Management Information Systems*, vol. 14, no. 1, p. 1–19, 2023.

[26]D. C. Montgomery, *Design and Analysis of Experiments*, 10th ed. Hoboken, NJ: Wiley, 2020.

[27]M. Delacre, C. Leys, Y. L. Mora, and D. Lakens, "Taking parametric assumptions seriously: Arguments for the use of Welch's F-test instead of the classical F-test in one-way ANOVA," *International Review of Social Psychology*, vol. 32, no. 1, p. 13, 2019.

[28]D. I. Harvey, S. J. Leybourne, and Y. Zu, "Tests for equal forecast accuracy under heteroskedasticity," *Journal of Applied Econometrics*, vol. 39, no. 5, p. 850–869, 2024.

[29]Congreso de la República de Colombia, "Código sustantivo del trabajo," http://www.secretariasenado.gov.co/senado/basedoc/codigo_sustantivo_trabajo.html, 2026, texto compilado vigente. Límite de dos horas extra diarias y doce semanales; recargo del 25 % del trabajo extra diurno (art. 168). Consultado el 8 de octubre de 2026.

[30]——, "Ley 2466 de 2025: por medio de la cual se modifica parcialmente normas laborales y se adopta una reforma laboral para el trabajo decente y digno en colombia," https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=260676, 2025, artículos 10, 13 y 14: trabajo nocturno desde las 7 p. m., límite de dos horas extra diarias y doce semanales, y recargo dominical y festivo gradual hasta 100 %. Consultado el 15 de octubre de 2026.

[31]——, "Ley 2101 de 2021: por medio de la cual se reduce la jornada laboral semanal de manera gradual," http://www.secretariasenado.gov.co/senado/basedoc/ley_2101_2021.html, 2021, jornada máxima de 42 horas semanales desde el 15 de julio de 2026. Consultado el 8 de octubre de 2026.

[32]Portafolio, "¿va a tanquear? estas son las ciudades donde la gasolina y el ACPM están más caros desde octubre," https://www.portafolio.co/energia/va-a-tanquear-estas-son-las-ciudades-donde-la-gasolina-y-el-acpm-estan-mas-caros-desde-octubre-503652, 2026, precios de la Circular CREG 358 de 2026; ACPM en Montería: 11 506 COP por galón. Publicado el 30 de septiembre de 2026.

[33]Ó. J. Restrepo Mantilla, "Prueba Toyota Hilux 2.4 diésel," https://www.elcarrocolombiano.com/pruebas/toyota-hilux-tc5-2-4-diesel-mt/, 2016, el Carro Colombiano. Consumo en ciudad de 38 km por galón según la ficha técnica. Consultado el 10 de octubre de 2026.

[34]I. Shatnawi, N. Al Hosain, A. Muhsen, and L. Yaseen, "Impact of urban traffic on fuel consumption leveraging IoT data: Case study of Riyadh city," https://www.kapsarc.org/our-offerings/publications/impact-of-urban-traffic-on-fuel-consumption-leveraging-iot-data-case-study-of-riyadh-city, 2024, king Abdullah Petroleum Studies and Research Center (KAPSARC), 19 de diciembre de 2024.

[35]Levels.fyi, "Data analyst salary in colombia," https://www.levels.fyi/t/data-analyst/locations/colombia, 2026, mediana de compensación anual de 34,9 millones de COP. Consultado el 10 de octubre de 2026.

[36]Comisión de Regulación de Energía y Gas (CREG), "Resolución 102 002 de 2023: por la cual se modifica la resolución CREG 103 de 2021," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_102-2_2023.htm, 2023, fija la tasa de descuento de 11,88 % en pesos constantes para la actividad de transporte de gas natural. Consultado el 15 de octubre de 2026.

[37]Congreso de la República de Colombia, "Ley 142 de 1994: por la cual se establece el régimen de los servicios públicos domiciliarios y se dictan otras disposiciones," https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=2752, 1994, texto compilado vigente. Artículo 81.2, multas de la Superintendencia de Servicios Públicos Domiciliarios; artículos 136 y 137, falla del servicio e indemnización no inferior al consumo de un día por cada día de falla. Consultado el 15 de octubre de 2026.

[38]Superintendencia de Servicios Públicos Domiciliarios (SSPD), "Resolución SSPD 20242400301975 del 25 de junio de 2024," https://www.superservicios.gov.co/sites/default/files/2024-07/Resolucion-SSPD-No.-20242400301975-del-25-de-junio-de-2024.pdf, 2024, aplica el numeral 81.2 de la Ley 142 de 1994 con un límite de 2000 salarios mínimos mensuales. Consultado el 15 de octubre de 2026.

[39]Corte Constitucional de Colombia, "Sentencia C-030 de 2021," https://www.corteconstitucional.gov.co/relatoria/2021/c-030-21.htm, 2021, declara inexequible el artículo 19 de la Ley 1955 de 2019, que modificaba el artículo 81 de la Ley 142 de 1994. Consultado el 15 de octubre de 2026.

[40]Comisión de Regulación de Energía y Gas (CREG), "Resolución 137 de 2013: por la cual se establecen las fórmulas tarifarias generales para la prestación del servicio público domiciliario de gas combustible por redes de tubería a usuarios regulados," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0137_2013.htm, 2013, artículos 4 y 15: el costo unitario de confiabilidad será cero mientras se define su metodología. Consultado el 15 de octubre de 2026.

[41]——, "Proyecto de resolución 702 016 de 2025: fórmulas tarifarias generales para la prestación del servicio público domiciliario de gas combustible por redes de tubería," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_702-16_2025.htm, 2025, proyecto en consulta, no vigente. Consultado el 15 de octubre de 2026.

[42]——, "Resolución 017 de 2005: por la cual se adopta el costo de interrupción del servicio de gas combustible por redes," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0017_2005.htm, 2005, fija el costo de interrupción en 3100 COP/m^3 de octubre de 2004, actualizado mensualmente con el índice de precios del productor. Consultado el 15 de octubre de 2026.

[43]Unidad de Planeación Minero Energética (UPME), "Circular externa 000064 de 2023: ampliación de la información

de costos de racionamiento de gas natural del estudio técnico del plan de abastecimiento de gas natural," https://www1.upme.gov.co/Hidrocarburos/publicaciones/Ampliacion_de_informacion_regiones.pdf, 2023, costos de racionamiento por regiones, entre ellas la Caribe. Consultado el 9 de octubre de 2026.

[44] Quantil, "Estimación costos de racionamiento: entregable 2, versión final," Unidad de Planeación Minero Energética (UPME), Bogotá, Tech. Rep., 2021, costo de un corte no programado de gas natural en el sector residencial de la región Caribe: 2866,77 COP/m^3 en el corto plazo. Consultado el 15 de octubre de 2026. [Online]. Available: https://docs.upme.gov.co/DemandayEficiencia/Doc_Hemeroteca/Informe_Final_Costos_Racionamiento_GN-GLP_Quantil_C-060-2021.pdf

[45] Surtigas S.A. E.S.P., "Factura del servicio de gas natural, usuario residencial estrato 4, Cartagena, periodo de junio de 2026," Documento físico emitido el 17 de junio de 2026, 2026, consumo de 33 m^3, tarifa aplicada de 2687 COP/m^3 y componente de confiabilidad igual a cero.

[46] OpenStreetMap contributors, "OpenStreetMap y servicio de geocodificación Nominatim," https://nominatim.openstreetmap.org, 2026, datos bajo licencia ODbL. Consultado el 7 de octubre de 2026.

[47] P. Reyes Bohórquez, "Una ciudad colombiana es la más congestionada del mundo, y no es ni Bogotá ni Medellín," https://www.elcarrocolombiano.com/?p=277442, 2025, el Carro Colombiano, 17 de enero de 2025. Datos del TomTom Traffic Index 2024 para Barranquilla.

[48] E. D. Saldivar-Carranza, J. Desai, A. Thompson, M. Taylor, J. Sturdevant, and D. M. Bullock, "Vehicle and pedestrian traffic signal performance measures using LiDAR-derived trajectory data," *Sensors*, vol. 24, no. 19, p. 6410, 2024.

[49] Comisión de Regulación de Energía y Gas (CREG), "Resolución 202 de 2013: por la cual se establecen los criterios generales para remunerar la actividad de distribución de gas combustible por redes de tubería," https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0202_2013.htm, 2013, artículo 14: Cargo Delta de Confiabilidad y/o Seguridad en Distribución, citado en el Concepto CREG 2899 de 2021. Consultado el 9 de octubre de 2026.